

שאלה 2. (25 נקודות)

נתונה קבוצת האימון הבאה:

#	f1	f2	f3	class
1	1	6	1	1
2	7	2	4	1
3	7	6	2	1
4	1	3	5	-1

א. חשב עפ"י אלגוריתם KNN, עבור $K=1$, כיצד יסווג הווקטור הבא: $(f1=4, f2=4, f3=4)$.
רשום בתחילת כל תת-סעיף את נוסחת המטריקה הרלוונטית לאותו תת-סעיף. יש להראות את החישובים עבור כל תת-סעיף.

a. עם מטריקת מרחק L_1 (3 נקודות)

פתרון:

#	f1	f2	f3	class	מרחק מ- $(4,4,4)$
1	1	6	1	1	$ 1-4 + 6-4 + 1-4 =3+2+3=8$
2	7	2	4	1	$ 7-4 + 2-4 + 4-4 =5$
3	7	6	2	1	$ 7-4 + 6-4 + 2-4 =7$
4	1	3	5	-1	$ 1-4 + 3-4 + 5-4 =5$

עבור $k=1$ עם L_1 הנקודות הקרובות ביותר הינן #2 (סיווג 1) ו#4 (סיווג -1). נסווג כ-1 מכיוון שרוב העולם 1.

b. עם מטריקת מרחק L_2 (3 נקודות)

פתרון:

#	f1	f2	f3	class	מרחק מ- $(4,4,4)$
1	1	6	1	1	$\sqrt{(1-4)^2 + (6-4)^2 + (1-4)^2} = 4.69$

2	7	2	4	1	$\sqrt{(7-4)^2 + (2-4)^2 + (4-4)^2} = 3.6$
3	7	6	2	1	$\sqrt{(7-4)^2 + (6-4)^2 + (2-4)^2} = 4.12$
4	1	3	5	-1	$\sqrt{(1-4)^2 + (3-4)^2 + (5-4)^2} = 3.31$

עבור $k=1$ עם $L2$ הנקודה הקרובה ביותר היא #4 (סיווג -1). לכן
נסווג כ-1-

c. עם מטריקת מרחק L_∞ (3 נקודות)

פתרון

#	f1	f2	f3	class	מרחק מ-(4,4,4)
1	1	6	1	1	$J_{hj} \max(1-4 , 6-4 , 1-4) = \max(3, 2, 3) = 3$
2	7	2	4	1	$J_{hj} \max(7-4 , 2-4 , 4-4) = 3$
3	7	6	2	1	$J_{hj} \max(7-4 , 6-4 , 2-4) = 3$
4	1	3	5	-1	$J_{hj} \max(1-4 , 3-4 , 5-4) = 3$

מרחק כל הנקודות זהה ולכן נסווג לפי הרוב, ז"א, נסווג 1.

ב. הסבר/י מהי בעיית underflow באלגוריתם NaiveBayes וכיצד פותרים את הבעיה ? (6 נקודות)

פתרון

בעיית underflow באלגוריתם NaiveBayes נובעת ממכפלה של הסתברויות רבות (לעיתים מאות ויותר) שערכן קרוב ל-0 וברמת הדיוק של המחשב התוצאה מתאפסת. הפתרון: במקום לחשב מכפלת ההסתברויות אנו מחשבים את סכום הלוגים. (נובע מכך שלוג של המכפלה שווה לסכום הלוגים)

ג. נתונה לנו פונקציית הסיווג הבאה: $f(new_vector) = SGN(w \bullet new_vector + b)$. כיצד יסווג הווקטור הבא: $(f1=4, f2=4, f3=4)$. אם נתון ש- $w=(0.5, 0.5, 0.5)$ $b = 3 - 1$ (5 נקודות)

פתרון:

$$f((4,4,4)) = SGN((0.5,0.5,0.5) \bullet \begin{pmatrix} 4 \\ 4 \\ 4 \end{pmatrix} + 3)$$

$$SGN((2+2+2)+3) = SGN(9) = 1$$

הווקטור יסווג כ"חיובי" (1)

ד. מה מטרתו של "טריק הקרנל" (Kernel Trick) באלגוריתם Support Vector (5)
(נקודות)

פתרון: הראנו שלעיתים גם אם אין פתרון לינארי לבעיית הלמידה הנתונה ניתן ל"מפות" את הבעיה למימד גבוה יותר בו יש פתרון לינארי. ע"מ לחסוך את הצורך במיפוי המפורש למימד הגבוה וביצוע החישובים במימד הגבוה, אנו משתמשים בטריק הקרנל. מכיוון שיש מיפויים עבורם מתקיים

$$K(x_i \cdot x_j) = \Phi(x_i) \cdot \Phi(x_j),$$

(ואנו צריכים לדעת את תוצאת המכפלה באלגוריתם SVM), אנו בעצם יכולים לחשב את תוצאת הקרנל (שאינו דורש מיפוי) במקום המיפוי עצמו.