

שאלה 1:

נתונה בעיית למידה (סיווג) בה יש 16 מחלקות סיווג שונות. מהי האנדרופיה המינימאלית והמקסימאלית של "מחלקה" (class)

1. מינימאלית – 0, מקסימאלית - 4
2. מינימאלית – 0, מקסימאלית - 5
3. מינימאלית – 4, מקסימאלית – אין סוף
4. מינימאלית – 4, מקסימאלית - 5
5. מינימאלית – $2\log_2 3$, מקסימאלית - 4

שאלה 2:

K-FOLD CROSS VALIDATION

1. מאפשר להעריך באיזה אלגוריתם למידה כדאי להשתמש.
2. עוזר לנו לבחור את ה"מאפיין" האינפורמטיבי ביותר.
3. מסווג לפי K הווקטורים הקרובים ביותר.
4. שיטה לביצוע boosting בין אלגוריתמים שונים.
5. אף תשובה אינה נכונה

שאלה 3:

נתון לנו שאלגוריתם הלמידה שלנו הצליח לגלות 100 "חיוביים" מתוך 150 "חיוביים", וטעה ב- 10 "שליליים" מתוך 120 שליליים:

1. $TP = 2/3, FP = 1/12, Precision = 10/11$
2. $TP = 1/12, FP = 2/3, Precision = 11/15$
3. $TP = 1/12, FP = 2/3, Precision = 10/11$
4. $TP = 2/3, FP = 1/12, Precision = 11/15$
5. לא ניתן לחשב

שאלה 4:

נתונה טבלת אימון בת 8 דוגמאות. רוצים לסווג דוגמא מסויימת X עפ"י אלגוריתם KNN. חישבנו את המרחק של הדוגמא X המבוקשת מכל אחת מהדוגמאות שבקבוצת האימון. נתונה הטבלה הבאה המכילה סיווג כל דוגמא ומרחקה מהדוגמא X . אנו רוצים לסווג עבור בשתי דרכים: דרך א' - $k=3$ ועם שקלול מרחקים של $w=1/d$. דרך ב' - $k=3$ וללא שקלול מרחקים

סיווג הדוגמא	מרחק מהדוגמא X	דוגמא מס'
1	2	1
1	3	2
1	2	3
2	4	4
2	1.5	5
2	4	6
3	4	7
3	4	8

כיצד יסווג הווקטור X

1. עם שקלול מרחקים יסווג כ-1, ללא שקלול מרחקים יסווג כ-1
2. עם שקלול מרחקים יסווג כ-2, ללא שקלול מרחקים יסווג כ-1
3. עם שקלול מרחקים יסווג כ-2, ללא שקלול מרחקים יסווג כ-2
4. עם שקלול מרחקים יסווג כ-3, ללא שקלול מרחקים יסווג כ-2
5. עם שקלול מרחקים יסווג כ-1, ללא שקלול מרחקים יסווג כ-2

שאלה 5:

הוספת שכבה חבויה ברשתות נוירונים:

1. ללא שכבות חבויות – הפרדה לינארית בלבד. עם שכבה חבויה אחת לפחות – גם הפרדה לא לינארית.
2. ללא שכבות חבויות – הפרדה לא לינארית בלבד. עם שכבה חבויה אחת לפחות – הפרדה לינארית בלבד.
3. עם שכבות חבויות וללא שכבות חבויות – הפרדה לינארית בלבד
4. עם שכבות חבויות וללא שכבות חבויות – גם הפרדה לא לינארית
5. אף תשובה אינה נכונה

שאלה 6:

אלגוריתם Lazy

1. אינו מחשב מודל למידה בשלב ה"אימון", אלגוריתם KNN הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה
2. אינו מחשב מודל למידה בשלב ה"אימון", אלגוריתם פרספטרון הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה
3. מחשב מודל למידה כבר בשלב ה"אימון", אלגוריתם פרספטרון הינו אלגוריתם Lazy, חסרון גדול הינו זמן בניית המודל
4. מחשב מודל למידה כבר בשלב ה"אימון", אלגוריתם KNN הינו אלגוריתם Lazy, חסרון גדול הינו זמן בניית המודל
5. מחשב מודל למידה גם בשלב ה"אימון" וגם בזמן סיווג נקודה חדשה, אלגוריתם SVM הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה.

שאלה 7:

אלגוריתם SVM – שתי שיטות שלמדנו לטיפול כשאין הפרדה לינארית:

1. soft margin ו"מיפוי" למימד גבוה
2. hard margin ו"מיפוי" למימד גבוה
3. hard margin – soft margin
4. לא ניתן לפתור באמצעות אלגוריתם SVM מקרה לא לינארי.
5. אף תשובה אינה נכונה


שאלה 8:

אלגוריתם DBSCAN שלמדנו בהרצאה

1. אלגוריתם clustering המתבסס על צפיפות הווקטורים.
2. אלגוריתם classification המתבסס על צפיפות הווקטורים.
3. אלגוריתם regression המתבסס על צפיפות הווקטורים.
4. הינו אלגוריתם supervised
5. אף תשובה אינה נכונה

שאלה 9:

נתון אלגוריתם הפרספטרון הבא. ערך הסף בשכבת היציאה הינו 0. ערכי המשקולות מופיעים
בשרטוט. אלו מהווקטורים הבאים יסווג כ"שלילי"



1. $(x_1=1, x_2=2, x_3=3, x_4=4)$
2. $(x_1=4, x_2=3, x_3=2, x_4=1)$
3. $(x_1=2, x_2=2, x_3=1, x_4=1)$
4. $(x_1=4, x_2=3, x_3=4, x_4=1)$
5. כל התשובות נכונות

שאלה 10:

אלגוריתם Adaboost (Adaptive Boosting) רגיש ל"רעשים" -

1. כי בכל איטרציה מעלה את המשקל של ה"רעשים" ו"מתאמצ" יותר לסווג נכון את ה"רעש"
2. אינו רגיש ל"רעשים"
3. כי מחשב את ההסתברות לקבלת ווקטור "רעש"
4. כי באלגוריתם זה יוצא שאלגוריתם "רעש" תמיד קרוב למחלקת ה"חיוביים"
5. אף תשובה אינה נכונה

שאלה 11:

אלגוריתם NaiveBayes -

1. משתמש בידע על ההסתברות להופעה של כל מחלקה (נלמד מתוך קבוצת האימון)
2. אינו משתמש בידע על ההסתברות להופעה של כל מחלקה
3. משתמש רק בידע המוקדם של ההסתברות להופעה של מחלקה חיובית
4. משתמש בידע המוקדם רק עבור בעיה בינארית
5. אף תשובה אינה נכונה

שאלה 12:

נתונים לנו שלושה אלגוריתמים בלתי תלויים זה בזה לפתרון בעית למידה בינארית. רוצים לבצע תהליך של boosting בין האלגוריתמים ע"י הצבעת רוב בין האלגוריתמים. כל מאפיין יכול לקבל את הערך 0 או 1.

Algorithm A: $\text{class} = \text{SGN}(0.1 \times f_1 + 0.2 \times f_2 + 0.3 \times f_3)$

Algorithm B: $\text{class} = \text{if } (f_1 == 1 \text{ and } f_2 == 1) \text{ then classify as POS else classify NEG}$

Algorithm C: $\text{class} = \text{SGN}(0.1 \times f_1 + 0.2 \times f_2 - 0.4 \times f_3)$

כיצד יסווג הווקטור $(f_1=1, f_2=1, f_3=?)$ (לא ידוע מהו f_3)

1. POS

2. NEG

3. צריך לדעת את f_3

4. מכיוון שהאלגוריתמים לא מאותו סוג, לא ניתן לבצע boosting.

5. לא ניתן לחשב



המסלול האקדמי
המכללה למינהל

המסלול האקדמי המכללה למינהל

החוג למדעי המחשב

_____ ת.ז. הסטודנט:
_____ מספר חדר:
_____ מספר נבחן:

ברקוד

מבחן בקורס: למידה ממוחשבת וכריית נתונים

תאריך הבחינה: 08/06/2012

שנה"ל: תשע"ב, **סמסטר:** ב', **מועד:** ב'

שם המרצה/ים: דר' משה בוטמן

שם המתרגל/ים:

משך הבחינה: שעתיים וחצי

מבנה הבחינה: הבחינה מורכבת מחלק אחד.

מספר השאלות בבחינה: .

משקל כל שאלה: בצמוד לכל שאלה

הוראות לנבחן:

- אסור השימוש במחשב כיס
- יש לענות במחברת הבחינה.
- לבחינה לא מצורף דבר.
- לא נדרש להחזיר את השאלון.
- מחברת נפרדת: לא

שאלה 1 (20 נקודות):

נתונים בעיית למידה בהינתן המאפיינים feature1, feature2, feature3 יש צורך לחזות את class.
נתונה קבוצת האימון הבאה:

#	feature1	feature2	feature3	class
1	1	1	0	P
2	1	0	1	P
3	0	0	0	N
4	0	1	1	N

א. (5 נקודות) חשב את $\text{InfoGain}(\text{class}|\text{feature1})$

פתרון:

$$\begin{aligned} \text{InfoGain}(\text{class} | \text{feature1}) &= H(\text{class}) - H(\text{class} | \text{feature1}) \\ H(\text{class}) &= -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{2} = 1 \\ H(\text{class} | \text{feature1}) &= p(\text{feature1}=1) \times H(\text{class} | \text{feature1}=1) + p(\text{feature1}=0) \times H(\text{class} | \text{feature1}=0) \\ p(\text{feature1}=1) &= \frac{1}{2}, p(\text{feature1}=0) = \frac{1}{2} \\ H(\text{class} | \text{feature1}=1) &= 0, H(\text{class} | \text{feature1}=0) = 0 \\ \text{InfoGain}(\text{class} | \text{feature1}) &= 1 - (0 + 0) = 1 \end{aligned}$$

ב. (5 נקודות) צייר עץ החלטה בעל רמה אחת לבעיה

ג. פתרון:

מכיוון שיצא לנו ש- $\text{infoGain}(\text{class}|\text{feature1}) = 1$ שזה הערך המקסימאלי האפשרי ברור שכדאי להשתמש במאפיין feature1 בראש העץ.

If (feature1 == 1) then classify P
Else if (feature1 == 0) classify N

ד. (3 נקודות) סווג עפ"י העץ שנוצר את הדוגמא ($\text{feature1} = 1, \text{feature2} = 1, \text{feature3} = 1$)

פתרון: מספיק לבדוק את feature1 , מכיוון ש- $\text{feature1} = 1$ נציב באלגוריתם מסעיף ב' ונקבל סיווג: P

ה. (7 נקודות) נניח שמבקשים מאיתנו לבצע "אישכול" (clustering) של הווקטורים. הרץ את אלגוריתם k-means. עבור $k=2$. התחל כך שווקטור #1 הינו המרכז הראשון וווקטור #2 הינו הווקטור השני. מה יהיו המרכזים באיטרציה השנייה.

פתרון: $\text{Center\#1} = (1,1,0)$, $\text{Center\#2} = (1,0,1)$

נבצע שיוך של הווקטורים למרכזים. לצורך כך נחשב את המרחק של הווקטורים משני המרכזים בסה"כ אנו צריכים לחשב איזה מרחק קרוב יותר לכל נקודה כך שאין צורך להוציא שורש ולכן נחשב את המרחק בריבוע.

#	f1	f2	f3	Distance from C1 ²	Distance from C2 ²
1	1	1	0	0	אין צורך לחשב
2	1	0	1	אין צורך לחשב	0
3	0	0	0	$(0-1)^2 + (0-1)^2 + (0-0)^2 = 2$	$(0-1)^2 + (0-0)^2 + (0-1)^2 = 2$
5	0	1	1	$(0-1)^2 + (1-1)^2 + (1-0)^2 = 2$	$(0-1)^2 + (1-0)^2 + (1-1)^2 = 2$

ווקטור מס' 3 – מרחק שווה מהמרכז הראשון ומהמרכז השני. נבחר שרירותית לשייך למרכז הראשון.

ווקטור מס' 4 – מרחק שווה מהמרכז הראשון ומהמרכז השני. נבחר שרירותית לשייך למרכז השני.

(כמובן שגם בחירה למרכז השני היא בסדר)

כעת, ווקטורים #1, #3, משוייכים למרכז הראשון, ווקטורים #2, #4 משוייכים למרכז השני.

לכן המרכזים החדשים:

$$\text{center1} = [(1,1,0) + (0,0,0)] / 2 = (0.5, 0.5, 0)$$

$$\text{center2} = [(1,0,1) + (0,1,1)] / 2 = (0.5, 0.5, 1)$$

שאלה 2 (20 נקודות):

נתונים בעיית למידה בהינתן המאפיינים feature1, feature2, feature3 יש צורך לחזות את class.
נתונה קבוצת האימון הבאה:

#	feature1	feature2	feature3	class
1	1	1	0	P
2	1	0	1	P
3	1	0	0	N
4	0	1	1	N

א. (7 נקודות) הרצנו את בעיית האופטימיזציה של אלגוריתם SVM לינארי והפתרון שקיבלנו הוא:

$$\alpha_1 = 1, \alpha_2 = 1, \alpha_3 = 1, \alpha_4 = 1, b = 0.5$$

פונקציית הסיווג הינה: $f(x) = \text{SGN}(w^T x - b)$

חשב את ה-TP וה-FP על קבוצת האימון

$$W = \sum_{SV} y_i \alpha_i x_i = 1 \times 1 \times (1,1,0) + 1 \times 1 \times (1,0,1) + (-1) \times 1 \times (1,0,0) + (-1) \times 1 \times (0,1,1)$$

$$(1,1,0) + (1,0,1) + (-1,0,0) + (0,-1,-1) = (2,0,0)$$

$$w = (1,0,0)$$

עעת נבדוק את הסיווג של כל ווקטור:

#	feature1	feature2	feature3	class	svm	Classification
1	1	1	0	P	$(1,0,0)^T x (1,1,0) - 0.5 = 0.5$	P
2	1	0	1	P	$(1,0,0)^T x (1,0,1) - 0.5 = 0.5$	P
3	0	0	0	N	$(1,0,0)^T x (1,0,0) - 0.5 = 0.5$	P
4	0	1	1	N	$(1,0,0)^T x (0,1,1) - 0.5 = -0.5$	N

לכן ה-TP הוא: 2/2

ה-FP הוא 1/2

ב. (7 נקודות) הרצנו את בעיית האופטימיזציה של אלגוריתם SVM עם קרנל פולינומיאלי (לא לינארי) והפתרון שקיבלנו הוא:

$$\alpha_1 = 1, \alpha_2 = 1, \alpha_3 = 1, \alpha_4 = 1, b = 0.02$$

השתמש בטריק הקרנל ע"מ לסווג את הדוגמא הבאה: (feature1 = 1, feature2 = 1, feature3 = 1)

$$\langle \phi(x_1), \phi(x_2) \rangle = \frac{1}{3} (\langle x_1, x_2 \rangle)^3 \quad \text{בהינתן הקרנל}$$

$$\begin{aligned} \text{Classification}(x) &= \text{SGN}\left(\sum_{SV} y_i \alpha_i \langle \phi(x_{svm-i}), \phi(x) \rangle - b\right) \\ y_i \alpha_i \langle \phi(x_{svm-i}), \phi(x) \rangle &= \\ 1 \times \langle \phi(1,1,0), \phi(1,1,1) \rangle &+ 1 \times 1 \times \langle \phi(1,0,1), \phi(1,1,1) \rangle + (-1) \times 1 \times \langle \phi(1,0,0), \phi(1,1,1) \rangle + (-1) \times 1 \times \langle \phi(0,1,1), \phi(1,1,1) \rangle \\ \frac{1}{3} \langle (1,1,0), (1,1,1) \rangle^3 &+ \frac{1}{3} \langle (1,0,1), (1,1,1) \rangle^3 - \frac{1}{3} \langle (1,0,0), (1,1,1) \rangle^3 - \frac{1}{3} \langle (0,1,1), (1,1,1) \rangle^3 \\ \frac{1}{3} \times 8 + \frac{1}{3} \times 8 - \frac{1}{3} \times 1 - \frac{1}{3} \times 8 &= \frac{8+8-1-8}{3} = \frac{7}{3} \\ \text{Classification}(1,1,1) &= \text{SGN}\left(\frac{7}{3} - 0.02\right) > 0 \rightarrow \text{POS} \end{aligned}$$

ג. (6 נקודות) נניח שאנו משנים את אלגוריתם העדכון של הפרספטרון עפ"י הנוסחה הבאה:

If current example (x_i, y_i) is correctly classified, don't change

If wrongly classified as 1, $w \leftarrow w + x_i$

If wrongly classified as -1, $w \leftarrow w + x_i$

מה הבעיה באלגוריתם עדכון זה?

פתרון: אלגוריתם זה הינו בעייתי, כי במצב שבו אנו טועים ומסווגים דוגמא "שלילית" כ-"חיובית", זאת אומרת שסט המשקולות שלנו מחזיר תשובה (בפונקציה) שהיא גדולה ממה שצריך להיות – במצב זה היינו רוצים להקטין את ערכי המשקולות כדי שיתאפשר לקבל ערך קטן יותר, אבל באלגוריתם המוצע זה לא אפשרי.

בהצלחה !