



המסלול האקדמי
המכללה למינהל

המסלול האקדמי המכללה למינהל

החוג למדעי המחשב

ת.ז. הסטודנט: _____
מספר חדר: _____
מספר נבחן: _____

ברקוד

מבחן בקורס: למידה ממוחשבת וכריית נתונים

תאריך הבחינה: 27/06/2012

שנה"ל: תשע"ב, סמסטר: קיץ, מועד: א'

שם המרצה/ים: דר' משה בוטמן

שם המתרגל/ים:

משך הבחינה: שעתיים וחצי

מבנה הבחינה: הבחינה מורכבת מחלק אחד.

מספר השאלות בבחינה: .

משקל כל שאלה: בצמוד לכל שאלה

הוראות לנבחן:

- אסור השימוש במחשב כיס בחרי/י
- יש לענות במחברת הבחינה.
- לבחינה לא מצורף דבר.
- לא נדרש להחזיר את השאלון.
- מחברת נפרדת: לא

שאלה 1 (20 נקודות):

נתונה קבוצת האימון הבאה

(נתונים המאפיינים feature1, feature2, feature3 ויש צורך לחזות את class):

#	Feature1	Feature2	Feature3	Class
1	2	1	1	P
2	1	3	2	P
3	3	0	1	N
4	0	2	0	N

א. (7 נקודות) נדרש לסווג באמצעות KNN את קבוצת המבחן הבאה:

#	Feature1	Feature2	Feature3	class
1	2	2	2	P
2	3	3	3	P
3	1	1	1	N
4	0	0	0	N

מטריקת מרחק $L1$, $K=3$, ללא שקלול מאפיינים, ללא שקלול מרחקים. חשב/חשבי את אחוז ה True-Positive ואת אחוז ה False Positive של האלגוריתם המוצע על קבוצת המבחן.

(תזכורת $L1$ עבור שני ווקטורים שארכם n : $d(X,Y)=|X1-Y1|+|X2-Y2|+.....+|Xn-Yn|$)

ב. (5 נקודות) כיצד יסווג הווקטור הבא: (Feature1=2, Feature2 = 2, Feature3 = 2) עם שקלול מרחקים של $1/d^2$?

ג. (4 נקודות) נניח שהטבלה מייצגת רשימות של קניות בסופר. Feature1 מייצג את מוצר החלב שנקנה (1 – "חלב", 2 – "גבינה" וכו'), feature2 מייצג את סוג השתיה ו- feature3 מייצג את מוצר הבשר שנקנה. יש לנו מאות רשומות ואנו רוצים לבצע תהליך של "אישכול" (clustering) כדי למצוא קבוצות של קונים. ידוע לנו גם שיש 5 קבוצות. האם אלגוריתם k-means מתאים למקרה זה?

ד. (4 נקודות) אלגוריתם K-MEANS: עבור מקרה דו-מימדי, הצג דוגמא של ווקטורים ובחירה ראשונית של "מרכזים" שתוביל להתכנסות לתוצאה לא אופטימאלית

שאלה 2 (20 נקודות):

א. נתונה בעיית למידה דו-מימדית (2d). הפעלנו אלגוריתם SVM ויצא לנו שה-support vectors הינם:

#	f1	f2	class
1	0	6	P
2	5	4	P
3	2	0	N

א. (3 נקודות) הצג ויזואלית את ה- support vectors על גבי שרטוט ושרטט באופן סכמטי (לא חייב להיות מדויק אבל מבהיר) את המפריד הלינארי המתקבל מאלגוריתם SVM (hard margin). (ציר ה-x: f1)

ב. (3 נקודות) מה ערך ה- hyperplane שנוצר ע"י אלגוריתם SVM לינארי (hard margin) אם נציב בו את הנקודה (5,4)

ג. (9 נקודות) חשב באופן מדויק את משוואת ה- hyperplane שנוצר ע"י אלגוריתם SVM $w_1f_1 + w_2f_2 + b = 0$

ד. (5 נקודות) מהו ה-VC dimension (Vapnik-Chervonenkis) של ה-hyperplane שנוצר?

בהצלחה !

שאלה 1:

עץ החלטה:

1. מסוגל לפתור בעיה "מרבית מחלקות" (multi-class), מסוגל לפתור בעיה לא לינארית
2. מסוגל לפתור רק בעיה בינארית, מסוגל לפתור בעיה לא לינארית
3. מסוגל לפתור בעיה "מרבית מחלקות" (multi-class), מסוגל לפתור רק בעיה לינארית
4. מסוגל לפתור רק בעיה בינארית, מסוגל לפתור רק בעיה לינארית
5. כל התשובות נכונות

שאלה 2:

סדר התהליכים הנכון יותר בבניית מערכת למידה

1. איסוף תצפיות, תהליכי קדם עיבוד, הוצאת מאפיינים, בחירת אלגוריתם למידה, הערכת ביצועים.
2. תהליכי קדם עיבוד, הוצאת מאפיינים, בחירת אלגוריתם למידה, הערכת ביצועים, איסוף תצפיות
3. איסוף תצפיות, הוצאת מאפיינים, בחירת אלגוריתם למידה, תהליכי קדם עיבוד, הערכת ביצועים.
4. איסוף תצפיות, הערכת ביצועים, תהליכי קדם עיבוד, הוצאת מאפיינים, בחירת אלגוריתם למידה.
5. אין חשיבות לסדר

שאלה 3:

אלגוריתם KNN (K-Nearest-Neighbors)

1. קל למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, צריך להגדיר מראש את K ואת מטריקת המרחק, מאפשר הפרדה לא לינארית
2. קל למימוש באופן מקבילי בזמן סיווג נקודה חדשה, מייצר מודל למידה כבר בשלב האימון, זמן ריצה שקול לזמן ריצה של אלגוריתם פרספטרון, צריך להגדיר מראש את K ואת מטריקת המרחק, מאפשר רק הפרדה לינארית
3. לא ניתן למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, צריך להגדיר מראש את K ואת מטריקת המרחק, מאפשר הפרדה לא לינארית
4. קל למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, צריך להגדיר מראש את K ואת מטריקת המרחק, מאפשר רק הפרדה לינארית
5. קל למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה מהיר מזמן הריצה של פרספטרון, צריך להגדיר מראש את K ואת מטריקת המרחק, מאפשר הפרדה לא לינארית

שאלה 4:

אלגוריתם KNN (K-nearest neighbors). נתונים 100 ווקטורים. רוצים לסווג ווקטור חדש.

1. עבור $k=1$ אין משמעות לשקלול מרחקים
2. עבור $k=1$ אין משמעות לשקלול מאפיינים
3. עבור $k=1$ אין משמעות לשקלול מאפיינים ואין משמעות לשקלול מרחקים
4. עבור $k=100$ אין משמעות לשקלול מרחקים
5. כל התשובות נכונות

שאלה 5:

הוספת שכבה חבויה ברשתות נוירונים:

1. רק אם נפעיל פונקציית אקטיביציה לא לינארית על נוירונים בשכבה החבויה, נוכל לייצר אלגוריתם לא לינארי
2. גם אם לא נפעיל פונקציית אקטיביציה לא לינארית על נוירונים בשכבה החבויה, נוכל לייצר אלגוריתם לא לינארי
3. לא ניתן לבצע הפרדה לא לינארית עם שכבה חבויה אחת.
4. זהו פרספטרון
5. אף תשובה אינה נכונה

שאלה 6:

מצאנו אלגוריתם למידה לבעיה מסויימת. החלטנו לבחון את האלגוריתם על 1000 ווקטורים. 500 "חיוביים" ו-500 "שליליים". חישבנו את ה-confusion matrix. חישבנו ה-TP וה-FP מבוצע באחוזים כפי שלמדנו. קיבלנו ש: $TP=0.5\%$, $FP=0.1\%$. כעת שכפלנו את הווקטורים החיוביים (כלומר יש לנו כעת 1000 ווקטורים חיוביים, כל ווקטור חיובי מופיע פעמיים).

6. אחוז ה-TP וה-FP ישאר כפי שהיה לפני השינוי
7. אחוז ה-TP יגדל לאחר השינוי
8. אחוז ה-FP יקטן לאחר השינוי
9. אחוז ה-TP יגדל וה-FP יקטן לאחר השינוי
10. אחוז ה-TP וה-FP יגדל לאחר השינוי

שאלה 7:

אלגוריתם SVM – "מקדם הענישה" C עבור soft-margin:

1. מגדיר עבור המקרה בו אין פתרון לינארי את "מחיר הטעות". מחושב ע"י סכום מרחקי הטעויות מה-hyperplane המתאים.
2. מגדיר עבור המקרה בו אין פתרון לינארי את "מחיר הטעות". מחושב ע"י מס' הווקטורים בהם אנו טועים.
3. לא משפיע על ה-hyperplane שיוצר
4. לא ניתן לפתור באמצעות אלגוריתם SVM מקרה לא לינארי.
5. אף תשובה אינה נכונה


שאלה 8:

אלגוריתמים היררכיים לביצוע "אישכול" (clustering)

1. קושי הוא להגדיר תנאי עצירה בבניית ההיררכיה
2. תנאי העצירה מוגדר היטב באלגוריתם
3. קלט לאלגוריתם הינו מס' ה"אשכולות" הקיימים
4. הינם אלגוריתם supervised
5. אף תשובה אינה נכונה

שאלה 9:

נתונה רשת הנורונים הבאה. פונקציית האקטיבציה בשכבות הביניים ובשכבת היציאה הינה SGN עם ערך סף 0 (כלומר אם גדול/שווה ל-0 הערך הוא 1, אחרת 0). ערכי המשקולות מופיעים בשרטוט. אלו מהווקטורים הבאים יסווג כ"חיובי"



1. כל התשובות נכונות
2. $(x1=1, x2=2, x3=3)$
3. $(x1=4, x2=3, x3=2)$
4. $(x1=2, x2=2, x3=1)$
5. $(x1=4, x2=3, x3=4)$

שאלה 10:

נאמר על Learner שהוא PAC (Probably Approximately Correct)

1. אם בהסתברות גבוהה (לפחות $1-\delta$), מייצר לנו אלגוריתם שמובטח שטעותו קטנה מ- ϵ . האלגוריתם מיוצר בזמן חסום פולינומיאלי ע"י מס' פרמטרים.
2. אם בהסתברות גבוהה (לפחות $1-\delta$), מייצר לנו אלגוריתם שמובטח שטעותו גדולה מ- ϵ . האלגוריתם מיוצר בזמן חסום פולינומיאלי ע"י מס' פרמטרים.
3. אם מייצר לנו טעות 0 על קבוצת האימון
4. אם מייצר לנו טעות 0 על קבוצת המבחן
5. כל התשובות נכונות

שאלה 11:

נתונה טבלת האימון הבאה:

X1	X2	X3	X4	class
1	2	1	1	P
1	2	2	1	P
1	1	2	2	N
1	1	1	1	N

נדרש לסווג עם אלגוריתם Naïve-Bayes. המשתנים x_1, x_2, x_3, x_4 הינם בלתי תלויים זה בזה. כיצד יסווג הווקטור $v=(x_1=1, x_2=2, x_3=2, x_4=1)$ עפ"י האלגוריתם? אין להשתמש ב"החלקה" גם אם נדרש.

1. P
2. N
3. הסתברות זהה לשניהם
4. אף תשובה אינה נכונה
5. לא ניתן לחשב

שאלה 12:

נתונים לנו 100 ווקטורים כקבוצת אימון. ע"מ לבצע תהליך boosting מציע יענקלה לייצר מס' אלגוריתמי למידה שונים בצורה הבאה: לסדר את הווקטורים בסדר שונה בכל פעם, כך n פעמים, עבור כל סידור של הווקטורים לייצר אלגוריתם למידה שונה ואז עבור ווקטור חדש להכריע בהצבעת רוב בין n המסווגים שנוצרו. איזה אלגוריתם מהאלגוריתמים הבאים עשוי להיות רגיש לסדר של הווקטורים:

1. פרספטרון במוד incremental
2. SVM
3. עץ החלטה ID3
4. KNN
5. Naïve Bayes

שאלה 1:

עץ החלטה:

1. מסוגל לפתור בעיה "מרבית מחלקות" (multi-class), מסוגל לפתור בעיה לא לינארית
2. מסוגל לפתור רק בעיה בינארית, מסוגל לפתור בעיה לא לינארית
3. מסוגל לפתור בעיה "מרבית מחלקות" (multi-class), מסוגל לפתור רק בעיה לינארית
4. מסוגל לפתור רק בעיה בינארית, מסוגל לפתור רק בעיה לינארית
5. כל התשובות נכונות

שאלה 2:

סדר התהליכים הנכון יותר בבניית מערכת למידה

1. איסוף תצפיות, תהליכי קדם עיבוד, הוצאת מאפיינים, בחירת אלגוריתם למידה, הערכת ביצועים.
2. תהליכי קדם עיבוד, הוצאת מאפיינים, בחירת אלגוריתם למידה, הערכת ביצועים, איסוף תצפיות
3. איסוף תצפיות, הוצאת מאפיינים, בחירת אלגוריתם למידה, תהליכי קדם עיבוד, הערכת ביצועים.
4. איסוף תצפיות, הערכת ביצועים, תהליכי קדם עיבוד, הוצאת מאפיינים, בחירת אלגוריתם למידה.
5. אין חשיבות לסדר

שאלה 3:

אלגוריתם KNN (K-Nearest-Neighbors)

1. קל למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, צריך להגדיר מראש את K ואת מטריקת המרחק, מאפשר הפרדה לא לינארית
2. קל למימוש באופן מקבילי בזמן סיווג נקודה חדשה, מייצר מודל למידה כבר בשלב האימון, זמן ריצה שקול לזמן ריצה של אלגוריתם פרספטרום, צריך להגדיר מראש את K ואת מטריקת המרחק, מאפשר רק הפרדה לינארית
3. לא ניתן למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, צריך להגדיר מראש את K ואת מטריקת המרחק, מאפשר הפרדה לא לינארית
4. קל למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, צריך להגדיר מראש את K ואת מטריקת המרחק, מאפשר רק הפרדה לינארית
5. קל למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה מהיר מזמן הריצה של פרספטרום, צריך להגדיר מראש את K ואת מטריקת המרחק, מאפשר הפרדה לא לינארית

שאלה 4:

אלגוריתם KNN (K-nearest neighbors). נתונים 100 ווקטורים. רוצים לסווג ווקטור חדש.

1. עבור $k=1$ אין משמעות לשקלול מרחקים
2. עבור $k=1$ אין משמעות לשקלול מאפיינים
3. עבור $k=1$ אין משמעות לשקלול מאפיינים ואין משמעות לשקלול מרחקים
4. עבור $k=100$ אין משמעות לשקלול מרחקים
5. כל התשובות נכונות

שאלה 5:

הוספת שכבה חבויה ברשתות נוירונים:

1. רק אם נפעיל פונקציית אקטיביציה לא לינארית על נוירונים בשכבה החבויה, נוכל לייצר אלגוריתם לא לינארי
2. גם אם לא נפעיל פונקציית אקטיביציה לא לינארית על נוירונים בשכבה החבויה, נוכל לייצר אלגוריתם לא לינארי
3. לא ניתן לבצע הפרדה לא לינארית עם שכבה חבויה אחת.
4. זהו פרספטרון
5. אף תשובה אינה נכונה

שאלה 6:

מצאנו אלגוריתם למידה לבעיה מסויימת. החלטנו לבחון את האלגוריתם על 1000 ווקטורים. 500 "חיוביים" ו-500 "שליליים". חישבנו את ה-confusion matrix. חישבנו ה-TP וה-FP מבוצע באחוזים כפי שלמדנו. קיבלנו ש: $TP=0.5\%$, $FP=0.1\%$. כעת שכפלנו את הווקטורים החיוביים (כלומר יש לנו כעת 1000 ווקטורים חיוביים, כל ווקטור חיובי מופיע פעמיים).

6. אחוז ה-TP וה-FP ישאר כפי שהיה לפני השינוי
7. אחוז ה-TP יגדל לאחר השינוי
8. אחוז ה-FP יקטן לאחר השינוי
9. אחוז ה-TP יגדל וה-FP יקטן לאחר השינוי
10. אחוז ה-TP יקטן וה-FP יגדל לאחר השינוי

שאלה 7:

אלגוריתם SVM – "מקדם הענישה" C עבור soft-margin:

1. מגדיר עבור המקרה בו אין פתרון לינארי את "מחיר הטעות". מחושב ע"י סכום מרחקי הטעויות מה-hyperplane המתאים.
2. מגדיר עבור המקרה בו אין פתרון לינארי את "מחיר הטעות". מחושב ע"י מס' הווקטורים בהם אנו טועים.
3. לא משפיע על ה-hyperplane שיוצר
4. לא ניתן לפתור באמצעות אלגוריתם SVM מקרה לא לינארי.
5. אף תשובה אינה נכונה


שאלה 8:

אלגוריתמים היררכיים לביצוע "אישכול" (clustering)

1. קושי הוא להגדיר תנאי עצירה בבניית ההיררכיה
2. תנאי העצירה מוגדר היטב באלגוריתם
3. קלט לאלגוריתם הינו מס' ה"אשכולות" הקיימים
4. הינם אלגוריתם supervised
5. אף תשובה אינה נכונה

שאלה 9:

נתונה רשת הנורונים הבאה. פונקציית האקטיבציה בשכבות הביניים ובשכבת היציאה הינה SGN עם ערך סף 0 (כלומר אם גדול/שווה ל-0 הערך הוא 1, אחרת 0). ערכי המשקולות מופיעים בשרטוט. אלו מהווקטורים הבאים יסווג כ"חיובי"



1. כל התשובות נכונות
2. $(x1=1, x2=2, x3=3)$
3. $(x1=4, x2=3, x3=2)$
4. $(x1=2, x2=2, x3=1)$
5. $(x1=4, x2=3, x3=4)$

שאלה 10:

נאמר על Learner שהוא PAC (Probably Approximately Correct)

1. אם בהסתברות גבוהה (לפחות $1-\delta$), מייצר לנו אלגוריתם שמובטח שטעותו קטנה מ- ϵ . האלגוריתם מיוצר בזמן חסום פולינומיאלי ע"י מס' פרמטרים.
2. אם בהסתברות גבוהה (לפחות $1-\delta$), מייצר לנו אלגוריתם שמובטח שטעותו גדולה מ- ϵ . האלגוריתם מיוצר בזמן חסום פולינומיאלי ע"י מס' פרמטרים.
3. אם מייצר לנו טעות 0 על קבוצת האימון
4. אם מייצר לנו טעות 0 על קבוצת המבחן
5. כל התשובות נכונות

שאלה 11:

נתונה טבלת האימון הבאה:

X1	X2	X3	X4	class
1	2	1	1	P
1	2	2	1	P
1	1	2	2	N
1	1	1	1	N

נדרש לסווג עם אלגוריתם Naïve-Bayes. המשתנים x_1, x_2, x_3, x_4 הינם בלתי תלויים זה בזה. כיצד יסווג הווקטור $v=(x_1=1, x_2=2, x_3=2, x_4=1)$ עפ"י האלגוריתם? אין להשתמש ב"החלקה" גם אם נדרש.

1. P
2. N
3. הסתברות זהה לשניהם
4. אף תשובה אינה נכונה
5. לא ניתן לחשב

שאלה 12:

נתונים לנו 100 ווקטורים כקבוצת אימון. ע"מ לבצע תהליך boosting מציע יענקלה לייצר מס' אלגוריתמי למידה שונים בצורה הבאה: לסדר את הווקטורים בסדר שונה בכל פעם, כך n פעמים, עבור כל סידור של הווקטורים לייצר אלגוריתם למידה שונה ואז עבור ווקטור חדש להכריע בהצבעת רוב בין n המסווגים שנוצרו. איזה אלגוריתם מהאלגוריתמים הבאים עשוי להיות רגיש לסדר של הווקטורים:

1. פרספטרון במוד incremental
2. SVM
3. עץ החלטה ID3
4. KNN
5. Naïve Bayes