



המסלול האקדמי המכללה למינהל בית הספר "מדעי המחשב"

ת.ז. הסטודנט: _____

מס' חדר: _____ מס' נבחן: _____

מבחן בקורס "למידה חישובית וכריית נתונים"

תאריך הבחינה: 25/08/2013 שעה- 09:00

שנה"ל: תשע"ג, סמסטר: ב', מועד: ב'

שם המרצה/ים: ד"ר משה בוטמן

שם המתרגל/ים:

משך הבחינה: 2.5 שעות

מספר חלקים בבחינה: 2

הוראות לנבחן:

- חלק א: 2 שאלות פתוחות, משקל כל שאלה בצמוד לשאלה.
- יש לענות במחברת בחינה וגוף השאלון.
- חלק ב: 12 שאלות רב ברירה יש לענות על כל השאלות.
- משקל כל שאלה: 5 נקודות
- הבחינה: ללא חומר עזר!
- שימוש במחשבון כיס/פיננסי: לא
- מחברת טיוטה: כן
- יש לבחור את התשובה הנכונה ביותר ולסמן את התשובה בדף הקידוד.
- יש לסמן את התשובה בדף הקידוד בעט שחור או כחול בלבד באופן ברור ומודגש.
- רק דף הקידוד ייבדק!
- יש להחזיר את טופס השאלון!
- אין לסמן את התשובות על גבי השאלון בטוש זוהר (מרקר)!

*** חשוב מאוד:

בדף הקידוד יש לרשום ולקדד את מספר השאלון מוצמד לימין (להוסיף אפסים משמאל).
יש לרשום את מס' תעודת הזהות במקום המיועד בכתב יד ברור (כולל ספרת הביקורת).

בהצלחה !!!

חלק א': שאלות פתוחות

שאלה 1 (20 נקודות):

נתונה בעיית למידה - בהינתן המאפיינים feature1, feature2, feature3 יש צורך לחזות את class.

נתונה קבוצת האימון הבאה:

#	feature1	feature2	feature3	class
1	1	1	0	P
2	1	0	1	P
3	1	0	0	N
4	0	1	1	N

- א. (7 נקודות) סווג את הווקטור $(1,1,1)$ עפ"י KNN עבור $k=1$, מטריקת מרחק $L1$, משקול מרחקים של $1/d^2$, ללא משקול מאפיינים.
- ב. (6 נקודות) סווג את הווקטור $(1,1,1)$ עפ"י אלגוריתם Naïve-Bayes.
- ג. (7 נקודות) הרצנו את בעיית האופטימיזציה של אלגוריתם SVM עם קרנל פולינומיאלי (לא לינארי) והפתרון שקיבלנו הוא:

$$\alpha_1 = 7, \alpha_2 = 7, \alpha_3 = 11, \alpha_4 = 3, b = 1.3$$

(הערה: הערכים הינם קירובים של התוצאה האמיתית וזאת כדי להקל על החישובים)

פונקצית הסיווג הינה:

$$\text{sgn}(\sum_i \alpha_i y_i K(x_i, x) - b)$$

משוואת הקרנל:

$$K(x \cdot y) = \left(\frac{1}{3} x \cdot y\right)^2$$

כיצד יסווג הווקטור $(1,1,1)$

שאלה 2 (20 נקודות):

נתונה קבוצת הווקטורים הבאה (בעיה חד-מימדית מאפיין בודד f_1)

	Vector #1	Vector #2	Vector #3	Vector #4	Vector #5	Vector #6	Vector #7	Vector #8	Vector #9
f_1	1	2	4	7	19	18	30	11	64

א. (8 נקודות) הרץ בפירוט אלגוריתם אישכול היררכי bottom-up (מרחק אוקלידי).

מרחק בין ווקטור לאשכול מוגדר כמרחק לווקטור הקרוב ביותר באשכול.

הרץ את האלגוריתם 4 איטרציות.

כמה אשכולות נוצרו? לאיזה אשכול שייך כל ווקטור?


ב. (6 נקודות) הצע מדד לעצירת אלגוריתם האישכול ההיררכי?

ג. (6 נקודות) עבור הדוגמא הדו-מימדית הבאה, הראה את תוצאת אלגוריתם k-means, כלומר הראה

את מרכזי האשכולות שיוצרו. אם יש יותר מאפשרות אחת הצג/תאר זאת. אנו מניחים שהאלגוריתם

התחיל מבחירה אקראית של ווקטורים "אמיתיים", כלומר ווקטורים שקיימים בקבוצת האימון.

הראה את התוצאה עבור $k=2$



התפלגות אחידה של הווקטורים בשני מעגלים ברדיוס r .

1. אילו מהאמירות הבאות היא הנכונה ביותר

1. פרספטון מאפשר גם הפרדה לינארית וגם הפרדה לא לינארית, לא מובטחת לנו יכולת הכללה כמו ב-SVM, מובטחת לנו התכנסות של האלגוריתם לאחר מס' צעדים סופי כאשר ידוע שישנה הפרדה לינארית.
2. פרספטון מאפשר הפרדה לינארית בלבד, לא מובטחת לנו יכולת הכללה כמו ב-SVM, מובטחת לנו התכנסות של האלגוריתם לאחר מס' צעדים סופי כאשר ידוע שישנה הפרדה לינארית.
3. פרספטון מאפשר גם הפרדה לינארית וגם הפרדה לא לינארית, מובטחת לנו יכולת הכללה טובה מאשר ב-SVM, מובטחת לנו התכנסות של האלגוריתם לאחר מס' צעדים סופי כאשר ידוע שישנה הפרדה לינארית.
4. פרספטון מאפשר הפרדה לינארית בלבד, לא מובטחת לנו יכולת הכללה כמו ב-SVM, תמיד מובטח לנו התכנסות של האלגוריתם לאחר מס' צעדים סופי.
5. פרספטון מאפשר הפרדה לינארית בלבד, מובטחת לנו יכולת הכללה טובה יותר מאשר ב-SVM, מובטחת לנו התכנסות של האלגוריתם לאחר מס' צעדים סופי כאשר ידוע שישנה הפרדה לינארית.

2. נתונה טבלת האימון הבאה:

X1	X2	X3	X4	Class
1	1	1	1	P
1	1	0	0	P
0	0	1	0	N
0	0	0	0	N

חשב את $IG(class|x2)$

1. 0.25
2. 1
3. לא ניתן לחשב
4. 0
5. 0.75

3. החלטנו לבנות מע' בקרת כניסה למשרד. יש לנו 16 עובדים במשרד ואנו רוצים לבנות מע' זיהוי פנים (Face Recognition) כך שבהינתן תמונת פנים המערכת תסווגה לאחד מ-16 "מחלקות" (כל עובד = "מחלקה"). בשלב אימון מערכת הלמידה הזנו מס' זהה של דוגמאות (תמונות) עבור כל עובד. מהי האנדרופיה של "מחלקה"?

1. 2
2. 4
3. 0
4. 3
5. 1

4. נתונים לנו 100 ווקטורים כקבוצת אימון. ע"מ לבצע תהליך boosting מציע יענקלה לייצר מס' אלגוריתמי למידה שונים בצורה הבאה: לשכפל את קבוצת האימון (כלומר יש לנו 200 ווקטורים) לסדר את 200 הווקטורים באופן אקראי ולייצר אלגוריתם למידה חדש, בפעם הראשונה פעם אחת, בפעם השנייה לשכפל שתי פעמים (כעת יש לנו 300 ווקטורים) ולסדר באופן אקראי, כך ה פעמים, עבור כל קבוצה לייצר אלגוריתם למידה. עבור איזה מהאלגוריתמים הבאים עשוי להתקבל אלגוריתם למידה שונה עבור כל "שכפול"

1. KNN
2. SVM
3. פרספטון במוד incremental
4. עץ החלטה ID3
5. Naïve Bayes

5. נתונים לנו שני אלגוריתמים לזיהוי וסיווג מוסיקת ג'ז. בחנו את המערכת על קבוצת מבחן של קבצי מוסיקה. עבור האלגוריתם הראשון קיבלנו ש- $FP = 2$, $TP = 80$, $\%TP = 90$, $\%FP = 10$. איזה מהאלגוריתמים טוב יותר?

1. תלוי ב-confusion matrix של כל אלגוריתם
2. האלגוריתם הראשון כי ה-TP שלו גבוה יותר
3. נבחן את מדדי עקומת ה-ROC של כל אלגוריתם כדי להחליט
4. האלגוריתם השני כי ה-FP שלו נמוך יותר
5. האלגוריתם הראשון כי סכום ה-TP שלו וה-FP שלו נמוכים יותר

6. פתרנו את בעיית האופטימיזציה של אלגוריתם SVM עם קרנל לינארי, חישבנו את $W=(1,1,1)$ וקיבלנו $b=-2$. משוואת הסיווג של SVM: $f(\text{vector})=W \cdot \text{vector}^T + b$. איזה מהבאים בוודאות נכון:

1. הווקטור $(f_1=1, f_2=1, f_3=1)$ אינו Support Vector
2. אף תשובה אינה נכונה
3. הווקטור $(f_1=1, f_2=1, f_3=1)$ הינו Support Vector וערכו הוא N.
4. הווקטור $(f_1=1, f_2=1, f_3=1)$ הינו Support Vector וערכו הוא P.
5. הווקטור $(f_1=0, f_2=0, f_3=0)$ הינו Support Vector וערכו הוא P.


7. נתונה טבלת האימון הבאה:

X1	X2	X3	X4	class
1	2	1	2	1
1	2	2	1	1
1	2	2	2	-1
1	1	1	1	-1

נדרש לסווג עם אלגוריתם Naïve-Bayes. המשתנים x_1, x_2, x_3, x_4 הינם בלתי תלויים זה בזה. רוצים לסווג את הווקטור $v=(x_1=1, x_2=2, x_3=2, x_4=2)$ עפ"י האלגוריתם שלמדנו:

1. $P(\text{class}=1|v) = 2 \times P(\text{class}=-1|v)$
2. לא ניתן לחשב
3. $P(\text{class}=1|v) = 0.5 \times P(\text{class}=-1|v)$
4. $P(\text{class}=1|v) = 0.75 \times P(\text{class}=-1|v)$
5. $P(\text{class}=1|v) = P(\text{class}=-1|v)$

8. נתונה לנו רשת הניורונים הבאה:



משקל הקשתות מצויין בשרטוט. פונקציית האקטיבציה בשכבת הביניים ובשכבת היציאה הינה SGN עם ערך סף 0. מה יהיה הפלט של הרשת עבור הווקטור ($x_1 = 1, x_2 = 2, x_3 = 1$)

1. "Out1 = "POS", out2 = "NEG"
2. לא ניתן לחשב
3. "Out1 = "POS", out2 = "POS"
4. "Out1 = "NEG", out2 = "NEG"
5. "Out1 = "NEG", out2 = "POS"

9. אלגוריתם KNN (K-Nearest-Neighbors)

1. מתאים למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, מאפשר הפרדה לא לינארית, אינו מתאים לבעיית multi-class
2. מתאים למימוש באופן מקבילי בזמן סיווג נקודה חדשה, אינו צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, מאפשר הפרדה לא לינארית, אינו מתאים לבעיית multi-class
3. אינו מתאים למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יעיל, מאפשר הפרדה לא לינארית, מתאים לבעיית multi-class
4. מתאים למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, אינו מאפשר הפרדה לא לינארית, מתאים לבעיית multi-class
5. מתאים למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, מאפשר הפרדה לא לינארית, מתאים לבעיית multi-class

10. פתרון בעיה לא לינארית באמצעות אלגוריתם SVM – מבצעים "מיפוי" של הווקטורים למימד גבוה כי :

1. לא ניתן לפתור בעיה לא לינארית באמצעות SVM
2. כל התשובות נכונות
3. אם אין הפרדה לינארית במימד הנמוך, לא תהיה הפרדה לינארית גם במימד גבוה יותר
4. ב-SVM מבצעים מיפוי רק למימד נמוך יותר
5. במימד הגבוה אולי יש הפרדה לינארית

11. באלגוריתם DBSCAN לביצוע "אישכול" אנו מגדירים כקלט לאלגוריתם את r ואת $\minPts$. אלו מבין הבאים יביא ככל הנראה למס' האשכולות גדול יותר?

1. ככל ש- $\minPts$ קטן, ו- r קטן.
2. ככל ש- $\minPts$ גדל, ו- r קטן.
3. ככל ש- $\minPts$ גדל, ו- r גדל.
4. מס' האשכולות שיווצרו הינו תמיד קבוע ללא קשר לגודלם של $\minPts$ ושל r .
5. ככל ש- $\minPts$ קטן, ו- r גדל.

12. WEKA הינה:

1. מודל לא לינארי ללמידה בלתי מונחית
 2. אף תשובה אינה נכונה
 3. מודל לינארי ללמידה מונחית
 4. תכנה המאפשרת בחינה והשוואה של אלגוריתמי למידה שונים
 5. אלגוריתם למידה דיסקרימינטיבי
-