

שאלה 1:

נתונים לנו שני אלגוריתמים לזיהוי וסיווג מוסיקת ג'ז. בחנו את המערכת על קבוצת מבחן של קבצי מוסיקה. עבור האלגוריתם הראשון קיבלנו ש- $TP = 80\%$, $FP = 2\%$ ועבור האלגוריתם השני קיבלנו ש- $TP = 90\%$, $FP = 10\%$. איזה מהאלגוריתמים טוב יותר?

1. נבחן את מדדי עקומת ה-ROC של כל אלגוריתם כדי להחליט
2. האלגוריתם הראשון כי ה-TP שלו גבוה יותר
3. האלגוריתם השני כי ה-FP שלו נמוך יותר
4. תלוי ב-confusion matrix של כל אלגוריתם
5. האלגוריתם הראשון כי סכום ה-TP שלו וה-FP שלו נמוכים יותר

שאלה 2:

החלטנו לבנות מע' בקרת כניסה למשרד. יש לנו 16 עובדים במשרד ואנו רוצים לבנות מע' זיהוי פנים (Face Recognition) כך שבהינתן תמונת פנים המערכת תסווגה לאחד מ-16 "מחלקות" (כל עובד = "מחלקה"). בשלב אימון מערכת הלמידה הזנו מס' זהה של דוגמאות (תמונות) עבור כל עובד. מהי האנתרופיה של "מחלקה"?

1. 4
2. 3
3. 2
4. 1
5. 0

שאלה 3:

אלגוריתם KNN (K-Nearest-Neighbors)

1. מתאים למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, מאפשר הפרדה לא לינארית, מתאים לבעיית multi-class
2. אינו מתאים למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יעיל, מאפשר הפרדה לא לינארית, מתאים לבעיית multi-class
3. מתאים למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, אינו מאפשר הפרדה לא לינארית, מתאים לבעיית multi-class
4. מתאים למימוש באופן מקבילי בזמן סיווג נקודה חדשה, צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, מאפשר הפרדה לא לינארית, אינו מתאים לבעיית multi-class
5. מתאים למימוש באופן מקבילי בזמן סיווג נקודה חדשה, אינו צורך מקום רב בזכרון בזמן ריצה, זמן ריצה יקר, מאפשר הפרדה לא לינארית, אינו מתאים לבעיית multi-class


שאלה 4:

WEKA הינה:

1. תכנה המאפשרת בחינה והשוואה של אלגוריתמי למידה שונים
2. אלגוריתם למידה דיסקרימינטיבי
3. מודל לא לינארי ללמידה בלתי מונחית
4. מודל לינארי ללמידה מונחית
5. אף תשובה אינה נכונה

שאלה 5:

נתונה לנו רשת הנורונים הבאה:



משקל הקשתות מצויין בשרטוט. פונקציית האקטיבציה בשכבת הביניים ובשכבת היציאה הינה SGN עם ערך סף 0. מה יהיה הפלט של הרשת עבור הווקטור $(x1 = 1, x2 = 2, x3 = 1)$

1. Out1 = "POS", out2 = "NEG"
2. Out1 = "POS", out2 = "POS"
3. Out1 = "NEG", out2 = "POS"
4. Out1 = "NEG", out2 = "NEG"
5. לא ניתן לחשב

שאלה 6:

נתונה טבלת האימון הבאה:

X1	X2	X3	X4	Class
1	1	1	1	P
1	1	0	0	P
0	0	1	0	N
0	0	0	0	N

חשב את $IG(class|x2)$

1. 1
2. 0
3. 0.25
4. 0.75
5. לא ניתן לחשב

שאלה 7:

פתרנו את בעיית האופטימיזציה של אלגוריתם SVM עם קרנל לינארי, חישבנו את W וקיבלנו $W=(1,1,1)$ ו $b=-2$. משוואת הסיווג של SVM: $f(\text{vector})=W \cdot \text{vector}^T + b$. איזה מהבאים בוודאות נכון:

1. הווקטור $(f_1=1, f_2=1, f_3=1)$ הינו Support Vector, וערכו הוא P .
2. הווקטור $(f_1=1, f_2=1, f_3=1)$ הינו Support Vector, וערכו הוא N .
3. הווקטור $(f_1=1, f_2=1, f_3=1)$ אינו Support Vector.
4. הווקטור $(f_1=0, f_2=0, f_3=0)$ הינו Support Vector, וערכו הוא P .
5. אף תשובה אינה נכונה.

שאלה 8:

פתרון בעיה לא לינארית באמצעות אלגוריתם SVM – מבצעים "מיפוי" של הווקטורים למימד גבוה כי :

1. במימד הגבוה אולי יש הפרדה לינארית
2. אם אין הפרדה לינארית במימד הנמוך, לא תהיה הפרדה לינארית גם במימד גבוה יותר
3. ב-SVM מבצעים מיפוי רק למימד נמוך יותר
4. לא ניתן לפתור בעיה לא לינארית באמצעות SVM
5. כל התשובות נכונות

שאלה 9:

באלגוריתם DBSCAN לביצוע "אישכול" אנו מגדירים כקלט לאלגוריתם את r ואת minPts . אלו מבין הבאים יביא ככל הנראה למס' האשכולות גדול יותר?

1. ככל ש- minPts גדל, ו- r קטן.
2. ככל ש- minPts קטן, ו- r גדל.
3. ככל ש- minPts קטן, ו- r קטן.
4. ככל ש- minPts גדל, ו- r גדל.
5. מס' האשכולות שיווצרו הינו תמיד קבוע ללא קשר לגודלם של minPts ושל r .

שאלה 10:

אילו מהאמירות הבאות היא הנכונה ביותר

1. פרספטרון מאפשר הפרדה לינארית בלבד, לא מובטחת לנו יכולת הכללה כמו ב-SVM, מובטחת לנו התכנסות של האלגוריתם לאחר מס' צעדים סופי כאשר ידוע שישנה הפרדה לינארית
2. פרספטרון מאפשר הפרדה לינארית בלבד, לא מובטחת לנו יכולת הכללה כמו ב-SVM, תמיד מובטח לנו התכנסות של האלגוריתם לאחר מס' צעדים סופי.
3. פרספטרון מאפשר הפרדה לינארית בלבד, מובטחת לנו יכולת הכללה טובה יותר מאשר ב-SVM, מובטחת לנו התכנסות של האלגוריתם לאחר מס' צעדים סופי כאשר ידוע שישנה הפרדה לינארית.
4. פרספטרון מאפשר גם הפרדה לינארית וגם הפרדה לא לינארית, לא מובטחת לנו יכולת הכללה כמו ב-SVM, מובטחת לנו התכנסות של האלגוריתם לאחר מס' צעדים סופי כאשר ידוע שישנה הפרדה לינארית.
5. פרספטרון מאפשר גם הפרדה לינארית וגם הפרדה לא לינארית, מובטחת לנו יכולת הכללה טובה מאשר ב-SVM, מובטחת לנו התכנסות של האלגוריתם לאחר מס' צעדים סופי כאשר ידוע שישנה הפרדה לינארית.

שאלה 11:

נתונים לנו 100 ווקטורים כקבוצת אימון. ע"מ לבצע תהליך boosting מציע יענקלה לייצר מס' אלגוריתמי למידה שונים בצורה הבאה: לשכפל את קבוצת האימון (כלומר יש לנו 200 ווקטורים) לסדר את 200 הווקטורים באופן אקראי ולייצר אלגוריתם למידה חדש, בפעם הראשונה פעם אחת, בפעם השנייה לשכפל שתי פעמים (כעת יש לנו 300 ווקטורים) ולסדר באופן אקראי, כך n פעמים, עבור כל קבוצה לייצר אלגוריתם למידה. עבור איזה מהאלגוריתמים הבאים עשוי להתקבל אלגוריתם למידה שונה עבור כל "שכפול"

1. פרספטרון במוד incremental

2. SVM

3. עץ החלטה ID3

4. KNN

5. Naïve Bayes

שאלה 12:

נתונה טבלת האימון הבאה:

X1	X2	X3	X4	class
1	2	1	2	1
1	2	2	1	1
1	2	2	2	-1
1	1	1	1	-1

נדרש לסווג עם אלגוריתם Naïve-Bayes. המשתנים x_1, x_2, x_3, x_4 הינם בלתי תלויים זה בזה. רוצים לסווג את הווקטור $v=(x_1=1, x_2=2, x_3=2, x_4=2)$ עפ"י האלגוריתם שלמדנו:

6. $P(\text{class}=1 | v) = 2 \times P(\text{class}=-1 | v)$

7. $P(\text{class}=1 | v) = 0.5 \times P(\text{class}=-1 | v)$

8. $P(\text{class}=1 | v) = P(\text{class}=-1 | v)$

9. $P(\text{class}=1 | v) = 0.75 \times P(\text{class}=-1 | v)$

10. לא ניתן לחשב

שאלה 1 (20 נקודות):

נתונה בעיית למידה - בהינתן המאפיינים feature1, feature2, feature3 יש צורך לחזות את class.

נתונה קבוצת האימון הבאה:

#	feature1	feature2	feature3	class
1	1	1	0	P
2	1	0	1	P
3	1	0	0	N
4	0	1	1	N

א. (7 נקודות) סווג את הווקטור (1,1,1) עפ"י KNN עבור $k=1$, מטריקת מרחק L1, משקול מרחקים של $1/d^2$, ללא משקול מאפיינים.

פתרון:

#	feature1	feature2	feature3	class	מרחק מ-(1,1,1)
1	1	1	0	P	$ 1-1 + 1-1 + 1-0 = 1$
2	1	0	1	P	$ 1-1 + 0-1 + 1-1 = 1$
3	1	0	0	N	$ 1-1 + 1-0 + 1-0 = 2$
4	0	1	1	N	$ 1-0 + 1-1 + 1-1 = 1$

יש לנו שלושה ווקטורים במרחק של 1, אין משמעות לשקלול מרחקים. מכיוון ששניים אומרים P ואחד N נסווג כ-P.

ב. (6 נקודות) סווג את הווקטור (1,1,1) עפ"י אלגוריתם Naïve-Bayes

נבדוק האם ההסתברות ל-P גדולה או קטנה מההסתברות ל-N

מניחים שהווקטורים בלתי תלויים

$$P(P | x_1=1, x_2=1, x_3=1) = \frac{P(x_1=1, x_2=1, x_3=1 | P)P(P)}{P(x_1=1, x_2=1, x_3=1)}$$

$$P(N | x_1=1, x_2=1, x_3=1) = \frac{P(x_1=1, x_2=1, x_3=1 | N)P(N)}{P(x_1=1, x_2=1, x_3=1)}$$

המכנה זהה ולכן לא "מעניין". $P(P)=P(N)$ ולכן גם לא "מעניין"

$$P(x_1=1, x_2=1, x_3=1 | P) = P(x_1=1 | P) \times P(x_2=1 | P) \times P(x_3=1 | P) = 1 \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{4}$$

$$P(x_1=1, x_2=1, x_3=1 | N) = P(x_1=1 | N) \times P(x_2=1 | N) \times P(x_3=1 | N) = \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{8}$$

ההסתברות לקבלת P גדולה מההסתברות לקבלת N, ולכן נסווג כ-P

ג. (7 נקודות) הרצנו את בעיית האופטימיזציה של אלגוריתם SVM עם קרנל פולינומיאלי (לא לינארי) והפתרון שקיבלנו הוא:

$$\alpha_1 = 7, \alpha_2 = 7, \alpha_3 = 11, \alpha_4 = 3, b = 1.3$$

(הערה: הערכים הינם קירובים של התוצאה האמיתית וזאת כדי להקל על החישובים)

פונקצית הסיווג הינה:

$$\text{sgn}(\sum_i \alpha_i y_i K(x_i, x) - b)$$

משוואת הקרנל:

$$K(x \cdot y) = \left(\frac{1}{3} x \cdot y\right)^2$$

כיצד יסווג הווקטור (1,1,1)

פתרון:

$$\begin{aligned} & \text{sgn}(7 \times 1 \times K((1,1,0)(1,1,1)) + 7 \times 1 \times K((1,0,1)(1,1,1)) + 11 \times -1 \times K((1,0,0)(1,1,1)) + 3 \times -1 \times K((0,1,1)(1,1,1)) - 1.3 = \\ & \text{sgn}(7 \times \frac{(1,1,0)(1,1,1)^T}{9} + 7 \times \frac{(1,0,1)(1,1,1)^T}{9} - 11 \times \frac{(1,0,0)(1,1,1)^T}{9} - 3 \times \frac{(0,1,1)(1,1,1)^T}{9} - 1.3) = \\ & \text{sgn}(7 \times \frac{4}{9} + 7 \times \frac{4}{9} - 11 \times \frac{1}{9} - 3 \times \frac{4}{9} - 1.3) = \text{sgn}(\frac{28+28-11-12}{9} - 1.3) = \text{sgn}(\frac{33}{9} - 1.3) > 0 \end{aligned}$$

לכן יסווג כחיובי.

שאלה 2 (20 נקודות):

נתונה קבוצת הווקטורים הבאה (בעיה חד-מימדית מאפיין בודד f_1)

	Vector #1	Vector #2	Vector #3	Vector #4	Vector #5	Vector #6	Vector #7	Vector #8	Vector #9
f_1	1	2	4	7	19	18	30	11	64

א. (8 נקודות) הרץ בפירוט אלגוריתם אישכול היררכי bottom-up (מרחק אוקלידי).

מרחק בין ווקטור לאשכול מוגדר כמרחק לווקטור הקרוב ביותר באשכול.

הרץ את האלגוריתם 4 איטרציות.

כמה אשכולות נוצרו? לאיזה אשכול שייך כל ווקטור?

איטרציה 1: נאחד את ווקטורים #1, #2 מכיוון שהמרחק ביניהם הוא הקטן ביותר (כמובן אפשר גם לבחור את #5, #6).

8 אשכולות: (#1, #2), (#3), (#4), (#5), (#6), (#7), (#8), (#9)

איטרציה 2: נאחד את ווקטורים #5, #6

7 אשכולות: (#1, #2), (#3), (#4), (#5, #6), (#7), (#8), (#9)

איטרציה 3: נאחד את ווקטור #3, לאשכול של (#1, #2)

6 אשכולות: (#1, #2, #3), (#4), (#5, #6), (#7), (#8), (#9)

איטרציה 4: נאחד את ווקטור #4, לאשכול של (#1, #2, #3)


5 אשכולות: (#1, #2, #3, #4), (#5, #6), (#7), (#8), (#9)

ב. (6 נקודות) הצע מדד לעצירת אלגוריתם האישכול ההיררכי?

פתרון: מדד אפשרי לעצירת האלגוריתם – כאשר המרחק בין אשכול לאשכול הקרוב ביותר גדול מסף מסויים. (זה אומר כמובן שאנו לא נרצה לאחד אשכולות אלו והאלגוריתם יעצור)

ג. (6 נקודות) עבור הדוגמא הדו-מימדית הבאה, הראה את תוצאת אלגוריתם k-means, כלומר הראה את מרכזי האשכולות שיוצרו. אם יש יותר מאפשרות אחת הצג/תאר זאת. אנו מניחים שהאלגוריתם התחיל מבחירה אקראית של ווקטורים "אמיתיים", כלומר ווקטורים שקיימים בקבוצת האימון.

הראה את התוצאה עבור $k=2$



התפלגות אחידה של הווקטורים בשני מעגלים ברדיוס r .

פתרון: עבור $k=2$

