



המסלול האקדמי המכללה למינהל בית הספר "מדעי המחשב"

ת.ז. הסטודנט: _____

מס' חדר: _____ מס' נבחן: _____

מבחן בקורס "למידה חישובית וכריית נתונים"

תאריך הבחינה: 02/10/2013 שעה - 16:00

שנה"ל: תשע"ג, סמסטר: קיץ, מועד: א'

שם המרצה/ים: ד"ר משה בוטמן

שם המתרגל/ים:

משך הבחינה: 2.5 שעות

מספר חלקים בבחינה: 2

הוראות לנבחן:

- הבחינה מורכבת משני חלקים:

- חלק א: 2 שאלות פתוחות, משקל כל שאלה: בצמוד לשאלה.
- חלק ב: 12 שאלות רב ברירה. משקל כל שאלה 5 נקודות.
- יש לענות על כל השאלות.
- הבחינה: ללא חומר עזר!
- שימוש במחשבון כיס/פיננסי: לא
- מחברת טיוטה: כן
- יש לבחור את התשובה הנכונה ביותר ולסמן את התשובה בדף הקידוד.
- יש לסמן את התשובה בדף הקידוד בעט שחור או כחול בלבד באופן ברור ומודגש.
- רק דף הקידוד ייבדק!
- יש להחזיר את טופס השאלון!
- אין לסמן את התשובות על גבי השאלון בטוש זוהר (מרקר)!

*** חשוב מאוד:

בדף הקידוד יש לרשום ולקדד את מספר השאלון מוצמד לימין (להוסיף אפסים משמאל).
יש לרשום את מס' תעודת הזהות במקום המיועד בכתב יד ברור (כולל ספרת הביקורת).

בהצלחה !!!

חלק א: 2 שאלות פתוחות

שאלה 1 (20 נקודות):

נניח שאנו רוצים לסווג עבור מערכת בנקאית את הלקחות שלנו ל"לקוחות שכדאי לתת להם אשראי" (לקוח "חיובי") וללקוחות שלא כדאי לתת להם אשראי (לקוח "שלילי") קבוצת האימון שלנו מכילה נתונים היסטוריים על לקוחות רבים ומכילה את המאפיינים הבאים עבור כל לקוח:

גיל – 4 קבוצות גיל שונות ("0" - קטן מ-30, "1" - 31-40, "2" - 41-50, "3" - 51-60, "4" - גדול מ-60)

גובה שכר – 3 קבוצות ("0" - נמוך, "1" - בינוני, "2" - גבוה)

מין – "0" - זכר/"1" - נקבה

מצב משפחתי – "0" - רווק/"1" - נשוי/"2" - גרוש

א. (6 נקודות)

נדרש לתת תכן (ארכיטקטורה) לרשת נוירונים המתאימה לבעיה. הנחת העבודה שלנו היא שהבעיה איננה ניתנת להפרדה לינארית. שרטט סכמטית רשת נוירונים המתאימה לפתרון הבעיה. הסבר כל שיקול שהפעלת בשרטוט הרשת. יש להתייחס כמובן למס' הנוירונים בשכבת הכניסה, בשכבת היציאה ועוד.

ב. (8 נקודות)

נתונה טבלת האימון הבאה

#	גיל	גובה שכר	מין	מצב משפחתי	class
1	0	2	0	1	P
2	1	0	1	1	P
3	1	0	0	0	P
4	0	1	1	1	P
5	0	1	1	2	N
6	2	1	1	0	N
7	1	2	0	1	N
8	1	2	0	1	N

סווג עפ"י אלגוריתם Naïve Bayes את הדוגמא: (גיל קטן מ-30, גובה שכר בינוני, זכר, רווק)

ג. (6 נקודות)

הרצנו את אלגוריתם SVM על קבוצת מבחן וקיבלנו את תוצאת האלגוריתם (לפני הפעלת ערך הסף לקביעה סופית). נתון לנו כמובן גם הסיווג האמיתי של כל דוגמא. שרטט את גרף ה-ROC

#	Algorithm Result	Real Class
1	4	P
2	1	P
3	8	P
4	-3	P
5	7	N
6	-7	N
7	-17	N
8	-8	N

שאלה 2 (20 נקודות):

בעיית אישכול – נתונים לנו 5 ווקטורים. נתונה לנו טבלת "דמיון" בין הווקטורים (כלומר ככל שערך הדמיון גבוה יותר, הווקטורים "דומים" יותר זה לזה):

	V1	V2	V3	V4	V5
V1	1	0	0.2	0.5	0.1
V2		1	0.6	0.4	0.9
V3			1	0.3	0.8
V4				1	0.7
V5					1

א. (7 נקודות)

הרץ אלגוריתם אישכול היררכי bottom-up במלואו. רשום בכל איטרציה את מס' האשכולות שנוצרו, איזה ווקטורים בכל אשכול, והסבר בפירוט את צעדיך. נגדיר "דמיון" בין אשכול א' לאשכול ב' כדמיון המקסימאלי הקיים בין ווקטור כלשהו מאשכול א' לווקטור כלשהו מאשכול ב'.

ב. (7 נקודות)

הצע מדד לעצירת האלגוריתם ההיררכי. כמה אשכולות נוצרו עם הפעלת המדד שהצעת?

ג. (6 נקודות)

כחישוב מרחק בין ווקטורים מוצעת מטריקת המרחק הבאה:

$$d(a,b) = \sin(\text{EUCLIDEAN}(a,b))$$

כלומר חישוב סינוס על המרחק האוקלידי בין הנקודות. למשל עבור 2D נניח נקודה $a=(1,1)$ ונקודה $b=(4,5)$. המרחק האוקלידי ביניהם הוא 5. עפ"י הגדרת המטריקה $d(a,b) = \sin(5)=0.087$. האם זוהי מטריקת מרחק "חוקית"? הוכח או הפרך

1. בעיית Associations rules הינה בעיה מסוג:

1. Regression
2. Unsupervised
3. Clustering
4. Supervised
5. Classification

2. "עץ החלטה" –באלגוריתם "עץ החלטה" (ID3) חישובנו את ה-infogain של כל התכונות. ניסינו לפצל צומת וקיבלנו שה-infogain של כל התכונות הוא 0

1. אף תשובה אינה נכונה
2. לא יכול לצאת לכל התכונות infogain של 0
3. נפסיק את בניית העץ ונהפוך את הצומת ל"עלה"
4. זו לא סיבה להפסיק בבניית העץ
5. נחזור רמה אחת בעץ ונחליף את התכונה שנבחרה שם

3. פתרנו את בעיית האופטימיזציה של אלגוריתם SVM עם קרנל לינארי, חישובנו את W וקיבלנו $W=(1,0,0)$. נתונים לנו גם ה-Support Vectors והסיווג שלהם בטבלה הבאה. מהו b של משוואת הסיווג של SVM: $f(\text{vector})=W \cdot \text{vector}^T + b$

X1	X2	X3	Class
1	1	0	P
1	0	1	P
-1	0	0	N

1. 2
2. 1
3. -1
4. 0
5. -2

4. למדנו שכדי לפתור בעיית multi-class מספיק לדעת כיצד פותרים בעייה בינארי וזאת ע"י יצירת מספר בעיות למידה בינאריות. הזכרנו שתי שיטות: One vs. One (שיטה א') או One vs. All (שיטה ב').

1. לסיווג ווקטור חדש בשיטה ב' נדרשות יותר השוואות, כל בעיית למידה בשיטה א' היא כנראה פשוטה יותר
2. שיטה א' וב' זהות מבחינת מס' ההשוואות הנדרשות, כל בעיית למידה בשיטה א' היא כנראה פשוטה יותר
3. לסיווג ווקטור חדש בשיטה א' נדרשות יותר השוואות, כל בעיית למידה בשיטה א' היא כנראה פשוטה יותר
4. לסיווג ווקטור חדש בשיטה א' נדרשות יותר השוואות, כל בעיית למידה בשיטה ב' היא כנראה פשוטה יותר
5. לסיווג ווקטור חדש בשיטה ב' נדרשות יותר השוואות, כל בעיית למידה בשיטה ב' היא כנראה פשוטה יותר

5. בעיית ה-underflow באלגוריתם Naïve Bayes:

1. כאשר לא ניתן להניח אי תלות בין המאפיינים
2. כאשר איננו יודעים את ההסתברות לכל "מחלקה"
3. כאשר ערך של אחת ההסתברויות הינה 0
4. אף תשובה אינה נכונה
5. עשויה לקרות בגלל שיש מכפלות של הסתברויות רבות שערך קרוב ל-0

6. AdaBoost

1. ניתן להשתמש באותה היפוטזה h באיטרציה t ובאיטרציה $t+1$ רק אם השתמשנו באותה היפוטזה באיטרציה $t-1$
2. לא ניתן להשתמש באותה היפוטזה h באיטרציה t ובאיטרציה $t+1$ אם השתמשנו באותה היפוטזה באיטרציה $t-1$ (אחרת, מותר להשתמש)
3. ניתן להשתמש באותה היפוטזה h באיטרציה t ובאיטרציה $t+1$.
4. אף תשובה אינה נכונה
5. לא ניתן להשתמש באותה היפוטזה h באיטרציה t ובאיטרציה $t+1$ מכיוון שבאיטרציה $t+1$ נקבל טעות של 50%

7. נתונה טבלת האימון הבאה:

X1	X2	X3	X4	Class
1	1	1	1	P
1	1	0	0	P
0	2	1	0	P
0	0	0	0	N
0	0	1	0	N
0	2	1	0	N

חשב את $IG(class|x2)$

1. $2/3$
2. 1
3. לא ניתן לחשב
4. $1/2$
5. $1/3$

8. הרצנו את אלגוריתם הלמידה שלנו על קבוצת מבחן המכילה 420 דוגמאות. האלגוריתם שלנו הצליח לגלות 200 "חיוביים" מתוך 300 ה-"חיוביים", וצדק ב-110 "שליליים" מתוך 120 שליליים:

1. $TP = 2/3, FP = 1/12$
2. $TP = 11/12, FP = 1/12$
3. לא ניתן לחשב
4. $TP = 1/12, FP = 2/3$
5. $TP = 1/12, FP = 11/12$

9. למדנו שני מדדים להערכת ביצועים עפ"י גרף ROC – EER ו-AUC

1. מדד ה-EER בוחן נקודה ספציפית בגרף ומדד ה-AUC משקף לנו מדד על פני כל הגרף
2. מדד ה-EER ומדד ה-AUC בוחנים נקודה ספציפית בגרף
3. כל התשובות נכונות
4. מדד ה-AUC בוחן נקודה ספציפית בגרף ומדד ה-EER משקף לנו מדד על פני כל הגרף
5. מדד ה-EER ומדד ה-AUC משקפים לנו מדד על פני כל הגרף

10. נתונה טבלת האימון הבאה:

X1	X2	X3	X4	Class
3	5	2	1	1
5	1	1	3	1
2	1	3	0	-1
1	2	4	3	1

נדרש לסווג עם אלגוריתם פרספטרון. כפי שלמדנו בהרצאות, מוסיפים נורון דמי שערך $x_0=1$. הניחוש ראשוני שלנו לקבוצת המשקולות הוא, $w_0=2, w_1=2, w_2=1, w_3=2, w_4=1$. עוברים על הדוגמאות כפי סדר הופעתם בטבלה. מה יהיה צעד העדכון הבא

1. $w_0=3, w_1=5, w_2=6, w_3=4, w_4=2$
2. $w_0=1, w_1=0, w_2=0, w_3=-1, w_4=1$
3. אין עדכונים. קבוצת משקולות זו פותרת כבר את הבעיה הנתונה
4. $w_0=1, w_1=-3, w_2=1, w_3=1, w_4=-1$
5. $w_0=1, w_1=-1, w_2=-3, w_3=0, w_4=0$

11. הפרדה לא לינארית:

1. ניתן לבצע רק ע"י SVM עם קרנל לא לינארי
2. ניתן לייצר ע"י שקלול של מספר מפרידים לינאריים
3. אף תשובה אינה נכונה
4. ניתן לייצר ע"י פרספטרון
5. לא ניתן לייצר ע"י שקלול של מספר מפרידים לינאריים

12. נתונה טבלת אימון בת 8 דוגמאות. רוצים לסווג דוגמא מסוימת X עפ"י אלגוריתם KNN. עבור $k=3$. חישבנו את המרחק של הדוגמא X המבוקשת מכל אחת מהדוגמאות שבקבוצת האימון. נתונה הטבלה הבאה המכילה את שלושת הדוגמאות הקרובות ביותר (סיווג כל דוגמא ומרחקה מהדוגמא X)

סיווג הדוגמא	מרחק מהדוגמא X	דוגמא מס'
"שלילי"	2	1
"חיובי"	2	2
"חיובי"	2	3

כיצד יסווג הווקטור X

1. עם שקלול מרחקים של $1/d$ וללא שקלול מרחקים יסווג כחיובי
2. עם שקלול מרחקים של $1/d$ יסווג כחיובי, ללא שקלול מרחקים יסווג כחיובי
3. עם שקלול מרחקים של $1/d$ וללא שקלול מרחקים יסווג כשלילי
4. עם שקלול מרחקים של $1/d$ יסווג כשלילי, ללא שקלול מרחקים יסווג כשלילי
5. לא ניתן לחשב ללא ידיעת מטריקת המרחק