



המסלול האקדמי המכללה למינהל בית הספר "מדעי המחשב"

ת.ז. הסטודנט: _____

מס' חדר: _____ מס' נבחן: _____

מבחן בקורס "למידה חישובית וכריית נתונים"

תאריך הבחינה: 03/11/2013 שעה - 17:00

שנה"ל: תשע"ג, סמסטר: ב', מועד: ג'

שם המרצה/ים: ד"ר משה בוטמן

שם המתרגל/ים:

משך הבחינה: 2.5 שעות

מספר חלקים בבחינה: 2

הוראות לנבחן:

- הבחינה מורכבת משני חלקים:

- חלק א: 2 שאלות פתוחות, משקל כל שאלה: בצמוד לשאלה.
- חלק ב: 12 שאלות רב ברירה. משקל כל שאלה 5 נקודות.
- יש לענות על כל השאלות (חלק א': במחברת - חלק ב': בדף קידוד כנדרש).
- הבחינה: ללא חומר עזר!
- שימוש במחשבון כיס/פיננסי: לא
- מחברת טיוטה: לפי בקשה
- יש לבחור את התשובה הנכונה ביותר ולסמן את התשובה בדף הקידוד.
- יש לסמן את התשובה בדף הקידוד בעט שחור או כחול בלבד באופן ברור ומודגש.
- רק דף הקידוד ייבדק!
- יש להחזיר את טופס השאלון!
- אין לסמן את התשובות על גבי השאלון בטוש זוהר (מרקר)!

*** חשוב מאוד:

בדף הקידוד יש לרשום ולקדד את מספר השאלון מוצמד לימין (להוסיף אפסים משמאל).
יש לרשום את מס' תעודת הזהות במקום המיועד בכתב יד ברור (כולל ספרת הביקורת).

בהצלחה !!!

חלק א: 2 שאלות פתוחות

שאלה 1 (20 נקודות):

נניח שאנו רוצים לסווג עבור מערכת בנקאית את הלקחות שלנו ל"לקוחות שכדאי לתת להם אשראי" (לקוח "חיובי") וללקוחות שלא כדאי לתת להם אשראי (לקוח "שלילי") קבוצת האימון שלנו מכילה נתונים היסטוריים על לקוחות רבים ומכילה את המאפיינים הבאים עבור כל לקוח:

גיל – 4 קבוצות גיל שונות ("0" - קטן מ-30, "1" - 31-40, "2" - 41-50, "3" - 51-60)

גובה שכר – 3 קבוצות ("0" - נמוך, "1" - בינוני, "2" - גבוה)

מין – "0" - זכר, "1" - נקבה

מצב משפחתי – "0" - רווק, "1" - נשוי, "2" - גרוש

א. נתונה טבלת האימון הבאה

#	גיל (x_1)	גובה שכר (x_2)	מין (x_3)	מצב משפחתי (x_4)	class
1	0	2	0	1	P
2	1	0	1	1	P
3	1	0	0	0	P
4	0	1	1	1	P
5	0	1	1	2	N
6	2	1	1	0	N
7	1	2	0	1	N
8	1	2	0	1	N

א. (7 נקודות) הרץ את אלגוריתם הפרספטרון במוד אינקרמנטלי סיבוב שלם (כלומר מעבר פעם אחת על כל הדוגמאות). התחל מסט משקולות בו כל המשקולות 1, והוספת נורון דמי שערכו תמיד שווה ל-1.

(1) (5 נקודות) מהו סט המשקולות אליו הגעת?

(2) (2 נקודות) האם סט המשקולות אליו הגעת פותר את הבעיה? נמק.

ב. (6 נקודות) מגיע אלינו הלקוח הבא: גיל 33, גובה שכר בינוני, זכר, רווק. האם

נמליץ לתת ללקוח זה אשראי? פתור סעיף זה באמצעות אלגוריתם פרספטרון עבור סט

המשקולות הבא: ($w_0=1, w_1=-1, w_2=1, w_3=-1, w_4=1$). נמק בפירוט את תשובתך


ג. (7 נקודות) מגיע אלינו הלקוח הבא: גיל 33, גובה שכר בינוני, זכר, רווק. האם נמליץ לתת

ללקוח זה אשראי? פתור סעיף זה עם אלגוריתם KNN, מטריקת מרחק L_1 , $k=3$,

משקול מרחקים של $1/d$. נמק בפירוט את תשובתך

שאלה 2 (20 נקודות):

בעיית אישכול – נתונים לנו ווקטורים. המפולגים כמתואר בשרטוט הבא.



א. (7 נקודות) הנקודות האדומות מציינות לנו בחירה ראשונית של מרכזים עפ"י אלגוריתם K-means עבור $k=2$. שרטט את המרכזים והאשכולות בסוף הרצת האלגוריתם. הסבר בפירוט מה התהליך שיתרחש

ב. (7 נקודות) הרצנו על אותה בעיה אלגוריתם היררכי (bottom-up) עם תנאי עצירה של "עצירה כאשר המרחק בין האשכולות גדול מ- $0.75r$ ". שרטט את האשכולות שיווצרו. נמק בפירוט את תשובתך.

ג. (6 נקודות) הזכרנו בהרצאה שבאלגוריתם k-means קיימת בעיה כאשר יש outliers (דוגמאות שנראות שלא במקומם הטבעי כגון, רעשים וכו'). הסבר את הבעיה שעלולה להיווצר בהפעלת אלגוריתם k-means ומהו פתרון שהצענו להתמודדות חלקית עם הבעיה (רמז: k-medoids)

1. נתונה בעיית למידה (סיווג) בה יש 2 מחלקות סיווג שונות. מהי האנתרופיה המינימאלית והמקסימאלית של "מחלקה" (class)

- מינימאלית – 4, מקסימאלית – 5
- מינימאלית – $2\log 23$, מקסימאלית – 1
- מינימאלית – 1, מקסימאלית – 1
- מינימאלית – 0, מקסימאלית – 1
- מינימאלית – 0, מקסימאלית – 1.5

2. תהליך boosting

- רק אם משתמשים ב-adaboost ניתן להגיע ליכולת הפרדה לא לינארית ע"י שקלול של תוצאת מסווגים שונים
- באמצעות שקלול של תוצאת מס' מסווגים לינאריים לא ניתן להגיע למסווג לא לינארי
- באמצעות שקלול של תוצאת מס' מסווגים לינאריים ניתן להגיע למסווג לא לינארי
- הינו תהליך להערכת ביצועי מכונת למידה
- מותר לבצע את התהליך רק אם משקללים יחד מס' אלגוריתמי פרסטרון

3. שיטת gradient-descent באלגוריתם הפרסטרון:

- עשוי למצוא לנו מינימום מקומי של הטעות כפונקציה של המשקולות
- מתאים רק לבעיית סיווג
- תמיד ימצא לנו מינימום גלובלי של הטעות כפונקציה של המשקולות
- מתאים רק לבעיית רגרסיה
- תמיד יתכנס לסט משקולות שפותר את הבעיה (לפחות על קבוצת האימון)

4. "עץ החלטה" – באלגוריתם "עץ החלטה" (ID3) חישבנו את האנתרופיה של "מחלקה" וקיבלנו 1.3

- יש לפחות שש מחלקות
- ברור שבעיית הלמידה היא בינארית (שתי מחלקות)
- אף תשובה אינה נכונה
- לא יכול לצאת אנתרופיה גבוהה מ-1
- ברור שבעיית הלמידה היא "מרבית מחלקות" (multi-class)

5. הנחת אי התלות בין המאפיינים באלגוריתם נאיב בייס

- באה כדי למנוע את בעיית ה-overflow
- באה כדי למנוע את בעיית ה-underflow
- האלגוריתם אוסר להניח אי תלות בין המאפיינים
- הנחה זו הינה חלק מחוק בייס
- מאפשרת לנו לחשב את ההסתברות המותנית הנדרשת בהינתן ווקטור רב מימדי כמכפלה של ההסתברויות בהינתן כל מאפיין בנפרד.

6. שרטטנו את גרף ה-ROC עבור אלגוריתם מסויים. שתי נקודות בגרף הם- נקודה א': עבור TP% השווה ל- 80 יש לנו FP% השווה ל- 10 ונקודה ב': עבור TP% השווה ל- 90 יש לנו FP% השווה ל- 20. מה ניתן לאמר בוודאות על ה-EER

1. שווה בדיוק ל-0.1
2. ערכו קטן מ-0.1
3. שווה בדיוק ל-0.2
4. ערכו בין 0.1 ל-0.2
5. ערכו גדול מ-0.2

7. נתונה טבלת האימון הבאה:

X1	X2	X3	X4	Class
1	1	1	1	P
1	1	0	0	P
0	0	1	0	N
0	0	0	0	N

חשב את $H(\text{class} | x_1 = 1)$

1. 1/16
2. 1/2
3. 1
4. 1/4
5. 0

8. אלגוריתם Lazy

1. מחשב מודל למידה כבר בשלב ה"אימון", אלגוריתם KNN הינו אלגוריתם Lazy, חסרון גדול הינו זמן בניית המודל
2. מחשב מודל למידה כבר בשלב ה"אימון", אלגוריתם פרספטרון הינו אלגוריתם Lazy, חסרון גדול הינו זמן בניית המודל
3. אינו מחשב מודל למידה בשלב ה"אימון", אלגוריתם פרספטרון הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה
4. אינו מחשב מודל למידה בשלב ה"אימון", אלגוריתם KNN הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה
5. מחשב מודל למידה גם בשלב ה"אימון" וגם בזמן סיווג נקודה חדשה, אלגוריתם SVM הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה.

9. אלגוריתם (K Nearest Neighbors) KNN – ד"ר שקשוקה מציע שנשתמש ב-K השווה למספר הווקטורים שבקבוצת האימון

1. עם משקול מרחקים וללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי מיעוט הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "שלילי").
2. עם משקול מרחקים וללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי רוב הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "חיובי").
3. אף תשובה אינה נכונה
4. ללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי רוב הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "חיובי"). עם משקול מרחקים – לא ניתן לדעת
5. ללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי מיעוט הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "שלילי"). עם משקול מרחקים – לא ניתן לדעת

10. פתרנו את בעיית האופטימיזציה של אלגוריתם SVM עם קרנל לינארי, חישבנו את W וקיבלנו $W=(2,2,x)$. נתון לנו גם שהווקטור $(f_1=1, f_2=1, f_3=1)$ הינו Support Vector, וערכו כפי שקיבלנו מהמנחה הוא: P . אלו מהבאים הינם ערכים אפשריים ל- x ול- b של משוואת הסיווג של אלגוריתם SVM: $f(\text{vector})=W \cdot \text{vector}^T + b$

1. $(x=2, b=6)$
2. $(x=1, b=7)$
3. $(x=1, b=-4)$
4. $(x=2, b=-2)$
5. $(x=2, b=-6)$

11. אלגוריתם K-means - אחד החסרונות של האלגוריתם הינו שצריך לדעת את K מראש. ד"ר שקשוקה מציע את האלגוריתם הבא (נניח שנתונים לנו n ווקטורים) – הרץ את האלגוריתם עבור כל k אפשרי (מ-1 עד n) ובחר את ה- k שמביא אותנו ל- distortion המינימאלי.

1. אף תשובה אינה נכונה.
2. אלגוריתם מצויין. הבעיה שייקח הרבה זמן עיבוד.
3. עבור המקרה בו ה- k האופטימאלי הוא 3, אלגוריתם זה עשוי להתכנס ל- $k=2$.
4. זהו אלגוריתם לא טוב מכיוון שיתכנס לכך ש- k השווה בדיוק ל-1.
5. זהו אלגוריתם לא טוב מכיוון שיתכנס לכך ש- k השווה בדיוק ל- n .

12. למדנו שכדי לפתור בעיית multi-class מספיק לדעת כיצד פותרים בעייה בינארית וזאת ע"י יצירת מספר בעיות למידה בינאריות והרצתם. הזכרנו שתי שיטות: One vs. One (שיטה א') או One vs. All (שיטה ב'). עבור 4 "מחלקות". לסיווג ווקטור חדש:

1. בשיטה א' יש 6 הרצות ובשיטה ב' יש 6 הרצות
2. בשיטה א' יש 4 הרצות ובשיטה ב' יש 4 הרצות
3. בשיטה א' יש 6 הרצות ובשיטה ב' יש 4 הרצות
4. בשתי השיטות 6 השוואות
5. בשיטה א' יש 4 הרצות ובשיטה ב' יש 6 הרצות