

שאלה 1:

למדנו שכדי לפתור בעיית multi-class מספיק לדעת כיצד פותרים בעייה בינארית וזאת ע"י יצירת מספר בעיות למידה בינאריות והרצתם. הזכרנו שתי שיטות: One vs. One (שיטה א') או One vs. All (שיטה ב'). עבור 4 "מחלקות". לסיווג ווקטור חדש:

1. בשיטה א' יש 6 הרצות ובשיטה ב' יש 4 הרצות
2. בשיטה א' יש 4 הרצות ובשיטה ב' יש 6 הרצות
3. בשיטה א' יש 4 הרצות ובשיטה ב' יש 4 הרצות
4. בשיטה א' יש 6 הרצות ובשיטה ב' יש 6 הרצות
5. בשתי השיטות 6 השוואות

שאלה 2:

שרטטנו את גרף ה ROC-עבור אלגוריתם מסויים. שתי נקודות בגרף הם- נקודה א': עבור $TP\%$ השווה ל- 80 יש לנו $FP\%$ השווה ל- 10 ונקודה ב': עבור $TP\%$ השווה ל- 90 יש לנו $FP\%$ השווה ל- 20. מה ניתן לאמר בוודאות על ה-EER

1. ערכו בין 0.1 ל- 0.2
2. ערכו קטן מ- 0.1
3. ערכו גדול מ- 0.2
4. שווה בדיוק ל- 0.2
5. שווה בדיוק ל- 0.1

שאלה 3:

"עץ החלטה" – באלגוריתם "עץ החלטה" (ID3) חישבנו את האנתרופיה של "מחלקה" וקיבלנו 1.3

1. ברור שבעיית הלמידה היא "מרבית מחלקות" (multi-class)
2. ברור שבעיית הלמידה היא בינארית (שתי מחלקות)
3. לא יכול לצאת אנתרופיה גבוהה מ- 1
4. יש לפחות שש מחלקות
5. אף תשובה אינה נכונה

שאלה 4:

אלגוריתם KNN(K Nearest Neighbors) – ד"ר שקשוקה מציע שנשתמש ב-K השווה למספר הווקטורים שבקבוצת האימון

1. ללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי רוב הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "חיובי"). עם משקול מרחקים – לא ניתן לדעת
2. ללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי מיעוט הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "שלילי"). עם משקול מרחקים – לא ניתן לדעת
3. עם משקול מרחקים וללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי רוב הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "חיובי").
4. עם משקול מרחקים וללא משקול מרחקים, זה יגרום לכך שכל ווקטור חדש לסיווג, יסווג לפי מיעוט הווקטורים (כלומר, אם רוב הווקטורים בקבוצת האימון הם חיוביים, נכריע "שלילי").
5. אף תשובה אינה נכונה

שאלה 5:

נתונה בעיית למידה (סיווג) בה יש 2 מחלקות סיווג שונות. מהי האנטרופיה המינימאלית והמקסימאלית של "מחלקה" (class)

1. מינימאלית – 0, מקסימאלית – 1
2. מינימאלית – 0, מקסימאלית – 1.5
3. מינימאלית – -1, מקסימאלית – 1
4. מינימאלית – 4, מקסימאלית – 5
5. מינימאלית – $2\log_2 3$, מקסימאלית – 1

שאלה 6:

שיטת gradient-descent באלגוריתם הפרספטרון:

1. עשוי למצוא לנו מינימום מקומי של הטעות כפונקציה של המשקולות
2. תמיד ימצא לנו מינימום גלובלי של הטעות כפונקציה של המשקולות
3. תמיד יתכנס לסט משקולות שפותר את הבעיה (לפחות על קבוצת האימון)
4. מתאים רק לבעיית סיווג
5. מתאים רק לבעיית רגרסיה

שאלה 7:

נתונה טבלת האימון הבאה:

X1	X2	X3	X4	Class
1	1	1	1	P
1	1	0	0	P
0	0	1	0	N
0	0	0	0	N

חשב את $H(\text{class}|x_1=1)$

1. 0
2. 1
3. $1/4$
4. $1/16$
5. $1/2$

שאלה 8:

פתרנו את בעיית האופטימיזציה של אלגוריתם SVM עם קרנל לינארי, חישבנו את W וקיבלנו $W=(2,2,x)$. נתון לנו גם שהווקטור $(f_1=1, f_2=1, f_3=1)$ הינו Support Vector, וערכו כפי שקיבלנו מהמנחה הוא: P. אלו מהבאים הינם ערכים אפשריים ל- x ול- b של משוואת הסיווג של אלגוריתם SVM: $f(\text{vector})=W \cdot \text{vector}^T + b$

1. $(x=1, b=-4)$
2. $(x=2, b=-6)$
3. $(x=1, b=7)$
4. $(x=2, b=6)$
5. $(x=2, b=-2)$

שאלה 9:

אלגוריתם Lazy

1. אינו מחשב מודל למידה בשלב ה"אימון", אלגוריתם KNN הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה
2. אינו מחשב מודל למידה בשלב ה"אימון", אלגוריתם פרספטרון הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה
3. מחשב מודל למידה כבר בשלב ה"אימון", אלגוריתם פרספטרון הינו אלגוריתם Lazy, חסרון גדול הינו זמן בניית המודל
4. מחשב מודל למידה כבר בשלב ה"אימון", אלגוריתם KNN הינו אלגוריתם Lazy, חסרון גדול הינו זמן בניית המודל
5. מחשב מודל למידה גם בשלב ה"אימון" וגם בזמן סיווג נקודה חדשה, אלגוריתם SVM הינו אלגוריתם Lazy, חסרון גדול הינו הזמן לסיווג נקודה חדשה.

שאלה 10:

K-means - אחד החסרונות של האלגוריתם הינו שצריך לדעת את K מראש. ד"ר שקשוקה מציע את האלגוריתם הבא (נניח שנתונים לנו n ווקטורים) – הרץ את האלגוריתם עבור כל k אפשרי (מ-1 עד n) ובחר את ה- k שמביא אותנו ל-**distortion** המינימאלי.

1. זהו אלגוריתם לא טוב מכיוון שיתכנס לכך ש- k השווה בדיוק ל- n
2. זהו אלגוריתם לא טוב מכיוון שיתכנס לכך ש- k השווה בדיוק ל-1
3. אלגוריתם מצויין. הבעיה שייקח הרבה זמן עיבוד.
4. עבור המקרה בו ה- k האופטימאלי הוא 3, אלגוריתם זה עשוי להתכנס ל- $k=2$
5. אף תשובה אינה נכונה.

שאלה 11:

תהליך boosting

1. באמצעות שקלול של תוצאת מס' מסווגים לינאריים ניתן להגיע למסווג לא לינארי
2. באמצעות שקלול של תוצאת מס' מסווגים לינאריים לא ניתן להגיע למסווג לא לינארי
3. רק אם משתמשים ב-adaboost ניתן להגיע ליכולת הפרדה לא לינארית ע"י שקלול של תוצאת מסווגים שונים
4. מותר לבצע את התהליך רק אם משקללים יחד מס' אלגוריתמי פרספטרון
5. הינו תהליך להערכת ביצועי מכונת למידה

שאלה 12:

הנחת אי התלות בין המאפיינים באלגוריתם נאיב ביס

1. מאפשרת לנו לחשב את ההסתברות המותנית הנדרשת בהינתן ווקטור רב מימדי כמכפלה של ההסתברויות בהינתן כל מאפיין בנפרד.
2. האלגוריתם אוסר להניח אי תלות בין המאפיינים
3. הנחה זו הינה חלק מחוק ביס
4. באה כדי למנוע את בעיית ה-underflow
5. באה כדי למנוע את בעיית ה-overflow

שאלה 1 (20 נקודות):

נניח שאנו רוצים לסווג עבור מערכת בנקאית את הלקוחות שלנו ל"לקוחות שכדאי לתת להם אשראי" (לקוח "חיובי") וללקוחות שלא כדאי לתת להם אשראי (לקוח "שלילי") קבוצת האימון שלנו מכילה נתונים היסטוריים על לקוחות רבים ומכילה את המאפיינים הבאים עבור כל לקוח:

גיל – 4 קבוצות גיל שונות ("0" - קטן מ-30, "1" - 31-40, "2" - 41-50, "3" - 51-60)

גובה שכר – 3 קבוצות ("0" - נמוך, "1" - בינוני, "2" - גבוה)

מין – "0" - זכר/"1" - נקבה

מצב משפחתי – "0" - רווק/"1" - נשוי/"2" - גרוש

א. נתונה טבלת האימון הבאה

#	גיל (x1)	גובה שכר (x2)	מין (x3)	מצב משפחתי (x4)	class
1	0	2	0	1	P
2	1	0	1	1	P
3	1	0	0	0	P
4	0	1	1	1	P
5	0	1	1	2	N
6	2	1	1	0	N
7	1	2	0	1	N
8	1	2	0	1	N

א. (7 נקודות) הרץ את אלגוריתם הפרספטרון במוד אינקרמנטלי סיבוב שלם (כלומר מעבר פעם אחת על כל הדוגמאות). התחל מסט משקולות בו כל המשקולות 1, והוספת נורון דמי שערכו תמיד שווה ל-1.

(1 (5 נקודות) מהו סט המשקולות אליו הגעת?

(2 (2 נקודות) האם סט המשקולות אליו הגעת פותר את הבעיה? נמק.

(1 פתרון: נשתמש בחוק העדכון של פרספטרון:

אם חזינו בטעות כ"חיובי" $w = w - x$, אם חזינו בטעות כ"שלילי" $w = w + x$

#	x0	x1	x2	x3	x4	w0	w1	w2	w3	w4	prediction	Real class	Update?
1	1	0	2	0	1	1	1	1	1	1	P	P	N
2	1	1	0	1	1	1	1	1	1	1	P	P	N
3	1	1	0	0	0	1	1	1	1	1	P	P	N
4	1	0	1	1	1	1	1	1	1	1	P	P	N
5	1	0	1	1	2	1	1	1	1	1	P	N	Y
6	1	2	1	1	0	0	1	0	0	-1	P	N	Y
7	1	1	2	0	1	-1	-1	-1	-1	-1	N	N	N
8	1	1	2	0	1	-1	-1	-1	-1	-1	N	N	N

(2 פתרון: סט משקולות זה אינו פותר את הבעיה. ניתן לראות על דוגמא מס' 1 שסט משקולות זה יתן תשובה שלילית (למרות שהערך האמיתי הוא "חיובי")

ב. (6 נקודות) מגיע אלינו הלקוח הבא : גיל 33, גובה שכר בינוני, זכר, רווק. האם נמליץ לתת ללקוח זה אשראי? פתור סעיף זה באמצעות אלגוריתם פרספטון עבור סט המשקולות הבא: $(w_0=1, w_1=-1, w_2=1, w_3=-1, w_4=1)$. נוירון דמי – ערכו 1. נמק בפירוט את תשובתך פתרון :

$$(x_0=1, x_1=1, x_2=1, x_3=0, x_4=0)$$

$$(w_0=1, w_1=-1, w_2=1, w_3=-1, w_4=1)$$

$$\text{SGN}(1 \times 1 + 1 \times -1 + 1 \times 1 + 0 \times -1 + 0 \times 1) = \text{SGN}(1) = 1$$

ולכן יסווג כ"חיובי" כלומר נמליץ לתת לו אשראי.

ג. (7 נקודות) מגיע אלינו הלקוח הבא : גיל 33, גובה שכר בינוני, זכר, רווק. האם נמליץ לתת ללקוח זה אשראי? פתור סעיף זה עם אלגוריתם KNN, מטריקת מרחק $L_1, k=3$, משקול מרחקים של $1/d$. נמק בפירוט את תשובתך פתרון :

$$(x_1=1, x_2=1, x_3=0, x_4=0)$$

#	x1	x2	x3	x4	Distance from (x1=1, x2=1, x3=0, x4=0)
1	0	2	0	1	$ 1-0 + 1-2 + 0-0 + 0-1 =3$
2	1	0	1	1	$ 1-1 + 1-0 + 0-1 + 0-1 =3$
3	1	0	0	0	$ 1-1 + 1-0 + 0-0 + 0-0 =1$
4	0	1	1	1	$ 1-0 + 1-1 + 0-1 + 0-1 =3$
5	0	1	1	2	$ 1-0 + 1-1 + 0-1 + 0-2 =4$
6	2	1	1	0	$ 1-2 + 1-1 + 0-1 + 0-0 =2$
7	1	2	0	1	$ 1-1 + 1-2 + 0-0 + 0-1 =2$
8	1	2	0	1	$ 1-1 + 1-2 + 0-0 + 0-1 =2$

קיבלנו ששלושת הווקטורים הקרובים ביותר, הם ווקטור מס' 3 (ערכו "חיובי") ווקטורים 6#,7#,8 שערכם שלילי. נבחר שניים מהם ונבחן משקל מי גדול יותר – חיובי או שלילי?


$$\text{"משקל חיובי"} = 1/1$$

$$\text{"משקל שלילי"} = -1/2 + 1/2 = 1$$

משקל החיוביים והשליליים זהה. מכיוון שבשלושת הקרובים ביותר יש רוב שליליים – נסווג כשלילי, כלומר לא נמליץ לתת אשראי.

שאלה 2 (20 נקודות):

בעיית אישכול – נתונים לנו ווקטורים. המפולגים כמתואר בשרטוט הבא.



א. (7 נקודות) הנקודות האדומות מציינות לנו בחירה ראשונית של מרכזים עפ"י


אלגוריתם K-means עבור $k=2$. שרטט את המרכזים והאשכולות בסוף הרצת


האלגוריתם. הסבר בפירוט מה התהליך שיתרחש.

פתרון: עפ"י האלגוריתם יתבצע שיוך ווקטורים למרכזים ואז עדכון המרכזים. בדוגמא

שלנו העיגול העליון יתחיל בתנועה כלפי הריבוע העליון והעיגול התחתון יתכנס לכיוון

מרכז הריבוע התחתון. להלן תיאור סכמטי:





בסופו של התהליך הריבוע התחתון הינו אשכול והריבוע העליון הינו אשכול.

ב. (7 נקודות) הרצנו על אותה בעיה אלגוריתם היררכי (bottom-up) עם תנאי עצירה של "עצירה כאשר המרחק בין האשכולות גדול מ- $0.75r$ ". שרטט את האשכולות שיווצרו. נמק בפירוט את תשובתך.

פתרון: אלגוריתם היררכי bottom-up עובד בצורה הבאה מאחד בכל פעם את שני האשכולות הקרובים באותה איטרציה וכך עד שמתקיים תנאי עצירה. כלומר בדוגמא שלנו יאוחדו בכל שלב אשכולות מאותו הריבוע. כך נגיע למצב שכל ריבוע (כל הנקודות השייכות לאותו ריבוע יתאחדו) ויהיו לנו שני אשכולות: הריבוע העליון והריבוע התחתון. כעת, כשנרצה לאחד את שני האשכולות נבדוק את תנאי העצירה. מכיוון שהמרחק גדול מהמופיע בתנאי העצירה לא נאחד את שני האשכולות,

ונגיע למצב בו יש לנו שני אשכולות: הווקטורים בריבוע העליון – אשכול אחד.
הווקטורים בריבוע התחתון – ווקטור שני.

ג. (6 נקודות) הזכרנו בהרצאה שבאלגוריתם k-means קיימת בעיה כאשר יש outliers (דוגמאות שנראות שלא במקומם הטבעי כגון, רעשים וכו'). הסבר את הבעיה שעלולה להיווצר בהפעלת אלגוריתם k-means ומהו פתרון שהצענו להתמודדות חלקית עם הבעיה (רמז: k-medoids)
פתרון: כאשר יש outlier מרכז האשכול יהיה לא במקומו הטבעי כי ה-outlier "יסחוף" אותו. לדוגמא:



הפתרון החלקי שהצענו: k-medoids שמחייב שתמיד מרכז האשכול יהיה ווקטור מהקבוצה.