



המסלול האקדמי המכללה למינהל
בית הספר "מדעי המחשב"

ת.ז הסטודנט: _____

מס' חדר: _____ מס' נבחן: _____

מבחן בקורס "למידה חישובית וכריית נתונים"

תאריך הבחינה: 19/01/2014 שעה - 16:00

שנה"ל: תשע"ד, סמסטר: א', מועד: א'

שם המרצה/ים: ד"ר משה בוטמן

שם המתרגל/ים:

משך הבחינה: 2.5 שעות

מספר חלקים בבחינה: 2

הוראות לנבחן:

- חלק א: 2 שאלות פתוחות, משקל כל שאלה בצמוד לשאלה.
- יש לענות במחברת בחינה וגוף השאלון.
- חלק ב: 12 שאלות רב ברירה יש לענות על כל השאלות, משקל כל שאלה בצמוד לשאלה.
- הבחינה: ללא חומר עזר!
- שימוש במחשבון כיס/פיננסי: לא
- מחברת טיוטה: כן
- יש לבחור את התשובה הנכונה ביותר ולסמן את התשובה בדף הקידוד.
- יש לסמן את התשובה בדף הקידוד בעט שחור או כחול בלבד באופן ברור ומודגש.
- רק דף הקידוד ייבדק!
- יש להחזיר את טופס השאלון!
- אין לסמן את התשובות על גבי השאלון בטוש זוהר (מרקר)!

***** חשוב מאוד:**

בדף הקידוד יש לרשום ולקדד את מספר השאלון מוצמד לימין (להוסיף אפסים משמאל).

יש לרשום את מס' תעודת הזהות במקום המיועד בכתב יד ברור (כולל ספרת הביקורת).

בהצלחה !!!

חלק א': שאלות פתוחות

שאלה 1 (20 נקודות):

1. נתונה טבלת האימון הבאה (נתונים המאפיינים f_1, f_2, f_3 ויש צורך לחזות את class):

f1	f2	f3	Class
0	12	1	P
1	7	1	P
2	0	3	N
1	4	0	N
0	1	0	P
2	10	1	P

א. (7 נקודות) מוצע האלגוריתם הבא לפתרון הבעיה:

$$SGN(w_1 \times f_1 + w_2 \times f_2 + w_3 \times f_3)$$

$$w_1 = -1, w_2 = 2, w_3 = -3$$

חשבו את ה True-Positive ואת ה False Positive של האלגוריתם המוצע על קבוצת האימון.


ב. (8 נקודות) סווג את הווקטור ($f_1 = 3, f_2 = 3, f_3 = 3$) עפ"י אלגוריתם KNN.

$K=3$, משקול מרחקים של $1/d$, מטריקת מרחק אוקלידית, ללא משקול מאפיינים

ג. (5 נקודות) מהם שני החסרונות הבולטים של אלגוריתם KNN? הסבר.

שאלה 2 (20 נקודות):

א. נתונה קבוצת האימון הבאה:



אנו רוצים להשתמש באלגוריתם new_adaboost המתנהג בדיוק כמו אלגוריתם Adaboost שלמדנו בכיתה, למעט פונקציית עדכון המשקלים.

$$D_{t+1}(i) = D_t(i) \cdot \begin{cases} \frac{3}{2} & \text{if } y_i \neq h_t(x_i) \\ \frac{3}{4} & \text{if } y_i = h_t(x_i) \end{cases}_i$$

כאשר:


$D_t(i)$ - המשקל של הדוגמא i באיטרציה t .

y_i - סיווג המנחה על דוגמא i

$h_t(x_i)$ - סיווג ההיפוטזה (אלגוריתם) באיטרציה t על דוגמא i .

אנו מניחים שמתחילים, כפי שלמדנו, ממשקל שווה לכל דוגמא.

באיטרציה הראשונה קיבלנו את ההיפוטזה הבאה:



א. (4 נקודות) האם היפוטזה זו עומדת בתנאים שלמדנו עבור adaboost? נמק בפירוט.

ב. (6 נקודות) חשב את המשקלים החדשים של כל דוגמא לאחר הפעלת היפוטזה זו. הסבר בפירוט.

ג. (4 נקודות) הצע היפוטזה "חוקית" (כלומר שעומדת בתנאים שלמדנו) לאיטרציה 2. נמק בפירוט מדוע זוהי היפוטזה "חוקית".

ד. (6 נקודות) נניח שלא נתון לנו סיווג הדוגמאות ומבקשים מאיתנו לחלק אותם ל"אשכולות". הרץ אלגוריתם אישכול היררכי bottom-up על קבוצת הדוגמאות בשאלה זו.

כמרחק בין שתי אשכולות א' וב', נגדיר את המרחק הקטן ביותר הקיים בין ווקטור מאשכול א' לווקטור מאשכול ב'.

הרץ את האלגוריתם עם תנאי העצירה הבא: עצור כאשר לא קיימים אשכולות עם מרחק הקטן/שווה ל-2 (מרחק אוקלידי).

כמה אשכולות נוצרו בסוף התהליך? מי הם? נמק בפירוט.

בהצלחה !

1. למדנו שהערכת ביצועי מערכת למידה מבוצעת ע"י גרף ROC. למדנו שני מדדים למתן ציון: EER ו-AUC. נתונים לנו שני גרפים המתארים עקומת ROC של שתי מערכות למידה (מערכת א' ומערכת ב').

1. תמיד שני המדדים יצביעו על אותה מערכת כטובה יותר (למשל אם ה-EER יצביע על מערכת א' כטובה יותר גם מדד ה-AUC יצביע על מערכת א' כטובה יותר ולהיפך)
2. יתכן שעפ"י מדד AUC מערכת א' תהיה טובה יותר ועפ"י מדד ה-EER מערכת ב' תהיה טובה יותר
3. מדד ה-EER ומדד ה-AUC הינם אותו המדד בדיוק
4. מדד ה-EER בוחן את התנהגות הגרף בכל נקודות העבודה ומדד ה-AUC בוחן בנקודה ספציפית
5. כל התשובות נכונות

2. נתונה טבלת אימון בת 8 דוגמאות. רוצים לסווג דוגמא מסוימת X עפ"י אלגוריתם KNN. חישבנו את המרחק של הדוגמא X המבוקשת מכל אחת מהדוגמאות שבקבוצת האימון. נתונה הרשימה הבאה המכילה את שלושת הדוגמאות הקרובות ביותר (סיווג כל דוגמא, מרחקה מהדוגמא X):
- (3, "שלילי")
(2, "חיובי")
(2, "חיובי")

1. עבור $k=1$ יסווג כ"חיובי". עבור $k=3$ ללא שקלול מרחקים יסווג כ"חיובי", עם שקלול מרחקים יסווג כ"חיובי".
2. עבור $k=1$ יסווג כ"חיובי". עבור $k=3$ ללא שקלול מרחקים יסווג כ"חיובי", עם שקלול מרחקים - תלוי בפונקציית שקלול המרחק בה משתמשים
3. עבור $k=1$ יסווג כ"שלילי". עבור $k=3$ ללא שקלול מרחקים יסווג כ"חיובי", עם שקלול מרחקים - תלוי בפונקציית שקלול המרחק בה משתמשים
4. עבור $k=1$ יסווג כ"חיובי". עבור $k=3$ ללא שקלול מרחקים יסווג כ"שלילי", עם שקלול מרחקים - "שלילי"
5. עבור $k=1$ יסווג כ"שלילי". עבור $k=3$ ללא שקלול מרחקים יסווג כ"שלילי", עם שקלול מרחקים - "שלילי"

3. עץ החלטה - מנגנון לשיפור בעיית ה-overfitting יכול להיות ע"י:


1. הרצת האלגוריתם במלואו ואז "קיצוץ" העץ
2. בעץ החלטה אין בעיה של overfitting
3. בכל שלב יש לבחור את התכונה עם ה-InfoGain הנמוך ביותר
4. בכל שלב נבחר את התכונה עם מס' הפיצולים הגדול ביותר
5. אף תשובה אינה נכונה

4. פתרנו את בעיית האופטימיזציה של אלגוריתם SVM עם קרנל לינארי, חישבנו את W וקיבלנו $W=(1,2,3)$. נתון לנו גם שהוקטור $(f1=4, f2=2, f3=1)$ הינו Support Vector, וערכו כפי שקיבלנו מהמנחה הוא N. מהו b של משוואת הסיווג של SVM:

$$f(\text{new_vector}) = W \cdot \text{vector}^T + b$$

1. -12
2. -10
3. 1
4. 0
5. 7

5. נתונה רשת הנוירונים הבאה. עבור הכניסה $(x_1 = 1, x_2 = 1, x_3 = 1)$ נקבל במוצא הרשת. פונקציית האקטיבציה בצמתים הפנימיים וביציאה הינה פונקציית הסף עבורה $T=0$



1. $out1 = POS, out2 = NEG, out3 = NEG$
2. $out1 = POS, out2 = POS, out3 = NEG$
3. $out1 = POS, out2 = POS, out3 = POS$
4. $out1 = NEG, out2 = NEG, out3 = NEG$
5. $out1 = POS, out2 = NEG, out3 = POS$

6. אלגוריתם (K-Nearest-Neighbors) KNN

1. מאפשר פתרון בעיה לא לינארית, אינו מתאים לבעיית multi-class
2. אינו מאפשר פתרון בעיה לא לינארית, מתאים לפתרון בעיית multi-class
3. מאפשר פתרון בעיה לא לינארית, מתאים לפתרון בעיית multi-class
4. אינו מאפשר פתרון בעיה לא לינארית, אינו מתאים לפתרון בעיית multi-class
5. אף תשובה אינה נכונה

7. נתונה טבלת האימון הבאה:

X1	X2	X3	X4	Class
1	1	1	1	1
5	1	1	3	1
2	1	3	0	-1
1	2	4	3	1

נדרש לסווג עם אלגוריתם פרספטרון. כפי שלמדנו בהרצאות, מוסיפים נוירון ראשוני שלנו לקבוצת המשקולות הוא $w_0=2, w_1=2, w_2=1, w_3=2, w_4=1$. סדר הופעתם בטבלה. מה יהיה צעד העדכון הבא

1. $w_0=1, w_1=-1, w_2=-3, w_3=0, w_4=0$
2. $w_0=3, w_1=5, w_2=6, w_3=4, w_4=2$
3. $w_0=1, w_1=-3, w_2=1, w_3=1, w_4=-1$
4. אין עדכונים. קבוצת משקולות זו פותרת כבר את הבעיה הנתונה
5. $w_0=1, w_1=0, w_2=0, w_3=-1, w_4=1$

8. לפי אלגוריתם naive bayes מה יהיה סיווג הווקטור הבא:
($x_1=1, x_2=1, x_3=1$)
נתון ש- x_1, x_2, x_3 בלתי תלויים זה בזה. נתון גם:

$$P(\text{"yes"})=0.6$$

$$P(x_1=1|\text{"yes"}) = 0.5, P(x_2=1|\text{"yes"}) = 0.5, P(x_3=1|\text{"yes"}) = 0.5$$

$$P(x_1=1|\text{"no"}) = 0.5, P(x_2=1|\text{"no"}) = 0.5, P(x_3=1|\text{"no"}) = 0.5$$

1. NEG
2. לא ניתן לדעת
3. POS ו-NEG מקבלים הסתברות שווה
4. POS
5. אף תשובה אינה נכונה


9. תהליך boosting -

1. באמצעות שקלול של תוצאת מס' מסווגים לינאריים לא ניתן להגיע למסווג לא לינארי
2. הינו תהליך להערכת ביצועי מכונת למידה
3. באמצעות שקלול של תוצאת מס' מסווגים לינאריים ניתן להגיע למסווג לא לינארי
4. הינו אלגוריתם למציאת מינימום הטעות באלגוריתם פרספטרון
5. אף תשובה אינה נכונה

10. עקרון התער של אוקמה (Ocam's Razor)

1. מציע להפחית את מס' המכפלות באלגוריתם Naïve Bayes ככל שניתן
2. אומר לנו שכדאי לייצר עץ החלטה פשוט ככל שניתן
3. מציע לייצר עץ החלטה עם פיצולים רבים ככל שניתן
4. מציע עקרון boosting
5. כל התשובות נכונות

11. נתונה קבוצת האימון הבאה:



הסרת הנקודה A מקבוצת האימון בוודאי לא תשפיע על תוצאת אלגוריתם:

1. פרספטרון
2. Naive Bayes
3. עץ החלטה
4. SVM לינארי (hard margin)
5. כל התשובות נכונות

12. אלגוריתם אישכול k-means

1. ככל שנבחר k גדול יותר נקבל תשובה מדויקת יותר
 2. אם נבחר k השווה למספר הווקטורים, אזי כל ווקטור יצא אישכול
 3. אין משמעות לבחירת k
 4. אף תשובה אינה נכונה
 5. ב-kmeans נקבל תמיד בסוף התהליך שלושה אישכולות
-