



המסלול האקדמי המכללה למינהל
בית הספר "מדעי המחשב"

ת.ז הסטודנט: _____

מס' חדר: _____ מס' נבחן: _____

מבחן בקורס "למידה חישובית וכריית נתונים"

תאריך הבחינה: 23/02/2014 שעה - 16:00

שנה"ל: תשע"ד, סמסטר: א', מועד: ב'

שם המרצה/ים: ד"ר משה בוטמן

שם המתרגל/ים:

משך הבחינה: 2.5 שעות

מספר חלקים בבחינה: 2

הוראות לנבחן:

חלק א: 2 שאלות פתוחות. משקל כל שאלה בהתאם למופיע ליד השאלה.

חלק ב: 12 שאלות סגורות. משקל כל שאלה 5 נקודות.

- הבחינה: ללא חומר עזר

- שימוש במחשבון כיס/פיננסי: לא

- מחברת טיוטה: במידת הצורך.

- יש לבחור את התשובה הנכונה ביותר ולסמן את התשובה בדף הקידוד.

- יש לסמן את התשובה בדף הקידוד בעט שחור או כחול בלבד באופן ברור ומודגש.

- רק דף הקידוד ייבדק!

- יש להחזיר את טופס השאלון!

- אין לסמן את התשובות על גבי השאלון בטוש זוהר (מרקר)!

***** חשוב מאוד:**

בדף הקידוד יש לרשום ולקדד את מספר השאלון מוצמד לימין (להוסיף אפסים משמאל).

יש לרשום את מס' תעודת הזהות במקום המיועד בכתב יד ברור (כולל ספרת הביקורת).

בהצלחה !!!

שאלות פתוחות

שאלה 1 (20 נקודות):

1. נתונה טבלת האימון הבאה (נתונים המאפיינים f_1, f_2, f_3 ויש צורך לחזות את class):

f1	f2	f3	Class
0	12	1	P
1	7	1	P
2	0	3	N
1	4	0	N
0	1	0	P
2	10	1	P

א. (9 נקודות) מוצע האלגוריתם הבא לפתרון הבעיה:

$$(w_1 \times f_1 + w_2 \times f_2 + w_3 \times f_3)$$
$$w_1 = -1, w_2 = 2, w_3 = -3$$

שרטט את גרף ה-ROC של האלגוריתם.

ב. (6 נקודות) סווג את הווקטור ($f_1 = 1, f_2 = 1, f_3 = 1$) עפ"י אלגוריתם naiveBayes.

במידה ויש צורך לבצע "החלקה" יש להשתמש בפרמטרי ההחלקה הבאים:


בסיס נתונים וירטואלי שגודלו 4 ($m=4$) שהסתברות למאורע בו הינה 0.5 ($p=0.5$)

ג. (5 נקודות) הסבר בקצרה ובדיוק מדוע אלגוריתם ADABOOST רגיש

לווקטורי "רעש" (למשל דוגמא חיובית שהמנחה בטעות אמר עליה שהיא שלילית).

שאלה 2 (20 נקודות):

א. נתונה קבוצת האימון הבאה:



א. (5 נקודות) מהי האנתרופיה של "מחלקה" (כאשר "מחלקה" הינה ההחלטה על סיווג – ריבוע או עיגול)

ב. (6 נקודות) רשום את נוסחת ה-infogain של סיווג לפי x_1 .

ג. (9 נקודות) נניח שלא נתון לנו סיווג הדוגמאות ומבקשים מאיתנו לחלק אותם ל"אשכולות". הרץ אלגוריתם אישכול k-means על קבוצת הדוגמאות בשאלה זו.

יש להשתמש במטריקת מרחק L_1 . עבור $k=2$.

בחר כמרכזים התחלתיים ראשוניים בוקטורים: $(1,1)$ ו- $(2,7)$

הצג איטרציה אחת של עדכון ווקטורים לאשכולות. (כלומר עדכון מרכזים ואז עדכון אשכולות).

1. למדנו שכדי לפתור בעיית multi-class מספיק לדעת כיצד פותרים בעייה בינארית וזאת ע"י יצירת מספר בעיות למידה בינאריות והרצתם. הזכרנו שתי שיטות: One vs. One (שיטה א') או One vs. All (שיטה ב'). עבור 5 "מחלקות". לסיווג ווקטור חדש:

1. בשיטה א' יש 6 הרצות ובשיטה ב' יש 4 הרצות
2. בשיטה א' יש 10 הרצות ובשיטה ב' יש 5 הרצות
3. בשיטה א' יש 60 הרצות ובשיטה ב' יש 5 הרצות
4. בשיטה א' יש 8 הרצות ובשיטה ב' יש 4 הרצות
5. בשיטה א' יש 4 הרצות ובשיטה ב' יש 8 הרצות

2. שרטטנו את גרף ה-ROC של אלגוריתם למידה SVM. קיבלנו שערך ה-EER שווה ל-0.1. אלו מהבאים בוודאי אינו נכון?

1. יש נקודה בגרף שעבור $TP = 90\%$ נקבל $FP = 10\%$
2. ערכו של ה-AUC הוא 0.8
3. יש נקודה בגרף שעבור $TP = 80\%$ נקבל $FP = 20\%$
4. יש נקודה בגרף שעבור $TP = 90\%$ נקבל $FP = 20\%$
5. יש נקודה בגרף שעבור $TP = 80\%$ נקבל $FP = 10\%$

3. "עץ החלטה" – באלגוריתם "עץ החלטה" (ID3) חישבנו את האנדרופיה הספציפית המסויימת של "מחלקה" וקיבלנו 0.5.

$$H(Y|x_i=7) = 0.5$$

1. ברור שמדובר בבעיית למידה בינארית
2. אף תשובה אינה נכונה
3. לא נבחר בתכונה x_i באיטרציה זו כתכונה הטובה ביותר
4. מדובר בבעיית למידה לא לינארית
5. יתכן שזו בעייה מרובת מחלקות

4. הוספת שכבה חבויה ברשתות נוירונים:

1. ללא שכבות חבויות – הפרדה לינארית בלבד. עם שכבה חבויה אחת לפחות – גם הפרדה לא לינארית.
2. ללא שכבות חבויות – הפרדה לא לינארית בלבד. עם שכבה חבויה אחת לפחות – הפרדה לינארית בלבד.
3. עם שכבות חבויות וללא שכבות חבויות – הפרדה לינארית בלבד
4. עם שכבות חבויות וללא שכבות חבויות – גם הפרדה לא לינארית
5. אף תשובה אינה נכונה

5. מטרת טריק הקרנל באלגוריתם SVM

1. יש למפות את הווקטורים למימד הגבוה ובמימד הגבוה לבצע את טריק הקרנל
2. אין משמעות לבחירת הקרנל בסיווג דוגמא חדשה
3. עבור בעיה לינארית, נועד לפתור hard margin
4. עבור בעיה לא לינארית, חוסך לנו את הצורך במיפוי הווקטורים למימד גבוה
5. אף תשובה אינה נכונה

6. אלגוריתם SVM לינארי בעל הכללה טובה יותר מאלגוריתם הפרספטרון :

1. מכיוון שדואג ל-margin מקסימלי בין המחלקות
2. מכיוון שדואג ל-margin מינימאלי בין המחלקות
3. אלגוריתם SVM בעל הכללה פחות טובה מאשר אלגוריתם פרספטרון
4. האלגוריתמים בעלי יכולת הכללה זהה
5. יתרונו של אלגוריתם הפרספטרון שהוא תמיד מתכנס.

7. אלגוריתם K-means :

1. תמיד, ככל ש-K גדול יותר ידרשו יותר איטרציות לאלגוריתם
2. תמיד, ככל ש-K קטן יותר ידרשו יותר איטרציות לאלגוריתם
3. האלגוריתם עשוי לא להתכנס
4. הינו אלגוריתם supervised
5. אף תשובה אינה נכונה

8. נתונה לנו בעיית למידה בה כל ווקטור מיוצג ע"י מאפיינים שונים. אנו רוצים לתת משקל שונה למאפיינים מסויימים (למשל אנו רוצי לתת משקל גבוה יותר ל"גובה שכר" מאשר ל"איזור מגורים")

1. באלגוריתם SVM נבצע את טריק הקרנל
2. באלגוריתם KNN נשתמש במשקול מאפיינים
3. באלגוריתם KNN נשתמש במשקול מרחקים
4. נשתמש ברשת נוירונים עם שכבות חבויות
5. באלגוריתם SVM נשתמש ב-soft margin

9. נתונים לנו הווקטורים הבאים :

X1	X2	X3	Class
1	1	0	P
1	0	1	P
-1	0	0	N

הרצנו את בעיית האופטימיזציה של SVM לינארי, וקיבלנו:

$$\alpha_1 = 0, \alpha_2 = 0.3, \alpha_3 = 0.3$$

במשוואת ה-hyperplane המתקבלת היא:

1. $w=(0,0,0.3)$
2. $w=(0,0.3,0.3)$
3. לא ניתן לחשב
4. $w=(0.3,0.3,0.3)$
5. תלוי ב-b

10. רוצים לסווג את הווקטור $(3,3,3)$ עפ"י KNN
חישבנו את המרחקים מכל קבוצת האימון. להלן:

דוגמא מס'	מרחק מהדוגמא $(3,3,3)$	סיווג הדוגמא
1	2	1
2	3	1
3	2	1
4	4	2
5	1.5	2
6	5	2
7	4	3
8	4	3

1. עבור $K=1$ יסווג כמחלקה 3
2. עבור $K=3$. תלוי בשקלול המרחקים
3. עבור $K=5$ יסווג כ-2
4. עבור $K=3$ יסווג כמחלקה 2
5. עבור $K=1$ תלוי בשקלול מרחקים

11. נתונה בעיית למידה מרובת מחלקות. רוצים לסווג לפי naïve-bayes את הווקטור $(x_1=2, x_2=1, x_3=1)$. ידוע ש- x_1, x_2, x_3 בלתי תלויים. נתון:

$$P(\text{"dog"})=0.5, P(\text{"cat"})=0.2, P(\text{"Giraffe"})=0.3$$

$$P(x_1=1 | \text{"dog"}) = 0.5, P(x_2=1 | \text{"dog"}) = 1, P(x_3=1 | \text{"dog"}) = 1$$

$$P(x_1=1 | \text{"cat"}) = 0.5, P(x_2=1 | \text{"cat"}) = 0.5, P(x_3=1 | \text{"cat"}) = 0.5$$

$$P(x_1=1 | \text{"Giraffe"}) = 0.5, P(x_2=1 | \text{"v"}) = 0.3, P(x_3=1 | \text{"Giraffe"}) = 0.5$$

$$P(x_1=1) = 1, P(x_2=1) = 0.5, P(x_3=1) = 1$$

$$P(x_1=2) = 0.5, P(x_2=2) = 0.5, P(x_3=2) = 0.5$$

1. יסווג כ-GIRAFFE
2. יסווג כ-CAT
3. יסווג כ-DOG
4. אין מספיק נתונים
5. הסתברות שווה ל- CAT ול-GIRAFFE

12. אלגוריתם DBSCAN לביצוע אישכול

1. תמיד יחזיר פחות אשכולות מאלגוריתם K-MEANS
 2. תמיד יחזיר יותר אשכולות מאלגוריתם K-MEANS
 3. שקול לאלגוריתם היררכי top-down
 4. אם ידוע מס' האשכולות אין צורך להגדיר את r ואת minPts
 5. אתגר באלגוריתם הוא להגדיר מהי צפיפות עבור בעיה מסוימת (r, minPts)
-