

פתרון חלק אמריקאי:

1. 1

2. 2

3. 3

4. 4

5. 5

6. 1,2,3 (מי שענה תשובה אחת מאלו)

7. 1

8. 1

9. 1,2,3,4,5 (מי שענה תשובה אחת מאלו , מסתבר שניתן להעביר
קו לינארי שמפריד בין הקבוצות)

10. 1

11. 4

12. 2

שאלה 1 (20 נקודות):

נתונה טבלת האימון הבאה

(נתונים המאפיינים feature1, feature2, feature3 ויש צורך לחזות את class):

Feature1	Feature2	Feature3	Class
0	1	1	P
1	0	0	P
0	0	1	N
1	1	0	N
0	1	2	P
1	1	1	P

א. (4 נקודות) מוצעת המשוואה הבאה לפתרון הבעיה

if $(2f_1 + 3f_2 - f_3 + 4) > \text{THRESHOLD}$

classify POS

else

classify NEG

עבור ערך סף 0, חשב/חשבי את ה True-Positive ואת ה False Positive של

האלגוריתם המוצע על קבוצת האימון.

פתרון:

F1	F2	F3			סיווג
0	1	1	P	$2*0+3*1-1+4 = 6$	p
1	0	0	P	$2*1+3*0-0+4 = 6$	P
0	0	1	N	$2*0+3*0-1+4 = 3$	P
1	1	0	N	$2*1+3*1-0+4 = 9$	P
0	1	2	P	$2*0+3*1-2+4 = 5$	P
1	1	1	P	$2*1+3*1-1+4 = 6$	P

$$\%TP = 4/4 = 100\%$$

$$\%FP = 2/2 = 100\%$$

ב. (5 נקודות) הרץ את אלגוריתם העדכון של הפרספטרון. סיבוב אחד שלם. מוד אינקרמנטלי.

ערך כל המשקולות ההתחלתיים: 1

פתרון:

F0	F1	F2	F3		W0	W1	W2	W3	סיווג	Update?
1	0	1	1	P	1	1	1	1	P	N
1	1	0	0	P	1	1	1	1	P	N
1	0	0	1	N	1	1	1	1	P	Y
1	1	1	0	N	0	1	1	0	P	Y
1	0	1	2	P	-1	0	0	0	N	Y
1	1	1	1	P	0	0	1	2	P	N

ג. (5 נקודות) נדרש להכריע עפ"י אלגוריתם NaiveBayes עבור הווקטור $(x1=1, x2=1, x3=1)$.

האם הוא "P" או "N". נמק כיצד יוכרע הווקטור. יש לפרט כיצד הגעת לפתרון.

$$P(class = P | x1=1, x2=1, x3=1) > ? P(class = N | x1=1, x2=1, x3=1)$$

bayesRule

$$\frac{P(x1=1, x2=1, x3=1 | class = P) \times P(class = P)}{P(x1=1, x2=1, x3=1)} > ? \frac{P(x1=1, x2=1, x3=1 | class = N) \times P(class = N)}{P(x1=1, x2=1, x3=1)}$$

$$P(x1=1, x2=1, x3=1 | class = P) \times P(class = P) > ? P(x1=1, x2=1, x3=1 | class = N) \times P(class = N)$$

FeaturesIndependence

$$P(x1=1 | P) \times P(x2=1 | P) \times P(x3=1 | P) \times P(class = P) > ? P(x1=1 | N) \times P(x2=1 | N) \times P(x3=1 | N) \times P(class = N)$$

$$P(P) = \frac{4}{6} = \frac{2}{3}, P(N) = \frac{2}{6} = \frac{1}{3}$$

$$P(x1=1 | P) = \frac{1}{2}, P(x1=1 | N) = \frac{1}{2}$$

$$P(x2=1 | P) = \frac{3}{4}, P(x2=1 | N) = \frac{1}{2}$$

$$P(x3=1 | P) = \frac{1}{2}, P(x3=1 | N) = \frac{1}{2}$$

$$\frac{2}{3} \times \frac{1}{2} \times \frac{3}{4} \times \frac{1}{2} = \frac{6}{48} = \frac{1}{8}$$

$$\frac{1}{3} \times \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{24} = \frac{2}{48}$$

$$P(class = P | x1=1, x2=1, x3=1) > P(class = N | x1=1, x2=1, x3=1)$$

לכן יסווג כחיובי

ד. (6 נקודות) עפ"י אלגוריתם עץ החלטה ID3 שנלמד בכיתה, איזה תכונה תהיה "אינפורמטיבית" לראש העץ בין feature1 לבין feature3?

פתרון:

$$IG(Y | f_1) = H(Y) - H(Y | x_1)$$

$$IG(Y | f_3) = H(Y) - H(Y | x_3)$$

מכיוון ש- $H(Y)$ זהה עלינו לבדוק רק את הביטוי $H(Y|x_1)$ לעומת $H(Y|x_3)$

$$H(Y | f_1) = H(Y | f_1 = 0) \times P(f_1 = 0) + H(Y | f_1 = 1) \times P(f_1 = 1)$$

$$H(Y | f_1 = 0) = H\left(\frac{1}{3}, \frac{2}{3}\right) \times \frac{1}{2} + H\left(\frac{1}{3}, \frac{2}{3}\right) \times \frac{1}{2} = H\left(\frac{1}{3}, \frac{2}{3}\right)$$

$$H(Y | f_3) = H(Y | f_3 = 0) \times P(f_3 = 0) + H(Y | f_3 = 1) \times P(f_3 = 1) + H(Y | f_3 = 2) \times P(f_3 = 2)$$

$$H(Y | f_3 = 0) = 1 \times \frac{1}{3} + H\left(\frac{1}{3}, \frac{2}{3}\right) \times \frac{1}{2} + 0 \times \frac{1}{6} = \frac{1}{3} + H\left(\frac{1}{3}, \frac{2}{3}\right)$$


$$H(Y | f_3 = 0) > H(Y | f_1 = 0)$$

$$IG(y | f_1) > IG(y | f_3)$$

לכן נבחר את feature1

שאלה 2 (20 נקודות):

נתונה קבוצת האימון הבאה:



1. (7 נקודות) מהו ערך השגיאה הכוללת של מסווג KNN כאשר $K=1$, אם משתמשים ב-leave one out? השתמשו במרחק אוקלידי $L2$ ללא משקול מאפיינים ומרחקים. נמק' את התשובה.

פתרון:

נשים לב שתמיד מתקיים – הוקטור הכי קרוב לכל אחד מהוקטורים הוא ממחלקה שונה. לכן, השגיאה תהיה מקסימלית 100%.

2. (7 נקודות) הנח' שלא נתונים סיווגי הנקודות. יש להריץ אלגוריתם KMEANS עם $K=2$ עד להתכנסות. הניחו שהמרכזים שנבחרו בהתחלה הם $(1,-1)$, $(-1,1)$

פתרון:

באיטרציה 1, כל הוקטורים בחלק העליון של האיור ישויכו ל $(-1,1)$ וכל הוקטורים בחלק התחתון של האיור ישויכו ל $(1,-1)$

לאחר מכן יוצרו המרכזים החדשים שהם הממוצעים של הוקטורים השייכים לכל אשכול. המרכזים החדשים יהיו:

$$newX_cluster1 = \frac{-1 + -1 + 0 + 0 + 1}{5} = -\frac{1}{5}, newY_cluster1 = \frac{1 + 2 + 2 + 3 + 3}{5} = \frac{11}{5}$$

($-1/5, 11/5$)

$$newX_cluster1 = \frac{1+2+2+3+3}{5} = \frac{11}{5}, newY_cluster1 = \frac{-1+-1+0+0+1}{5} = -\frac{1}{5}$$

(11/5, -1/5)

האלגוריתם יעצור בשלב הזה מאחר ואף וקטור לא יזוז בין מרכזים.

3. (6 נקודות) ציינו 3 אלגוריתמים מבין אלו שלמדנו שמסוגלים להתמודד עם קבוצת למידה שלא ניתנת להפרדה ליניארית.

פתרון:

רשת נוירונים, SVM עם קרנל לא ליניארי, KNN

בהצלחה !