


## פתרון

### שאלה 1 (20 נקודות):

נתונה קבוצת האימון הבאה. הוקטורים הינם דו מימדיים, המתחלקים לשתי מחלקות – העיגולים והמשולשים.




א. (10 נקודות) עבור כל אחד מהאלגוריתמים הבאים, ציינו אם הם יכולים להביא לשגיאה 0 (הפרדה מושלמת), ואם כן אז ציירו במחברת הבחינה כיצד יראה המפריד. אם לא, הסבירו בקצרה מדוע לא.

(1) פרספטרון

פתרון: לא יכול להביא לשגיאה 0. הקבוצה בלתי ניתנת להפרדה ליניארית.

(2) KNN עם  $K=1$

פתרון: ניתן להפריד –



ב. (6 נקודות) נתונים הוקטורים הבאים:

1: positive (1,0,0)

2: positive (0,1,0)

3: positive (0,0,1)

4: positive (1,1,0)

negative (1,0,1) :5

negative (1,1,0) :6

negative (1,1,1) :7

הרצנו SVM עם הקרנל  $K(X,Y) = (X \cdot Y + 1)^2$

וקיבלנו

$$\alpha_1=1/2, \alpha_2=1/2, \alpha_3=1/2, \alpha_4=1/2, \alpha_5=1/2, \alpha_6=1/2, \alpha_7=0$$
$$b = 1$$

כיצד יסווג הוקטור (0,0,0)? הראו את כל החישובים.

**פתרון-**

$$\begin{aligned} & \frac{1}{2}[(1,0,0)(0,0,0) + 1]^2 + \frac{1}{2}[(0,1,0)(0,0,0) + 1]^2 + \frac{1}{2}[(0,0,1)(0,0,0) + 1]^2 \\ & + \frac{1}{2}[(1,1,0)(0,0,0) + 1]^2 - \frac{1}{2}[(1,0,1)(0,0,0) + 1]^2 \\ & - \frac{1}{2}[(1,1,0)(0,0,0) + 1]^2 + b = 1 + 1 = 2 > 0 \rightarrow \text{positive} \end{aligned}$$

ג. (4 נקודות) בהנתן קבוצת האימון מהסעיף הקודם (סעיף ב), כיצד יסווג הוקטור (2,0,0) אם


משתמשים ב-KNN, עם  $K=1$  ומטריקת המרחק  $L1$ ?

**פתרון-**

(2,0,0) הכי קרוב ל-(1,0,0) ולכן יסווג כ-positive.


## שאלה 2 (20 נקודות):

בעיית אישכול בעזרת Kmeans – נתונים לנו ווקטורים (העיגולים), המפולגים כמתואר בשלושת השרטוטים הבאים. המרחק בין כל זוג וקטורים שכנים הוא זהה. המשולשים באיור, מייצגים את המיקום ההתחלתי של המרכזים. בכל השרטוטים  $K=2$ .



א. (9 נקודות) עבור כל שרטוט, ציירו את המרכזים והאשכולות בסוף הרצת האלגוריתם. יש לנמק בפירוט כל צעד.

**פתרון -**



ב. (6 נקודות) עבור כל אחד מהמשפטים הבאים, ענו נכון או לא ונמקו מדוע. תשובה ללא נימוק תזוכה רק בחלק קטן מהנקודות.

א. Kmeans תמיד מתכנס לאחר מספר סופי של צעדים.


**פתרון -**

נכון. בכל איטרציה משייכים וקטורים למרכזים עם המרחק הקטן ביותר אליהם ובכך מובטח שהמרחק הממוצע לא יעלה מאיטרציה לאיטרציה.

ב. DBSCAN תמיד יחלק את הוקטורים באופן זהה לחלוקה של Kmeans, הוא רק יעשה את זה מהר יותר.

**פתרון -**

לא נכון. DBSCAN מסוגל לחלק וקטורים בהתייחס לצפיפות שלהם ולא רק לפי חלוקה מרחבית. לדוגמא, המצב הבא יחולק באופן שונה ע"י שני האלגוריתמים.



ג. ככל ש- MinPts גדול יותר ב- DBSCAN, כמות הוקטורים שיוגדרו כ- outliers (רעש) תקטן.

פתרון –

לא נכון. ככל ש- MinPts יגדל, כך כמות ה- cores תרד וכך עשויים יותר וקטורים להשאר כרעש.

ג. (5 נקודות) על מנת למצוא את ה-  $K$  האופטימלי באלגוריתם Kmeans על קבוצה של  $n$  וקטורים, הוצע לנסות בכל פעם  $k$  גדול יותר, כאשר מתחילים ב-  $k=2$ , אח"כ  $k=3$ , וכך הלאה עד  $k=n$ . בכל שלב, מריצים את Kmeans עם ה-  $K$  הרלוונטי, ובסוף בוחרים את ה-  $K$  שהשיג את השגיאה הקטנה ביותר (ממוצע המרחקים של הוקטורים מהמרכזים שלהם). האם הצעה זו נחשבת לטובה? נמקו בפירוק.

פתרון –

הצעה לא טובה. תמיד יבחר  $k=n$  כאופטימלי וזה כמובן לא מייצר אשכול רלוונטי.



**המסלול האקדמי המכללה לסינהל  
בית הספר "מדעי המחשב"**

ת.ז הסטודנט: \_\_\_\_\_

מס' חדר: \_\_\_\_\_ מס' נבחן: \_\_\_\_\_

**מבחן בקורס: למידה חישובית וכריית נתונים**

**קוד נושא: 600089**

**תאריך הבחינה: 07.08.2016 שעה 9:00**

**שנה"ל: תשע"ה סמסטר: ב' מועד: ב'**

**שם המרצה/ים: ד"ר משה בוטמן, ד"ר כפיר בר**

**משך הבחינה: 2.5 שעות**

**מספר חלקים בבחינה: 2**

**הוראות לנבחן:**

- מספר השאלות בשאלון: 12
- יש לענות על כל השאלות.
- משקל כל שאלה: 5
- הבחינה: ללא חומר עזר!
- שימוש במחשבון כיס/פיננסי: לא
- מחברת טיוטה: לא
- יש לבחור את התשובה הנכונה ביותר ולסמן את התשובה בדף הקידוד.
- יש לסמן את התשובה בדף הקידוד בעט שחור או כחול בלבד באופן ברור ומודגש.
- רק דף הקידוד ייבדק!
- יש להחזיר את טופס השאלון!
- אין לסמן את התשובות על גבי השאלון בטוש זוהר (מרקר)!

**\*\*\* חשוב מאוד:**

בדף הקידוד יש לרשום ולקדד את מספר השאלון מימין לשמאל (להוסיף אפסים משמאל במידת הצורך).

יש לרשום את מס' תעודת הזהות במקום המיועד בכתב יד ברור (כולל ספרת הביקורת).

**בהצלחה !!!**

1. עבור אלגוריתם פרספטרון א' (עם ערך סף 0) קיבלנו ש  $TP=80\%$  ו-  $FP=5\%$ . הרצנו אלגוריתם ב' הזהה לאלגו א' עם ערך סף 50. מה צפוי?

1.  $FP$  באלגוריתם ב' גבוה יותר, ואילו  $TP$  נמוך יותר.
2. גם  $FP$  וגם  $TP$  נמוכים יותר באלגוריתם ב'.
3. גם  $FP$  וגם  $TP$  גבוהים יותר באלגוריתם ב'.
4.  $FP$  באלגוריתם ב' נמוך יותר, ואילו  $TP$  גבוה יותר.
5. אין משמעות לערך הסף.

## 2. אלגוריתם ADABOOST

1. בכל איטרציה נותן משקל גדול יותר לדוגמאות שסווגו לא נכון באיטרציה הקודמת.
2. בכל איטרציה נותן משקל קטן יותר לדוגמאות שסווגו לא נכון באיטרציה הקודמת.
3. ההחלטה הסופית מבוצעת ע"י הצבעת רוב בה נותנים לכל אלגוריתם weak hypothesis (שנוצר בכל איטרציה) משקל זהה.
4. צריך שרוב האלגוריתמים weak hypotheses (שנוצרו באיטרציות השונות) יהיו טובים מרנדומלי ואין צורך שכל אלגוריתם בודד יקיים תכונה זו.
5. אף תשובה אינה נכונה.

3. נתונה קבוצת אימון עם  $n$  וקטורים. סטודנט א' ניסה לאמן מסווג SVM עם קרנלים שונים בעזרת קבוצת האימון, ולבסוף הגיע למסקנה שעבודה ללא קרנל משיגה את הביצועים הטובים ביותר. כתוצאה מכך, סטודנט ב' הציע לאמן מסווג פרספטרון עבור אותה קבוצת אימון. מה מהבאים נכון?

1. המסווג של סטודנט א' עדיין יכול להיות טוב יותר, מכיוון ש SVM בעל יכולת הכללה טובה יותר.
2. שני המסווגים יצרו מישור מפריד זהה לחלוטין.
3. פרספטרון בעל יכולת הכללה טובה יותר ולכן תמיד עדיף להשתמש בו על SVM.
4. איכות הסיווג של פרספטרון יורדת ככל שהמימד עולה, ואילו איכות הסיווג של SVM עולה ככל שהמימד עולה. על כן, במימד גבוה תמיד כדאי להשתמש ב- SVM.
5. אף תשובה אינה נכונה.

4. מאמנים מסווג על בעייה מסויימת ומקבלים את המפריד. אח"כ מריצים פעם שנייה את אותו המסווג, כאשר את הוקטור הראשון לוקחים פעם אחת, את הוקטור השני לוקחים פעמיים, את הוקטור השלישי לוקחים שלוש פעמים וכן הלאה. מה מהבאים אינו נכון?

1. עבור SVM ללא קרנל עם Hard Margin, התוצאה בהרצה השנייה תהיה זהה לראשונה.
2. עבור SVM ללא קרנל עם Soft Margin, יתכן והתוצאה בהרצה השנייה תהיה שונה מהתוצאה של ההרצה הראשונה.
3. עבור K-NN עם  $K=1$ , עם משקול מרחקים התוצאה של ההרצה השנייה תהיה זהה לתוצאה של הראשונה.
4. עבור k-NN עם  $K=3$ , ללא משקול מרחקים התוצאה של ההרצה השנייה תמיד תהיה זהה לתוצאה של הראשונה.
5. עבור Naive Bayse יתכן והתוצאה של ההרצה השנייה תהיה שונה מההרצה של התוצאה הראשונה.

5. נתונה קבוצת אימון בגודל  $m$ . הוקטורים בעלי שני מאפיינים בוליאניים (מקבלים 0 או 1)  $f_1$  ו-  $f_2$ , ומתחלקים לשתי מחלקות  $C_1$  ו-  $C_2$ . בהנתן וקטור  $X$ , אילו משתנים אנחנו צריכים לדעת על מנת לסווג אותו בעזרת אלגוריתם Naive Bayes?

1.  $P(C_1)$ ,  $P(f_1=0 | C_1)$ ,  $P(f_2=0 | C_1)$ ,  $P(f_1=0 | C_2)$ ,  $P(f_2=0 | C_2)$

2.  $P(C_1)$ ,  $P(C_2)$ ,  $P(X | C_1)$ ,  $P(X | C_2)$

3.  $P(X)$ ,  $P(C_1)$ ,  $P(C_2)$

4.  $P(C_1, C_2)$ ,  $P(X | C_1, C_2)$

5. אף תשובה אינה נכונה.

6. נתונה בעיה עם 16 מחלקות, ה- InfoGain המקסימלי הוא -

1. 4

2. 8

3. 2

4. 16

5. אי אפשר לדעת.

7. המושג backpropagation מתייחס ל -

1. אלגוריתם לעדכון משקולות ברשת נוירונים.

2. אלגוריתם ללמידה לא מונחית (unsupervised).

3. אלגוריתם לחישוב משוואת ה- SVM.

4. אלגוריתם להערכת ביצועים של רשת נוירונים.

5. אף תשובה אינה נכונה.

8. מה מהבאים נכון לגבי אלגוריתם KNN?

1. אין לו שלב מפורש של למידה.

2. ככל ש-  $K$  גדול יותר, כך השגיאה על קבוצת האימון קטנה יותר.

3. ככל ש-  $K$  קטן יותר, כך השגיאה על קבוצת המבחן תהיה קטנה יותר.

4. המפריד הנוצר תמיד יהיה ליניארי.

5. תמיד כדאי לעבוד עם  $K$  זוגי.

9. מה מהבאים אינו נכון עבור אלגוריתם k-means?

1. התוצאה בהכרח אינה משתנה כאשר משנים את מיקומי המרכזים בשלב האתחול של האלגוריתם.

2. לא תמיד משיג את התוצאה האופטימלית.

3. האלגוריתם תמיד מתכנס.

4. משמש לאישכול.

5. המרכזים הם ממוצעי הערכים של הוקטורים השייכים אליהם.

10. השתמשו באלגוריתם SVM על מנת לפתור את השאלה הבאה.

$$f(x) = \text{SGN}(wx + b)$$

נתון  $w_1=2, w_2=-5, w_3=2, b=1$

סווגו את הדוגמאות הבאות:

א) 1,2,3

ב) 4,3,2

1. א מסווג שלילי ב מסווג שלילי

2. א מסווג חיובי ב מסווג שלילי

3. א מסווג חיובי ב מסווג חיובי

4. א מסווג שלילי ב מסווג חיובי

5. לא ניתן לדעת.

11. באלגוריתם AdaBoost,

השלימו: ככל שהשגיאה של המסווג החלש באיטרציה כלשהי יהיה קרוב ל - 0.5 -

1. כך המשקל של המסווג (ידוע גם כערך אלפא) יהיה קרוב ל - 0

2. כך המשקל של המסווג (ידוע גם כערך אלפא) יהיה קרוב ל - 1

3. כך המשקל של המסווג (ידוע גם כערך אלפא) יהיה קרוב לאינסוף

4. כך המשקל של המסווג (ידוע גם כערך אלפא) יהיה קרוב ל - 0.5

5. לא ניתן לדעת.

12. מה מהבאים מתאר מצב של overfitting?

1. כאשר השגיאה על קבוצת מבחן כלשהי גדולה יותר באופן משמעותי מהשגיאה על קבוצת האימון.

2. כאשר אין שגיאות על קבוצת המבחן.

3. כאשר אין שגיאות על קבוצת האימון.

4. כאשר אי אפשר להפריד ליניארית ובכל זאת משתמשים במפריד ליניארי.

5. כאשר אלגוריתם הלמידה לא מתכנס.