



המסלול האקדמי המכללה לסינהל

בית הספר "מדעי המחשב"

ת.ז. הסטודנט: _____

מס' חדר: _____ מס' נבחן: _____

מבחן בקורס: למידה חישובית וכריית נתונים

קוד נושא: 600089

תאריך הבחינה: 27.7.2017 שעה 16:00

שנה"ל: תשע"ז סמסטר: ב' מועד: א'

שם המרצה/ים: ד"ר משה בוטמן, ד"ר כפיר בר

משך הבחינה: 2.5 שעות

מספר חלקים בבחינה: 2

הוראות לנבחן:

- מספר השאלות בשאלון: 12
- יש לענות על כל השאלות.
- משקל כל שאלה: 5
- הבחינה: ללא חומר עזר!
- שימוש במחשבון כיס/פיננסי: לא
- מחברת טיוטה: לא
- יש לבחור את התשובה הנכונה ביותר ולסמן את התשובה בדף הקידוד.
- יש לסמן את התשובה בדף הקידוד בעט שחור או כחול בלבד באופן ברור ומודגש.
- רק דף הקידוד ייבדק!
- יש להחזיר את טופס השאלון!
- אין לסמן את התשובות על גבי השאלון בטוש זוהר (מרקר)!

*** חשוב מאוד:

בדף הקידוד יש לרשום ולקדד את מספר השאלון מימין לשמאל (להוסיף אפסים משמאל במידת הצורך).

יש לרשום את מס' תעודת הזהות במקום המיועד בכתב יד ברור (כולל ספרת הביקורת).

בהצלחה !!!

1. מה מהבאים הינו הסביר ביותר?

1. הסתברויות $(2/3, 1/3)$ - האנדרופיה 0.05
2. הסתברויות $(1/4, 1/4, 1/4, 1/4)$ - האנדרופיה 1
3. הסתברויות $(2/3, 1/3)$ - האנדרופיה 0.9
4. הסתברויות $(1/4, 1/4, 1/4, 1/4)$ - האנדרופיה 1.3
5. האנדרופיה המקסימאלית של 4 מחלקות קטנה מהאנדרופיה המקסימאלית של 2 מחלקות

2. בחנו ביצועים של שתי מערכות למידה:

מערכת א' -

$$EER = 0.1, AUC = 0.8$$

מערכת ב' -

$$EER = 0.2, AUC = 0.65$$

איזו מערכת עדיפה?

1. מערכת א' לפי שני הקריטריונים
2. מערכת ב' לפי שני הקריטריונים
3. לפי EER - מע' א' עדיפה. לפי AUC - מע' ב' עדיפה
4. לפי EER - מע' ב' עדיפה. לפי AUC - מע' א' עדיפה
5. כדי להחליט צריך לדעת את ה-INFOGAIN

3. KNN - אלו מהבאים אינו נכון

1. אין משמעות לשקלול מרחקים עבור $K=1$
2. הינו אלגוריתם "עצל" (LAZY)
3. כאשר K שווה לגודל קבוצת האימון, ההחלטה תהיה לפי "רוב העולם" בקבוצת האימון.
4. כאשר K שווה לגודל קבוצת האימון, אין משמעות לשקלול מרחקים..
5. עבור בעיית רגרסיה, עם שימוש ב-KNN נבחר את ערך התוצאה לפי ערך התוצאה בווקטור הקרוב ביותר.

4. NAIVE BAYES

נתונה טבלת האימון הבאה:

$x_1 = 2, x_2 = 2, x_3 = 1, x_4 = 2$ Y: Positive
 $x_1 = 1, x_2 = 2, x_3 = 2, x_4 = 2$ Y: Positive
 $x_1 = 1, x_2 = 2, x_3 = 2, x_4 = 1$ Y: Negative
 $x_1 = 2, x_2 = 1, x_3 = 1, x_4 = 2$ Y: Positive
 $x_1 = 2, x_2 = 1, x_3 = 1, x_4 = 2$ Y: Negative

המשתנים אינם תלויים זה בזה.

כיצד יסווג הווקטור $(2,2,2,2)$ עפ"י אלגוריתם נאיב בייס?

1. NEGATIVE
2. יש לבצע החלקה במקרה זה ורק בהינתן פרמטרי החלקה ניתן לפתור.
3. לא ניתן לדעת
4. אותו מרחק מהווקטור השני ("חיובי") והשלישי ("שלילי") ולכן נבחר רנדומלית את הסיווג
5. POSITIVE

5. מטרת שיטת GRADIENT DESCENT

1. שיטה למציאת המאפיינים עם ה-INFO-GAIN הטוב ביותר
2. מציאת הפונקציה שתוביל אותנו לטעות המינימאלית על קבוצת האימון
3. פותרת בעיית ריבוי מחלקות ברשתות נוירונים
4. מכניסה אי לינאריות ברשתות נוירונים
5. שקולה לטריק הקרנל שבאלגוריתם SVM

6. נתונה רשת הנוירונים הבאה:
- כניסה - שלושה מאפיינים $(f1, f2, f3)$
- יציאה - שני נוירונים $(y1, y2)$
- שכבה חבויה עם שני נוירונים
- פונקציית האקטיבציה בשכבה החבויה הינה RELU המוגדרת כך:
- $$f(x) = \max(0, x)$$
- שימו לב - בכיתה עסקנו בפונקציות אקטיבציה שונות כגון SIGMOID, THRESHOLD, SIGN גם RELU הינה פונקציית אקטיבציה המוגדרת לכם היטב.
- פונקציית האקטיבציה בשכבת היציאה - SGN
- משקולות:
- משקולות מסומנים כ- w_{ij_k} - משמעות: המשקולות מהנוירון ה- i בשכבה ה- k לנוירון ה- j בשכבה ה- $k+1$
- למשל w_{21_1} פירושו המשקולות מהנוירון השני בשכבה הראשונה לנוירון הראשון בשכבה השנייה
- $$w_{11_1} = w_{31_1} = -2$$
- $$w_{21_1} = 3$$
- $$w_{11_1} = w_{22_1} = w_{32_1} = w_{11_2} = w_{12_2} = w_{21_2} = w_{22_2} = 1$$

כיצד יסווג הווקטור

$$(f1 = 1, f2 = 1, f3 = 1)$$

1. $y1 = \text{Positive}, y2 = \text{Negative}$
2. $y1 = \text{Negative}, y2 = \text{Positive}$
3. $y1 = \text{Negative}, y2 = \text{Negative}$
4. $y1 = \text{Positive}, y2 = \text{Positive}$
5. לא ניתן לחשב

7. SVM עם קרנל לינארי -
חישבו את W וקיבלנו

$$w = (2, -2, 3)$$

חישבו את b וקיבלנו

$$b = 0$$

אלו מהבאים הגיוני

1. הווקטור $(1, 1, 1)$ הינו support vector חיובי
2. הווקטור $(1, 4, 2)$ הינו support vector שלילי
3. הווקטור $(1, 2, 1)$ הינו support vector חיובי
4. הווקטור $(1, 4, 2)$ הינו support vector חיובי
5. אף תשובה אינה נכונה

8. אלו מהאלגוריתמים הבאים "רגיש" לסדר בו מקבלים את הווקטורים בקבוצת האימון

1. KNN
2. SVM
3. רשת נוירונים
4. NAIVE BAYES
5. עץ החלטה

9. רוצים לחלק קבוצת ווקטורים ל-5 אשכולות.

אלו מהבאים אינן נכון?

1. K-MEANS מתאים לסוג כזה של בעיה
2. אלגוריתם היררכי עשוי להתאים לסוג כזה של בעיה אם נקבע תנאי עצירה לפי מס' אשכולות
3. אלגוריתמים מבוססי צפיפות (למשל DBSCAN) מתאים לסוג כזה של בעיה
4. K-MEANS מתאים לסוג כזה של בעיה ומובטח לנו שיתכנס.
5. K-MEANS מתאים לסוג כזה של בעיה אך יתכן ויוביל אותנו לפתרון לא אופטימאלי

10. אלגוריתם הפרספטרון. מוד אינקרמנטלי. בעיית סיווג במהלך עדכון המשקולות הגענו לווקטור הבא (כולל נורון דמי):

$$(x_0=1, x_1=2, x_2=-2, x_3=2, x_4=3)$$

הווקטור סווג ע"י המנחה כשלילי.

בשלב זה אנו עם סט המשקולות הבא

$$(w_0=1, w_1=-1, w_2=-1, w_3=1, w_4=1)$$

הווקטור מופיע 3 פעמים בקבוצת האימון ברצף

מה יהיה ערך המשקולות לאחר המעבר על שלושת מופעי הווקטור ברצף

1. $(w_0 = 1, w_1 = -1, w_2 = -1, w_3 = 1, w_4 = 1)$

2. $(w_0 = 0, w_1 = -3, w_2 = 1, w_3 = -1, w_4 = -2)$

3. $(w_0 = 3, w_1 = -5, w_2 = 3, w_3 = -3, w_4 = 6)$

4. $(w_0 = 0, w_1 = 1, w_2 = -3, w_3 = -1, w_4 = 4)$

5. $(w_0 = -1, w_1 = -1, w_2 = -1, w_3 = 1, w_4 = 1)$

11. overfitting פירוש

1. התאמת יתר לקבוצת האימון
2. התאמת יתר לקבוצת המבחן
3. יכולת הכללה טובה
4. שיטת אישכול
5. שיטת רגרסיה

12. רוצים לפתור בעיית רגרסיה באמצעות KNN עבור $k=1$ נתונים הווקטורים הבאים והערך לכל אחד מן הווקטורים

$$(x_1=1, x_2 = -1), \text{val} = 3$$

$$(x_1=1, x_2 = -2), \text{val} = 2$$

$$(x_1=2, x_2 = -1), \text{val} = 2$$

$$(x_1=2, x_2 = -2), \text{val} = 4$$

מה יהיה ערכו של הווקטור

$$(x_1 = 0, x_2 = 0)$$

1. 1

2. 2

3. 3

4. 4

5. 5

פתרון

שאלה 1 (20 נקודות):

נתונה טבלת האימון הבאה

(נתונים המאפיינים feature1, feature2, feature3 ויש צורך לחזות את class):

Feature1	Feature2	Feature3	Class
2	1	1	P
1	0	0	P
0	0	1	N
1	2	-3	N
-1	1	2	P
1	1	1	P

(5 נקודות) הרץ/י את אלגוריתם העדכון של הפרספטרון כפי שלמדנו, סיבוב אחד שלם. מוד אינקרמנטלי. ערך כל המשקולות ההתחלתיים: 1 (יש להוסיף נירון דמה עם ערך 1).

פתרון:

נוסיף נירון דמי שמשקלו 1

F0	F1	F2	F3	C	W0	W1	W2	W3	WX	סיווג	?UPDATE
1	2	1	1	P	1	1	1	1	>0	P	NO
1	1	0	0	P	1	1	1	1	>0	P	NO
1	0	0	1	N	1	1	1	1	>0	P	YES
1	1	2	-3	N	0	1	1	0	>0	P	YES
1	-1	1	2	P	-1	0	-1	3	>0	P	NO
1	1	1	1	P	-1	0	-1	3	>0	P	NO

סט המשקולות שהתקבל: (-1,0,-1,3)

(5 נקודות) חשבי את הביצועים (False positive rate, True positive rate) של המסווג שנוצר בסעיף 1 ואת הביצועים של מסווג שמחזיר הכל P, על קבוצת המבחן הבאה:

Feature1	Feature2	Feature3	Class
0	0	0	N
1	2	0	N
2	0	1	P
1	-3	0	N
-1	1	2	P
1	2	1	P

מסווג שנוצר מסעיף א: (כמובן יש להוסיף את נגזרת הדמיה המשקף את המשתנה החופשי במשוואה):

F0	F1	F2	F3	C	W0	W1	W2	W3	WX	סיווג
1	0	0	0	N	-1	0	-1	3	<0	N
1	1	2	0	N	-1	0	-1	3	<0	N
1	2	0	1	P	-1	0	-1	3	>0	P
1	1	-3	0	N	-1	0	-1	3	>0	P
1	-1	1	2	P	-1	0	-1	3	>0	P
1	1	2	1	P	-1	0	-1	3	0	P

בשורה האחרונה יוצא בדיוק 0 כך שמי שכתב N זה גם בסדר. כמובן שאז ה-TP ישתנה בהתאם. ולכן:

$$\%TP = 3/3 = 100\%$$

$$\%FP = 1/3 = 33.333\%$$

מסווג שמחזיר תמיד P

$$\%TP = 3/3 = 100\%$$

$$\%FP = 3/3 = 100\%$$

4 נקודות) נתון מסווג SVM עם $w=(1, 1, 1, b=1)$ (שימו לב שיש להפחית את b במשוואת הסיווג). מי מקבוצת האימון הם ה- support vectors? הראו את החישוב.

ה-SV החיוביים/שליליים הינם הווקטורים שבהצבת הנוסחה $WX-B$ נקבל עליהם ערך של $-1/1$ בהתאמה. כמובן יש להריץ זאת על קבוצת האימון

F1	F2	F3	C	W1	W2	W3	WX-B	?SV
2	1	1	P	1	1	1	3	NO
1	0	0	P	1	1	1	0	NO
0	0	1	N	1	1	1	0	NO
1	2	-3	N	1	1	1	-1	YES
-1	1	2	P	1	1	1	1	YES
1	1	1	P	1	1	1	2	NO

6 נקודות) נתונה קבוצת האימון הדו מימדית הבאה:



יש להפריד בין משולשים לעיגולים. ציירו על גבי האיור (העתיקו אותו למחברת הבחינה) כיצד נראה המפריד (איור סכמטי) של המסווגים הבאים:
א. עץ החלטה עם stamps decision, כלומר עבור כל מימד (מאפיין) ניתן להעביר קו אנכי או אופקי בלבד. שימו לב, אין צורך לבנות את העץ. יש לצייר את הקווים המפרידים על גבי הציור בלבד.

פתרון: כמובן ניתן להציג גם פתרונות אחרים.

הציור שכאן בעצם משקף עץ החלטה שנראה בסגנון:

(נניח ש x_1 הציר האופקי ו- x_2 הציר האנכי)

If $x_1 > T$


If $x_2 < T_2$

Decide "משולש"


Else decide "עיגול"

Else decide "עיגול"

לא היה צורך לכתוב את העץ אלא רק את הציור הבא:



ב. מסווג KNN עם $k=1$ ללא משקול מאפיינים ומרחקים, עם מרחק אוקלידי.



כאן ברור שכשקרובים יותר לעיגול מסווגים כעיגול, אחרת כמשולש

שאלה 2 (20 נקודות):

1. (6 נקודות) שאלה זו מתייחסת ל- AdaBoost. עבור כל אחד מהמשפטים הבאים,

קבעו נכון או לא נכון והסבירו בפירוט.

א. נתון מסווג חלש כלשהו h_t (t מציין את מספר האיטרציה) בעל שגיאה $\varepsilon_t > 0.5$.
על קבוצת האימון. h_t ישתתף במסווג המסכם של AdaBoost עם משקל חיובי.

לא נכון! מסווג עם שגיאה הגדולה מחצי אינו "חוקי" adaboost ולכן כלל לא יכנס למסווג הסופי.

ב. אם נריץ את AdaBoost מספיק איטרציות, הוא תמיד ימצא מסווג חלש עם שגיאה 0 על קבוצת האימון.

לא נכון! אין קשר למס' האיטרציות. למשל כאשר יש ווקטור המופיע פעמיים : פעם אחת כחיובי ופעם אחת מסווג כשלילי. לא נוכל למצוא במקרה זה מסווג "חלש עם שגיאה 0".

ג. אותו מסווג חלש אינו יכול להבחר פעמיים ברציפות, כלומר גם באיטרציה ה: $t+1$

נכון! למדנו שאם נבחר את אותו המסווג פעמיים ברציפות, באיטרציה t ובאיטרציה $t+1$, הטעות של המסווג באיטרציה ה: $t+1$ תהיה בדיוק 50% (כלומר לא יותר טובה מרנדומלי)

2. (8 נקודות) נתונה קבוצת הוקטורים הבאה:

x1	2	2
x2	8	6
x3	6	8
x4	2	4

א. הריצו kmeans עם $k=2$ כאשר המרכזים מתחילים ב- x_1 ו x_3 . הסבירו את כל השלבים והראו את התוצאה הסופית.

פתרון:

צריך לבדוק עבור x_2 ו- x_4 למי הם קרובים יותר: האם ל x_1 או ל- x_3

$$\text{Dist}(x_2, x_1) = (8-2)^2 + (6-2)^2 = 52$$

$$\text{Dist}(x_2, x_3) = (8-6)^2 + (6-8)^2 = 8$$

לכן x_2 ישוייך ל-אשכול של x_3

$$\text{Dist}(x_4, x_1) = (2-2)^2 + (4-2)^2 = 4$$

$$\text{Dist}(x_4, x_3) = (2-6)^2 + (4-8)^2 = 32$$

לכן x_4 ישוייך ל-אשכול של x_1

אשכול 1: x_1, x_4 המרכז הוא: 2,3 (ממוצע הערכים בכל מימד)

אשכול 2: x_2, x_3 המרכז הוא: 7,7

ניתן לראות בבירור (או ע"י חישוב) כי אין עדכונים נוספים ולכן כאן האלגוריתם עוצר.

ב. מה ערך השגיאה הסופי של הריצה?

$$\begin{aligned} \text{Distortion} &= \sum_{i=1}^R (x_i - c_{x_i})^2 \\ &= \text{dist}[(2,2), (2,3)]^2 + \text{dist}[(8,6), (7,7)]^2 + \text{dist}[(6,8), (7,7)]^2 \\ &\quad + \text{dist}[(2,4), (2,3)]^2 = 1 + 2 + 2 + 1 = 6 \end{aligned}$$

(6 נקודות) מה ההבדל בין DBSCAN ל- Kmeans? ניתן להשתמש בדוגמא על מנת להמחיש באיזה מקרים יעבוד טוב יותר כל אחד מהאלגוריתמים.

DBSCAN

לא ניתן לקבוע בעזרתו את מספר האשכולות שיווצרו בסיום הריצה. מתאים להתמודדות עם קבוצות שלא ניתנות להפרדה בעזרת מישורים, אלא קבוצות בעלות צפיפות מספקת.

KMEANS לעומתו, מקבל את מספר האשכולות שיווצרו בסוף, בתחילת הריצה כפרמטר. כמו כן, הוא הינו אלגוריתם המבוסס על חלוקות (partitions) ואינו מתאים לקבוצות שאינן ניתנות לחלוקה בעזרת מישורים.

KMEANS לא תמיד יתכנס לתוצאה האופטימלית.

מי שהראה דוגמא להבדל התוצאות בין ההרצות השונות גם מצויין.