

שאלה 1 (20 נקודות):

נתונה טבלת האימון הבאה

(נתונים המאפיינים feature1, feature2, feature3 ויש צורך לחזות את class):

Feature1	Feature2	Feature3	Class
2	1	1	P
1	0	0	P
0	0	1	N
1	2	-3	N
-1	1	2	P
1	1	1	P

א. (5 נקודות) סווג את הווקטור (1,0,1) באמצעות אלגוריתם KNN עם הפרמטרים הבאים:

$K=1$, ללא משקול מאפיינים, משקול מרחקים של $1/d$, מטריקת מרחק $L1$

פתרון:

F1	F2	F3	Class	Dist from (1,0,1)	
2	1	1	P	$ 2-1 + 1-0 + 1-1 = 2$	
1	0	0	P	$ 1-1 + 0-0 + 0-1 = 1$	
0	0	1	N	$ 0-1 + 0-0 + 1-1 = 1$	
1	2	-3	N	$ 1-1 + 2-0 + 3-1 = 4$	
-1	1	2	P	$ -1-1 + 1-0 + 2-1 = 4$	
1	1	1	P	$ 1-1 + 1-0 + 1-1 = 1$	

ישנם 3 ווקטורים במרחק 1. 2 "חיוביים" ואחד "שלילי". אין טעם לבצע שקלול מרחקים. ברור שנקבל שמשקל החיוביים גדול ממשקל השליליים ולכן נסווג את הדוגמא כחיובית.

ב. (5 נקודות) סווג את הווקטור (1,0,1) עפ"י אלגוריתם Naïve Bayes

פתרון:

$$P("POS" | f1=1, f2=0, f3=1) = \frac{P(f1=1, f2=0, f3=1 | "POS") \times P("POS")}{P(f1=1, f2=0, f3=1)}$$

$$P("NEG" | f1=1, f2=0, f3=1) = \frac{P(f1=1, f2=0, f3=1 | "NEG") \times P("NEG")}{P(f1=1, f2=0, f3=1)}$$

$$P("POS") = \frac{4}{6}, P("NEG") = \frac{2}{6}$$

Assu min g features independency

$$P(f1=1, f2=0, f3=1 | "POS") = P(f1=1 | "POS") \times P(f2=0 | "POS") \times P(f3=1 | "POS")$$

$$= \frac{2}{4} \times \frac{1}{4} \times \frac{2}{4} \times \frac{4}{6} = \frac{1}{2} \times \frac{1}{4} \times \frac{1}{2} \times \frac{2}{3} = \frac{2}{48}$$

$$P(f1=1, f2=0, f3=1 | "NEG") = P(f1=1 | "NEG") \times P(f2=0 | "NEG") \times P(f3=1 | "NEG")$$

$$= \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} \times \frac{2}{6} = \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} \times \frac{1}{3} = \frac{1}{24} = \frac{2}{48}$$

קיבלנו אותה הסתברות לחיובי ושלילי ולכן נבחר לפי "רוב העולם" שהוא חיובי ונסווג את הדוגמא כחיובית.

ג. (5 נקודות) נתון לנו מסווג SVM-LINEAR-HARD-MARGIN. משוואת סיווג – $w \cdot x - b$

הוכח כי לא יתכן שסט המשקולות $w=(1,1,1)$, $b=3$ הינו משוואת הסיווג שמחזיר לנו

SVM לינארי HARD-MARGIN

פתרון:

SVM-LINEAR-HARD-MARGIN חייב לתת פתרון מושלם. כבר בדוגמה השניה ניתן

לראות שעל דוגמא חיובית המכונה חוזה "שלילי".

$$W \cdot x - b = 1 \cdot X_1 + 1 \cdot X_0 + 1 \cdot X_0 - 3 = -2$$

סיבה נוספת: כשמציבים את הדוגמאות השליליות לא מקבלים על אף דוגמה תוצאה 1-.

ז"א יוצא שאף דוגמה אינה Support Vector.

ד. (5 נקודות) נתונה קבוצת האימון הדו מימדית הבאה:

יש להפריד בין ריבועים לעיגולים. ציירו על גבי האיור (העתיקו אותו למחברת הבחינה)

כיצד נראה מפריד ADABOOST המכיל שני פרספטרונים. ציירו ע"ג האיור שני


פרספטרונים, תנו להם שם: P_1, P_2 ורשמו את משוואת ADABOOST המשקללת את

שניהם.

פתרון: נניח ש"ריבוע = שלילי" ו"עיגול = חיובי".


כל ריבוע יקבל 2- (-1 כי מצד שמאל של הקו האדום -1 כי מעל הקו הירוק)

עיגולים יקבלו במינימום 0 ויסווגו כחיובי.



שאלה 2 (20 נקודות):


נתונה קבוצת הווקטורים הבאה:





הצג את כל התוצאות הסופיות האפשריות של KMEANS עבור כל אחד מה-K הבאים.
יש להציג עבור כל תוצאה סופית את בחירת המרכזים הראשונית שהובילה לתוצאה הסופית ותאור קצר של התהליך.

א. (5 נק') $K=1$



פתרון: לא משנה מה הבחירה. כל הווקטורים יצאו באותו אשכול.








ב. (5 נק') $K=2$
פתרון:



ג. (5 נק') $K=3$
פתרון: כל סיבוב אפשרי של הקבוצות הבאות:



ד. (5 נק') $K=4$
פתרון: כל סיבוב אפשרי של הקבוצות הבאות:



בהצלחה !



**המסלול האקדמי המכללה לסינהל
בית הספר "מדעי המחשב"**

ת.ז הסטודנט: _____

מס' חדר: _____ מס' נבחן: _____

מבחן בקורס: למידה חישובית וכריית נתונים

קוד נושא: 600089

תאריך הבחינה: 14.9.2017 שעה 9:00

שנה"ל: תשע"ז סמסטר: ב' מועד: ב'

שם המרצה/ים: ד"ר משה בוטמן, ד"ר כפיר בר

משך הבחינה: 2.5 שעות

מספר חלקים בבחינה: 2

הוראות לנבחן:

- מספר השאלות בשאלון: 12
- יש לענות על כל השאלות.
- משקל כל שאלה: 5
- הבחינה: ללא חומר עזר!
- שימוש במחשבון כיס/פיננסי: לא
- מחברת טיוטה: לא
- יש לבחור את התשובה הנכונה ביותר ולסמן את התשובה בדף הקידוד.
- יש לסמן את התשובה בדף הקידוד בעט שחור או כחול בלבד באופן ברור ומודגש.
- רק דף הקידוד ייבדק!
- יש להחזיר את טופס השאלון!
- אין לסמן את התשובות על גבי השאלון בטוש זוהר (מרקר)!

***** חשוב מאוד:**

בדף הקידוד יש לרשום ולקדד את מספר השאלון מימין לשמאל (להוסיף אפסים משמאל במידת הצורך).

יש לרשום את מס' תעודת הזהות במקום המיועד בכתב יד ברור (כולל ספרת הביקורת).

בהצלחה !!!


1. מהו "טריק הקרנל" ב SVM?

1. הטריק מאפשר הפרדת המופעים במימד גבוה יותר תוך כדי שמירה חישוב מכפלות במימד המקורי
2. טריק הקרנל זהו SVM hard margin
3. מאפשר להוריד את כמות ה support vectors
4. בעזרת טריק הקרנל ניתן לחשב את המסווג בעזרת חלק קטן מהמופעים
5. אף תשובה אינה נכונה

2. בנינו שני מסווגים A, B בעזרת קבוצת אימון, והערכנו את ביצועיהם על קבוצת מבחן. למסווג A יש 0 שגיאות על קבוצת האימון ו 20% שגיאות על קבוצת המבחן. כמו כן למסווג B יש 15% שגיאות על קבוצת האימון ו 3% שגיאות על קבוצת המבחן. מה נכון מבין הטענות הבאות?

1. מסווג A מתאים יותר על המידה (overfitting) לקבוצת האימון
2. מסווג B מתאים יותר על המידה (overfitting) לקבוצת האימון
3. מסווג B הינו מתאים יותר להיות עץ החלטה ואילו מסווג A מתאים יותר להיות SVM
4. מסווג A למד להכליל טוב יותר
5. אף תשובה אינה נכונה

3. עבור קבוצת האימון הנתונה באיור הבא (שתי מחלקות, עיגולים ומרובעים), מחליטים להעריך ביצועי שני מסווגים בעזרת leave one out cross validation.



- מסווג אחד נבנה בעזרת SVM hard margin, ומסווג שני נבנה בעזרת knn עם $k=1$. מה מהבאים נכון?

1. למסווג ה SVM יש אפס שגיאות ולעומת זאת למסווג knn יש 100% שגיאות.
2. למסווג ה SVM יש 100% שגיאות ולעומת זאת למסווג knn יש 0 שגיאות.
3. לשני המסווגים יש אותה כמות שגיאות.
4. לא ניתן להפריד את קבוצת האימון בעזרת SVM hard margin.
5. אף תשובה אינה נכונה.

4. נתונה הטבלה הבאה המתארת קבוצת אימון, כאשר העמודה Class מייצגת את מה שרוצים לחזות.

Feature 1	Feature 2	Class
0	1	1
1	1	0
0	1	1
1	1	0
0	1	1
1	1	0
0	1	1
1	1	0

מה מהבאים נכון?

1. ה - Infogain של feature 1 הוא 1, ה - Infogain של feature 2 הוא 0
2. ה - Infogain של feature 1 הוא 0, ה - Infogain של feature 2 הוא 1
3. ה - Infogain של feature 1 הוא 0.5, ה - Infogain של feature 2 הוא 0
4. ה - Infogain של feature 1 הוא 1, ה - Infogain של feature 2 הוא 0.5
5. ה - Infogain של feature 1 הוא 0.5, ה - Infogain של feature 2 הוא 0.5

5. נתון פרספטרון עם המשקלים הבאים, שנוצרו באמצעות gradient descent, שהורץ עד שלא ראו שיפור בפונקציית השגיאה:

$$\begin{aligned}w_0 &= 1 \\w_1 &= 2 \\w_2 &= -1 \\w_3 &= 0\end{aligned}$$

התייחסו לקבוצת האימון הבאה (כל שורה היא וקטור עם הסיווג שלו):

- 1,1,1,2 סיווג 1
- 1,1,1,2 סיווג 0
- 3,1,1,1 סיווג 1
- 1,1,1,3 סיווג 0

מה מהבאים נכון?

1. הפרספטרון הנ"ל לא נלמד מקבוצת האימון הזו
2. יתכן והפרספטרון הנ"ל נלמד מקבוצת אימון זו
3. אין מספיק נתונים על מנת לענות על השאלה
4. קבוצת הוקטורים הנתונה אינה יכולה להיות קבוצת אימון מאחר ולא ניתנת להפרדה ליניארית
5. הפרספטרון הנ"ל בטוח נלמד מקבוצת האימון הזו

6. מי מהאלגוריתמים הבאים תומך במחלקות מרובות (Multiclass)?

1. Naive Bayes
2. KNN
3. רשת נוירונים
4. פרספטרון
5. כל התשובות נכונות

7. אלגוריתם DBSCAN הינו -

1. אלגוריתם המבצע clustering תוך שימוש בצפיפות הוקטורים
2. אלגוריתם המבצע clustering למספר קבוע של מחלקות
3. אלגוריתם המבצע סיווג (supervised) לפי צפיפות הוקטורים
4. אלגוריתם המבצע boosting
5. אף תשובה אינה נכונה

8. שרטטנו את ה ROC של אלגוריתם למידה כלשהו וקיבלנו שה $EER=0.2$. מה ניתן לומר?

1. מובטח לנו שעל גרף ה ROC ישנה נק' בה מתקיים $TP=0.8$ %
2. בנקודת ה EER מתקיים : $FP=0.8$ %
3. $AUC=0.8$
4. אלגוריתם זה טוב יותר מאלגוריתם למידה אחר עם $EER=0.1$
5. אף תשובה אינה נכונה

9. בשאלה זו התייחסו ל AdaBoost וסמנו את הטענה הנכונה ביותר.

1. מסווגים חלשים שמתווספים באיטרציות מאוחרות נוטים להתייחס יותר למופעים ה"קשים" יותר בקבוצת האימון
2. מסווגים חלשים שמתווספים באיטרציות מאוחרות נוטים להתייחס יותר למופעים ה"קלים" יותר בקבוצת האימון
3. מסווגים חלשים שמתווספים באיטרציות מאוחרות תורמים הכי פחות למסווג המסכם של Adaboost
4. מסווגים חלשים שמתווספים באיטרציות מאוחרות יהיו בעלי אחוז שגיאה גבוה מאלגוריתם רנדומלי
5. אף תשובה אינה נכונה

10. נתונה קבוצת האימון הבאה :

F1	F2	F3	class
0	2	0	P
2	0	2	P
0	0	2	N
1	2	0	N
2	2	1	N

כיצד יסווג הוקטור הבא בעזרת Naive Bayes?

$F1=0$
 $F2=2$
 $F3=1$
(אין לבצע החלקה גם אם יש צורך)

1. N
2. P
3. לא ניתן לקבוע
4. הסתברות שווה לשתי המחלקות, לכן בוחרים ב - P
5. מאחר ויש יותר וקטורים המסווגים N בקבוצת האימון אז מיידית מסווגים כל וקטור חדש ל - N

11. נתונה רשת נוירונים עם 3 שכבות (שכבת כניסה, שכבה חבויה, שכבת יציאה), כאשר בכל שכבה יש 5 נוירונים. מה מהבאים נכון?

1. סה"כ ברשת יש 50 משקלים על הקשתות המחברות בין הנוירונים השונים.
2. סה"כ ברשת יש 15 משקלים על הקשתות המחברות בין הנוירונים השונים.
3. סה"כ ברשת יש 5 משקלים על הקשתות המחברות בין הנוירונים השונים.
4. סה"כ ברשת יש 125 משקלים על הקשתות המחברות בין הנוירונים השונים.
5. סה"כ ברשת יש 500 משקלים על הקשתות המחברות בין הנוירונים השונים.

12. עבור אלגוריתם kmeans, מה מהבאים מקטין את הסיכוי להתכנסות למינימום לוקלי (כלומר לא לתוצאה האופטימלית)?

1. הרצת האלגוריתם מספר פעמים, בכל פעם מאתחלים את המרכזים במקום אחר. בסוף בוחרים את התוצאה שנתנה מינימום distortion
 2. הרצת האלגוריתם N פעמים (N זהו מספר הוקטורים בקבוצה). בכל פעם בוחרים ערך K שונה. בסוף בוחרים את התוצאה שנתנה מינימום distortion
 3. הרצת האלגוריתם N פעמים (N זהו מספר הוקטורים בקבוצה). בכל פעם מורידים את כמות הוקטורים למציאת האשכולות ב - 10%. בסוף בוחרים את התוצאה שנתנה מינימום distortion
 4. אף תשובה אינה נכונה
 5. כל התשובות נכונות
-