

המסלול האקדמי המכללה למינהל
בית הספר מדעי המחשב



ת.ז. הסטודנט: _____

מס' חדר: _____ מס' נבחן: _____

מבחן בקורס: למידה חישובית וכריית נתונים

קוד נושא: 600089

תאריך הבחינה: 18.7.18 שעה 16:00

שנה"ל: תשע"ח סמסטר: ב' מועד: א'

שם המרצה: ד"ר משה בוטמן

שם המתרגל:

משך הבחינה: 2.5 שעות

מספר חלקים בבחינה: 2

הוראות לנבחנים:

- במבחן 2 חלקים:

חלק א' – שאלות פתוחות – 2 שאלות פתוחות (בסה"כ בחלק זה 40 נקודות)

- א. משקל כל שאלה מצוין בגוף השאלה
- ב. יש לענות על כל שאלה **במחברת נפרדת** ולציין בדף שער כל מחברת את כל הפרטים הנדרשים שם
- ג. יש לנמק בפירוק את תשובותיך. על תשובה לא מפורטת יורדו נקודות.

חלק ב' – שאלות ברירה – 12 שאלות ברירה (בסה"כ בחלק זה 60 נקודות)

- א. משקל כל שאלה – 5 נקודות
- ב. יש למלא בכתב יד ברור במקומות המיועדים **בחציו הימני של דף הקידוד** את שם ביה"ס, חדר המבחן, מספר הנבחן, שם הקורס, תאריך הבחינה, שם המרצה, מספר תעודת הזהות (מספר בן תשע ספרות, כולל ספרת ביקורת ועם אפס מקדים באם נדרש) ואת מספר השאלון (המופיע בצידו השמאלי העליון של השאלון)
- ג. ***** חשוב מאוד:**
- ד. **בדף הקידוד יש לרשום ולקדד את מספר השאלון מימין לשמאל (להוסיף אפסים משמאל במידת הצורך).**
- ה. בכל שאלה יש לבחור את התשובה הנכונה ביותר ולסמנה במקום המיועד בצידו השמאלי של דף הקידוד, **בעט שחור או כחול בלבד ובאופן ברור ומודגש**
- ו. אין לסמן את התשובות על גבי דף הקידוד במדגש (מךקר) זוהר!
- ז. רק דף הקידוד ייבדק!

- יש לענות על כל השאלות

- הבחינה ללא כל חומר עזר

- שימוש במחשבון כיס: לא

- יש להחזיר את טופס המבחן

בהצלחה !!!

חלק א' – שאלות פתוחות (40 נקודות)

שאלה פתוחה 1 (24 נקודות)

נתונה טבלת האימון הבאה:

	f1	f2	f3	Class
1	1	4	1	P
2	1	2	3	P
3	0	0	1	P
4	-1	4	0	P
5	1	0	-2	N
6	-1	-1	1	N
7	0	-4	0	N
8	1	0	-3	N

א. (8 נק') מוצע האלגוריתם הבא לפתרון הבעיה:


$$\text{SGN}(0.5 \cdot f_1 - 0.25 f_2 + 5 f_3)$$

חשב את %TP ואת %FP

ב. (8 נק') חשב את $\text{InformationGain}(\text{class}|f_1)$. אין צורך במחשבון. הצג את כל צעדך בפירוט.ג. (8 נק') מה יהיה סיווג הווקטור $(f_1=3, f_2=3, f_3=3)$ עפ"י אלגוריתם KNN. מטריקת מרחק אוקלידית, $K=3$, ללא שקלול מאפיינים. שקלול מרחקים של $1/d$

שאלה פתוחה 2 (16 נקודות)

- א. (8 נקודות) מריצים אלגוריתם KMEANS עבור $K=3$ ונתונים הווקטורים הבאים כמרכזים התחלתיים. כיצד יסתיים אלגוריתם.
 יש להציג את שלבי האלגוריתם בפירוט
 יש צורך להציג פתרון "איכותי". אין צורך לדייק ברמת הווקטור הבודד.



- 2) (8 נקודות) עם בחירת פרמטרים "מוצלחת", כיצד צפוי להסתיים אלגוריתם DBSCAN?

חלק ב' – שאלות ברירה (60 נקודות)

לפניך 12 שאלות ברירה. בכל שאלה עליך לסמן את התשובה הנכונה מבין 5 האפשרויות הרשומות.

שאלה מספר 1:
למניעת overfitting


1. הוספת דוגמאות רבות לקבוצת האימון
2. שימוש באלגוריתמי אשכול ולא באלגוריתם סיווג
3. הפחתה של מס' הדוגמאות לאימון
4. נעדיף שימוש באלגוריתם (פונקציה) מורכב יותר
5. נעדיף להשתמש באלגוריתם פרספטרון על-פני כל האלגוריתמים האחרים שמצאנו.

שאלה מספר 2:

עדכון משקולות זה באלגוריתם ADABOOST

$$e^{-\alpha_t}$$

1. מתאים לעדכון משקולות לדוגמא שסווגה נכון באיטרציה ה- t
2. מתאים לעדכון משקולות לדוגמא שסווגה לא נכון באיטרציה ה- t
3. מתאים הן לעדכון משקולות לדוגמא שסווגה לא נכון באיטרציה ה- t והן לעדכון משקולות לדוגמא שסווגה נכון.
4. אין כלל עדכון משקולות לדוגמאות באלגוריתם ADABOOST
5. מתאים לעדכון משקולות לדוגמא שסווגה נכון באיטרציה ה- t רק אם t האיטרציות האחרונות דוגמא זו סווגה לא נכון


שאלה מספר 3:

נתונים גרפי ה-ROC

1. נעדיף את גרף 1 הן עפ"י מדד ה- EER , והן עפ"י מדד ה- AUC .
2. נעדיף את גרף 2 הן עפ"י מדד ה- EER , והן עפ"י מדד ה- AUC .
3. נעדיף את גרף 1 עפ"י מדד ה- EER , ואת גרף 2 עפ"י מדד ה- AUC .
4. נעדיף את גרף 2 עפ"י מדד ה- EER , ואת גרף 1 עפ"י מדד ה- AUC .
5. מדד ה- EER של כל הגרפים האלו זהה.

שאלה מספר 4:

נתונות תוצאות אלו של סיום אלגוריתם "אישכול"



אלו הן תוצאות אפשריות של אלגוריתמי אישכול שלמדנו.

מהי תוצאה אפשרית של כל אלגוריתם?

הערה: באלגוריתם היררכי הכוונה הינה ל- bottom-up כאשר המרחק בין 2 אשכולות נקבע לפי המרחק בין שני הווקטורים הקרובים ביותר בין האשכולות (ולא עפ"י מרכזי האשכולות)

1. $DBSCAN$ - 3, היררכי, $KMEANS$ - 2
2. $KMEANS$ - 3, $DBSCAN$ - 2, היררכי
3. שלושת התוצאות יכולות להיות סיום של אלגוריתם $KMEANS$ (תנאי התחלה שונים)
4. $DBSCAN$ - 3, $KMEANS$ - 2, היררכי
5. שלושת התוצאות יכולות להיות סיום של אלגוריתם $DBSCAN$ (תנאי התחלה שונים)

שאלה מספר 5:

נתונה טבלת האימון הבאה:

x1	x2	x3	x4	x5	class
2	1	4	1	1	P
2	1	2	1	1	P
1	1	4	1	1	P
2	1	2	2	1	N
2	2	4	2	1	N
1	2	2	2	1	N

לאיזו מהתכונות יש את ה-Info-Gain הגבוה ביותר ומה ערכו?

1. $InfoGain(class/x4) = 1, X4$
2. $InfoGain(class/x4) = 0.5, X4$
3. $InfoGain(class/x3) = 0.5, X3$
4. $InfoGain(class/x3) = 1, X3$
5. אין מספיק נתונים ע"מ לחשב את ה-Info-Gain

שאלה מספר 6:

נתונה טבלת האימון הבאה :

class	x5	x4	x3	x2	x1	מס' דוגמא
P	1	1	4	1	2	1
P	1	1	2	1	2	2
P	1	1	4	1	1	3
N	1	2	2	1	2	4
N	1	2	4	2	2	5
N	1	2	2	2	1	6

הרצנו אלגוריתם SVM-HARD-MARGIN וקיבלנו

$$\alpha_1 = 0.5, \alpha_2 = 0.5, \alpha_6 = 0.5$$

מהו W

(נתוני השאלה אינם תוצאות אמת של אלגוריתם SVM ונועדו רק לצרכי השאלה)

1. $w_1 = 1.5, w_2 = 0, w_3 = 2, w_4 = 0, w_5 = 0.5$
2. $w_1 = 3, w_2 = 0, w_3 = 4, w_4 = 0, w_5 = 1$
3. $w_1 = -1.5, w_2 = 0, w_3 = -2, w_4 = 0, w_5 = -0.5$
4. $w_1 = 2, w_2 = 1, w_3 = 4, w_4 = 1, w_5 = 1$
5. אין מספיק נתונים ע"מ לחשב את ה-Info-Gain

שאלה מספר 7:

קבלת נתונים על עובדים במפעל מסויים. הנתונים הם: שם פרטי ומשפחה, ת.ז., מצב אישי, כתובת, עיר מגורים, האם בעל רכב, האם בעל דירה, רמת השכר במקום העבודה, תאריך תחילת עבודה, מספר נקודות זיכוי בביטוח לאומי, והאם העובד בעלים של בעל חיים או לא.

רוצים לחזות האם לאדם זה יש רכב יוקרה או לא.

אלו מהאלגוריתמים הבאים הינו המתאים ביותר לפתרון בעיה זו

1. *Decision tree*
2. *kmeans*
3. *SVM*
4. *Perceptron*
5. *DBSCAN*

שאלה מספר 8:

אלגוריתם KNN – נתונים לנו 300 ווקטורים המחולקים ל-3 מחלקות. רוצים לסווג ווקטור חדש.

בחר את התשובה הנכונה ביותר.

1. עבור $k=1$ אין משמעות לשקלול מרחקים
2. עבור $k=1$ אין משמעות לשקלול מאפיינים
3. עבור $k=300$ אין משמעות לשקלול מרחקים
4. עבור $k=100$ אין משמעות לשקלול מאפיינים
5. רק אם נשתמש במטריקת מרחק אוקלידית אין משמעות לשקלול מרחקים

שאלה מספר 9:

נתונה טבלת האימון הבאה:

x1	x2	x3	x4	class
-2	-1	1	2	P
1	1	1	1	P
1	1	1	1	P
-1	0	1	0	N
-2	1	1	1	N

כיצד יסווג ע"פי אלגוריתם Naïve-Bayes הווקטור ($x_1=-2, x_2=1, x_3=1, x_4=1$)

1. P
2. N
3. משקל זהה ל-P ול-N
4. אין מספיק נתונים
5. אלגוריתם Naïve-Bayes אינו מתאים לפתרון בעיה מעין זו.

שאלה מספר 10:

נתונה טבלת האימון הבאה:

x1	x2	x3	x4	class
3	5	2	1	P
5	1	1	3	P
2	1	3	0	N
1	2	4	3	P

- מריצים את אלגוריתם העדכון של הפרספטרון. מוסיפים נוירון דמי כפי שלמדנו שערכו $x_0 = 1$. מתחילים עם סט משקולות התחלתי ($w_0 = 2, w_1 = -2, w_2 = 1, w_3 = 1, w_4 = 1$). מה יהיה סט המשקולות לאחר צעד העדכון הראשון שיבוצע ($w_0 = 3, w_1 = 3, w_2 = 2, w_3 = 2, w_4 = 4$) .1
- ($w_0 = 1, w_1 = -4, w_2 = 0, w_3 = -2, w_4 = 1$) .2
- ($w_0 = 1, w_1 = -7, w_2 = 0, w_3 = 0, w_4 = -2$) .3
- ($w_0 = 1, w_1 = 1, w_2 = 0, w_3 = 0, w_4 = -2$) .4
- .5 אין עדכונים. סט משקולות זה פותר את קבוצת האימון.

שאלה מספר 11:

באלו מהאלגוריתמים הבאים יתכן ונקלע למינימום מקומי. בחר את התשובה הנכונה ביותר

.1 פרספטרון ורשתות נוירונים

.2 KNN

.3 פרספטרון - כן. רשת נוירונים - לא

.4 רשת נוירונים - כן. פרספטרון - לא

.5 SVM

שאלה מספר 12:

בעיית סיווג. נתונים טקסטים אותם צריך לסווג כעוסקים בנושא ספורט או לא. נתונים לנו בקבוצת המבחן 100 טקסטים העוסקים בנושא ספורט ו-500 טקסטים שאינם עוסקים בנושא ספורט. מתוך 100 הטקסטים שעוסקים בנושא ספורט – המערכת איתרה נכון 82 ומבין 500 הטקסטים שאינם עוסקים בספורט המערכת צדקה ב-400

.1 $\%TP = 82, \%FP = 20$

.2 $\%TP = 20, \%FP = 82$

.3 $\%TP = 82, \%FP = 80$

.4 $\%TP = 18, \%FP = 80$

.5 $\%TP = 100, \%FP = 80$

--- סוף המבחן ---

המסלול האקדמי המכללה למינהל
בית הספר מדעי המחשב



ת.ז.

הסטודנט:

מס' חדר: _____

מס' נבחן: _____

מבחן בקורס: למידה חישובית וקריית נתונים

קוד נושא: 600089

תאריך הבחינה: 18.7.18 שעה 16:00

שנה"ל: תשע"ח סמסטר: ב' מועד: א'

שם המרצה: ד"ר משה בוטמן

שם המתרגל:

משך הבחינה: 2.5 שעות

מספר חלקים בבחינה: 2

הוראות לנבחנים:

- במבחן 2 חלקים:

חלק א' – שאלות פתוחות – 2 שאלות פתוחות (בסה"כ בחלק זה 40 נקודות)

- משקל כל שאלה מצוין בגוף השאלה
- יש לענות על כל שאלה **במחברת נפרדת** ולציין בדף שער כל מחברת את כל הפרטים הנדרשים שם
- יש לנמק בפירוק את תשובותיך. על תשובה לא מפורטת יורדו נקודות.

חלק ב' – שאלות ברירה – 12 שאלות ברירה (בסה"כ בחלק זה 60 נקודות)

- משקל כל שאלה – 5 נקודות
- יש למלא בכתב יד ברור במקומות המיועדים **בחציו הימני של דף הקידוד** את שם ביה"ס, חדר המבחן, מספר הנבחן, שם הקורס, תאריך הבחינה, שם המרצה, מספר תעודת הזהות (מספר בן תשע ספרות, כולל ספרת ביקורת ועם אפס מקדים באם נדרש) ואת מספר השאלון (המופיע בצידו השמאלי העליון של השאלון)
- *** חשוב מאוד:**
- בדף הקידוד יש לרשום ולקדד את מספר השאלון מימין לשמאל (להוסיף אפסים משמאל במידת הצורך).**
- בכל שאלה יש לבחור את התשובה הנכונה ביותר ולסמנה במקום המיועד בצידו השמאלי של דף הקידוד, **בעט שחור או כחול בלבד ובאופן ברור ומודגש**
- אין לסמן את התשובות על גבי דף הקידוד במדגש (מךר) זוהר!
- רק דף הקידוד ייבדק!

- יש לענות על כל השאלות

- הבחינה ללא כל חומר עזר

- שימוש במחשבון כיס: לא

- יש להחזיר את טופס המבחן

בהצלחה !!!

חלק א' – שאלות פתוחות (40 נקודות)

שאלה פתוחה 1 (24 נקודות)

נתונה טבלת האימון הבאה :

	f1	f2	f3	Class
1	1	4	1	P
2	1	2	3	P
3	0	0	1	P
4	-1	4	0	P
5	1	0	-2	N
6	-1	-1	1	N
7	0	-4	0	N
8	1	0	-3	N

א. (8 נק') מוצע האלגוריתם הבא לפתרון הבעיה :

$$\text{SGN}(0.5 \cdot f1 - 0.25f2 + 5f3)$$

חשב את %TP ואת %FP

פתרון :

יש לחשב את תוצאת האלגוריתם עבור כל אחד מהווקטורים :

	f1	f2	f3	Real class	Predicted class according to the algorithm
1	1	4	1	P	$\text{SGN}(0.5 \times 1 - 0.25 \times 4 + 5 \times 1) = P$
2	1	2	3	P	$\text{SGN}(0.5 \times 1 - 0.25 \times 2 + 5 \times 3) = P$
3	0	0	1	P	$\text{SGN}(0.5 \times 0 - 0.25 \times 0 + 5 \times 1) = P$
4	-1	4	0	P	$\text{SGN}(0.5 \times -1 - 0.25 \times 4 + 5 \times 0) = N$
5	1	0	-2	N	$\text{SGN}(0.5 \times 1 - 0.25 \times 0 + 5 \times -2) = N$
6	-1	-1	1	N	$\text{SGN}(0.5 \times -1 - 0.25 \times -1 + 5 \times 1) = P$
7	0	-4	0	N	$\text{SGN}(0.5 \times 0 - 0.25 \times -4 + 5 \times 0) = P$
8	1	0	-3	N	$\text{SGN}(0.5 \times 1 - 0.25 \times 0 + 5 \times -3) = N$

מתוך 4 ה"חיוביים" חזינו 3 כ"חיוביים" $\%TP = 75\% (3/4)$

מתוך 4 ה"שליליים" חזינו 2 כ"חיוביים" $\%FP = 50\% (2/4)$

ב. (8 נק') חשב את $\text{InformationGain}(\text{class}|\text{f1})$. אין צורך במחשבון. הצג את כל צעדך בפירוט.

$$\begin{aligned}\text{IG}(\text{class} | \text{f1}) &= H(\text{class}) - H(\text{class} | \text{f1}) \\ H(\text{class}) &= 1 \quad (p(P) = 0.5, p(N) = 0.5) \\ H(\text{class} | \text{f1}) &= p(\text{f1} = 0) * H(\text{class} | \text{f1}=0) \\ &\quad + p(\text{f1} = 1) * H(\text{class} | \text{f1}=1) \\ &\quad + p(\text{f1} = -1) * H(\text{class} | \text{f1}=-1) \\ H(\text{class} | \text{f1}=0) &= 1, p(\text{f1} = 0) = 0.25 \\ H(\text{class} | \text{f1}=1) &= 1, p(\text{f1} = 1) = 0.5 \\ H(\text{class} | \text{f1}=-1) &= 1, p(\text{f1} = -1) = 0.25\end{aligned}$$

$$\begin{aligned}H(\text{class} | \text{f1}) &= 1 \\ \text{IG}(\text{class} | \text{f1}) &= H(\text{class}) - H(\text{class} | \text{f1}) = 1 - 1 = 0\end{aligned}$$

פתרון נוסף קביל ללא חישוב מתמטי

ניתן לראות בבירור מהנתונים שעבור כל ערך אפשרי של f1 מקבל (0,1,2) יוצאת הסתברות של 0.5 הן ל-P והן ל-N ולכן ברור שאם התחלנו בהסתברות של חצי/חצי ועבור כל ערך של f1 נשארת לנו הסתברות של חצי/חצי – אזי ברור ש"לא התקדמנו" ברמת הודאות ולכן ה-Infogain הינו 0.

ג. (8 נק') מה יהיה סיווג הווקטור ($\text{f1}=3, \text{f2}=3, \text{f3}=3$) עפ"י אלגוריתם KNN. מטריקת מרחק אוקלידית, $K=3$, ללא שקלול מאפיינים. שקלול מרחקים של $1/d$ פתרון:


ראשית נמצא את שלושת השכנים הקרובים:

	f1	f2	f3	class	מרחק מהווקטור מרחק מהווקטור (3,3,3)
1	1	4	1	P	$\sqrt{(1-3)^2 + (4-3)^2 + (1-3)^2} = \sqrt{9}$
2	1	2	3	P	$\sqrt{(1-3)^2 + (2-3)^2 + (3-3)^2} = \sqrt{5}$
3	0	0	1	P	$\sqrt{(0-3)^2 + (0-3)^2 + (1-3)^2} = \sqrt{22}$
4	-1	4	0	P	$\sqrt{(-1-3)^2 + (4-3)^2 + (0-3)^2} = \sqrt{26}$
5	1	0	-2	N	$\sqrt{(1-3)^2 + (0-3)^2 + (-2-3)^2} = \sqrt{38}$
6	-1	-1	1	N	$\sqrt{(-1-3)^2 + (-1-3)^2 + (1-3)^2} = \sqrt{36}$
7	0	-4	0	N	$\sqrt{(0-3)^2 + (-4-3)^2 + (0-3)^2} = \sqrt{67}$
8	1	0	-3	N	$\sqrt{(1-3)^2 + (0-3)^2 + (-3-3)^2} = \sqrt{49}$

שלושת השכנים הקרובים ביותר הם #2, #1, #3
שלושתם סווגו ע"י המנחה כ-P ולכן גם שקלול מרחקים ישאיר אותנו בסיווג P


שאלה פתוחה 2 (16 נקודות)

א. (8 נקודות) מריצים אלגוריתם KMEANS עבור $K=3$ ונתונים הווקטורים הבאים כמרכזים התחלתיים. כיצד יסתיים אלגוריתם. יש להציג את שלבי האלגוריתם בפירוט




פתרון :


בשלב ראשון שיוך ווקטורים למרכזים :



לאחר מכן תזוזה של המרכזים למרכז האשכול



ולאחר מכן עדוונים קלים. סיום הריצה יראה בערך כך :



(הדגמה יפה באתר <https://www.naftaliharris.com/blog/visualizing-k-means-clustering/>)

(/clustering

2) (8 נקודות) עם בחירת פרמטרים "מוצלחת", כיצד צפוי להסתיים אלגוריתם DBSCAN?

פתרון: בחירת פרמטרים "מוצלחת" עבור DBSCAN פירושה שכל איזור המחובר "בצפיפות" יאושכל כאיזור אחד.

