

מספר חלקים בבחינה: 2

f1	f2	Class
-2	-4	P
-2	0	P
0	2	P
2	2	N
2	-2	N
0	-4	N

[illegible]


1	-2	-4	P	2	-3	1	4	P	N
1	-2	0	P	2	-3	1	8	P	N
1	0	2	P	2	-3	1	4	P	N
1	2	2	N	2	-3	1	-2	N	N
1	2	-2	N	2	-3	1	-6	N	N
1	0	-4	N	2	-3	1	-2	N	N

סט המשקולות לאחר שתי איטרציות :

($w_0 = 2$, $w_1 = -3$, $w_2 = 1$)

ב. (5 נק') צייר בצורה סכמטית את הווקטורים על גבי מערכת צירים וסמן מיהם ה-Support Vectors. נמק תשובתך.

פתרון :



ה-sv support vectors מוקפים בעיגול והם:

ה-SV השליליים - $(-2, -4)$, $(0, 2)$

ה-SV החיוביים - $(2, 2)$, $(0, -4)$

ג. (8 נק') בהתבסס על סעיף ב' מצא את משוואת הסיווג של SVM-HARD-MARGIN.

רמז: זכור/זכרי מה אמור להיות ערך המשוואה על ה-SV

פתרון:

בהתאם ל- support vectors נקבל את מערכת המשוואות הבאה:

נזכור שעבור ווקטורים שהינם Support Vectors כאשר נציב אותם במשוואת הסיווג, נקבל עבור SV חיובי את הערך 1 ועבור SV שלילי את הערך -1

$$-2 \cdot w_1 - 4 \cdot w_2 + b = 1$$

$$0 \cdot w_1 + 2 \cdot w_2 + b = 1$$

$$2 \cdot w_1 + 2 \cdot w_2 + b = -1$$

$$0 \cdot w_1 - 4 \cdot w_2 + b = -1$$

נפתור את מערכת המשוואות ונקבל:

$$w_1 = -1, w_2 = 1/3, b = 1/3$$

שאלה פתוחה 2 (20 נקודות)

נתונים הווקטורים הבאים :

$$V_1 = (2,10), V_2 = (2,5), V_3 = (8,4), V_4 = (5,8), V_5 = (7,5), V_6 = (6,4), V_7 = (1,2), V_8 = (4,9)$$

מטריצה המפרטת את המרחק בריבוע (האוקלידי) בין כל שני ווקטורים נתונה להלן :

	V1	V2	V3	V4	V5	V6	V7	V8
V1	0	25	36	13	50	52	65	5
V2		0	37	18	25	17	10	20
V3			0	25	2	2	53	41
V4				0	13	17	52	2
V5					0	2	45	25
V6						0	29	29
V7							0	58
V8								0

מריצים את אלגוריתם KMEANS עבור $K=3$

המרכזים הראשונים שנבחרו הינם V_1, V_4, V_7

א. (10 נקודות) הריצו איטרציית KMEANS אחת מלאה. יש להראות את כל החישובים ובסופה יש

להציג :

מי האשכולות המתקבלים בתום איטרציה זו, מיהם המרכזים, ציירו דיאגרמה של 10×10 ובצורה

סכמטית ציירו את הווקטורים, האשכולות המתקבלים והמרכזים.

פתרון :

נשייך כל ווקטור למרכז הקרוב אליו ביותר. נשתמש בטבלת המרחקים בריבוע. (נכנה לצורך העניין

את המרחק בריבוע כ-D). ברור שאם המרחק בריבוע יותר גדול אז גם המרחק עצמו יותר גדול.


הווקטור	V1	V2	V3	V4	V5	V6	V7	V8
נימוק	נקודת השיוך, המרחק המינימלי, 0	D(V2,V1)=25 D(V2,V4)=18 D(V2,V7)=10 נבחר את המרחק הקצר ביותר	D(V3,V1)=36 D(V3,V4)=25 D(V3,V7)=53 נבחר את המרחק הקצר ביותר	נקודת השיוך, המרחק המינימלי, 0	D(V5,V1)=50 D(V5,V4)=13 D(V5,V7)=45 נבחר את המרחק הקצר ביותר	D(V6,V1)=52 D(V6,V4)=17 D(V6,V7)=29 נבחר את המרחק הקצר ביותר	נקודת השיוך, המרחק המינימלי, 0	D(V8,V1)=5 D(V8,V4)=2 D(V8,V7)=58 נבחר את המרחק הקצר ביותר
השיוך	V1	V7	V4	V4	V4	V4	V7	V4

האשכולות והמרכזים המתקבלים :

Cluster 1: {V1}. Center = (2,10)

Cluster 2: {V2, V7} Center = $(\frac{2+1}{2}, \frac{5+2}{2}) = (1.5, 3.5)$

Cluster 3: {V3,V4,V5,V6,V8} = $(\frac{8+5+7+6+4}{5}, \frac{4+8+5+4+9}{5}) = (6, 6)$



ב. (10 נקודות) הריצו איטרציות נוספות עד לעצירת האלגוריתם. יש לשרטט כל איטרציה בצורה סכמטית.

סיבוב ב :


ניתן לראות בבירור מהשרטוט כי הווקטור היחיד שישוייך למרכז שונה הוא V8

לכן האשכולות והמרכזים החדשים הינם :

$$\text{Cluster 1: } \{V1, V8\}. \text{ Center} = \left(\frac{2+4}{2}, \frac{9+10}{2}\right) = (3, 9.5)$$

$$\text{Cluster 2: } \{V2, V7\} \text{ Center} = \left(\frac{2+1}{2}, \frac{5+2}{2}\right) = (1.5, 3.5)$$

$$\text{Cluster 3: } \{V3, V4, V5, V6\} = \left(\frac{8+5+7+6}{4}, \frac{4+8+5+4}{4}\right) = (6.5, 5.25)$$




סיבוב ג :

ניתן לראות בבירור מהשרטוט כי הווקטור היחיד שישוייך למרכז שונה הוא V4
לכן האשכולות והמרכזים החדשים הינם :

$$\text{Cluster 1: } \{V1, V8, V4\}. \text{ Center} = \left(\frac{2+4+5}{3}, \frac{9+10+8}{3}\right) = (3.66, 9)$$

$$\text{Cluster 2: } \{V2, V7\} \text{ Center} = \left(\frac{2+1}{2}, \frac{5+2}{2}\right) = (1.5, 3.5)$$

$$\text{Cluster 3: } \{V3, V5, V6\} = \left(\frac{8+7+6}{3}, \frac{4+5+4}{3}\right) = (7, 4.33)$$



בשאלון שלהלן התשובות הנכונות הינן התשובה הראשונה בכל שאלה

חלק ב' – שאלות ברירה (60 נקודות)

לפניך 12 שאלות ברירה. בכל שאלה עליך לסמן את התשובה הנכונה מבין 5 האפשרויות הרשומות.

[Info]

נתון ה-confusion matrix הבא :

		Predicted		
		Class A	Class B	Class C
Actual	Class A	20	2	8
	Class B	10	20	10
	Class C	5	5	20

מהו ה-ACCURACY?

[q1]

0.6

[a]

0.4

[a]

0.2

[a]

1

[a]

0.75

[a]

נתונה טבלת האימון הבאה :

class	x3	x2	x1	מס' דוגמא
P	4	1	2	1
P	2	1	2	2
P	4	1	2	3
N	2	1	2	4
N	4	2	0	5
N	3	4	4	6

אלו מהבאים יסווג בוודאות כ-N עפ"י אלגוריתם KNN

[q2]

$(f1=4, f2=4, f3=4)$, $L1$, $K=3$, עם שקלול מרחקים של $1/d$

[a]

$(f1=3, f2=3, f3=3)$, $L1$, $K=6$, ללא שקלול מרחקים

[a]

אין מספיק נתונים בשאלה

[a]

$K=6, L1, (f1=2, f2=2, f3=2)$, ללא שקלול מרחקים

[a]

$K=1, L1, (f1=2, f2=1, f3=4)$, שקלול מרחקים של $1/d$

[a]

באלו מהאלגוריתמים הבאים שינוי סדר הזנת הדוגמאות בקבוצת האימון עשוי להשפיע על תוצאת האלגוריתם?

[q3]

NEURAL NETWORKS, PERCEPTRON

[a]

SVM-SOFT-MARGIN, DECISION TREE

[a]

NEURAL NETWORKS, MARGIN-SOFT-SVM

[a]

NAÏVE BAYES

[a]

DBSCAN

[a]

נתונה טבלת האימון הבאה :

class	x3	x2	x1	מס' דוגמא
P	4	1	2	1
P	2	2	2	2
P	4	1	2	3
P	2	1	2	4
N	4	2	2	5
N	2	2	1	6
N	4	2	2	7
N	1	1	1	8

מהו המאפיין עם ה-IG הנמוך ביותר $IG(class|x_i)$. אין צורך במחשבון אלא רק בהבנה של IG

[q4]

$x3$

[a]

$x1$

[a]

$x2$

[a]

ל- $x1$ ו- $x3$ אות *INFOGAIN* והוא הנמוך

[a]

ל- x_2 ו- x_3 אות *INFOGAIN* והוא הנמוך
[a]

לפתרון בעיית ה-underflow באלגוריתם NAÏVE BAYES

[q5]

נשתמש בסכום לוגים של ההסתברויות השונות במקום בהכפלת ההסתברויות
[a]

נבצע "החלקה"

[a]

נשתמש גם במכנה $P(X)$ בנוסחת בייס

[a]

נבחר את המאפיין X_i עם ה- $IG(Y|X_i)$ הגבוה ביותר

[a]

נשתמש בפונקציות אקטיבציה לא לינאריות

[a]

אלגוריתם ADABOOST

[q6]

רגיש לווקטורי *outliers* כי מעלה את משקלם של ווקטורי ה- *outliers* עוד ועוד
[a]

רגיש לווקטורי *outliers* כי מוריד את משקלם של ווקטורי ה- *outliers* עוד ועוד
[a]


אינו רגיש לווקטורי *outliers*

[a]

ככל שה- *weak hypothesis* שנבחר יהיה מדויק יותר, משקלו במסווג הסופי יהיה קטן יותר
[a]

בכל איטרציה מובטח לנו שנמצא היפוטזה טובה מרנדומלית
[a]

רשת נוירונים לסיווג – נתונה הרשת הבאה :



שימו לב – שכבת אקטיבציה sigmoid בשכבה האמצעית

$$\text{Sigmoid}(x) = \frac{1}{1+e^{-x}}$$

כיצד יסווג הווקטור שבכניסה (1,1,1,1,1)

[q7]

y3

[a]

y2

[a]

y1

[a]

y1 ו-y3 בהסתברות שווה

[a]

y2 ו-y3 בהסתברות שווה

[a]

מריצים svm-soft-margin על קבוצת ווקטורים שאינם ניתנים להפרדה לינארית

[q8]

אם "מקדם הענישה" C שואף לאין-סוף הרי אנו כמו ב- $SVM\ HARD\ MARGIN$

[a]

אם "מקדם הענישה" C שואף ל-0 הרי אנו כמו ב- $SVM\ HARD\ MARGIN$

[a]

נקבל משוואה לא לינארית המפרידה בין הקבוצות

[a]

יש להשתמש בפונקציות אקטיבציה לא לינאריות

[a]

תלוי בקבוצת הווקטורים

[a]

אלגוריתם SVM-HARD-MARGIN

מס' דוגמא	α	x1	x2	x3	class
1	0	2	1	4	P
2	0	2	2	2	P
3	1	2	1	4	P
4	0	2	1	2	P
5	0.5	2	2	4	N
6	1	1	2	2	N
7	0	2	2	4	N
8	0	1	1	1	N

חשב את W

[q9]

W = (0,-2,0)

[a]

W = (0,0,0)

[a]

W = (1,-2,0)

[a]

W = (1, 2,1)

[a]

W = (2, 2,-1)

[a]

אלגוריתם *NAÏVE BAYES* –
נתונים הווקטורים הבאים :

ווקטור #	$f1$	$f2$	$f3$	class
1	1	1	0	P
2	1	0	0	P
3	0	0	0	N
4	1	0	0	N
5	1	1	0	N
6	0	1	0	P
7	0	0	0	P
8	0	1	0	N

כיצד יסווג הווקטור ($f1 = 1, f2 = 1, f3 = 0$) לפי אלגוריתם Naïve Bayes?

[q10]

אותה הסתברות ל-P ול-N

[a]

P

[a]

N

[a]

יש לבצע "החלקה" (smoothing). תלי בפרמטרי ההחלקה.

[a]

אין מספיק נתונים בשאלה

[a]

מה מבין הבאים **אינו נכון** עבור אלגוריתם SVM?

[q11]

SVM-HARD-MARGIN עשוי להביא למס' היפוטוזות שונות, תלוי בבחירת פרמטרים ראשונית

[a]

SVM-SOFT-MARGIN עשוי להביא למס' היפוטוזות שונות, תלוי בבחירת פרמטרים ראשונית

[a]

אם יש הפרדה לינארית, אזי מובטח לנו ש-SVM-HARD-MARGIN ימצא היפוטזה

[a]

מיפוי למימד גבוה יותר מאפשר לנו למצוא פתרון גם לבעיה לא לינארית (במימד המקורי של הבעיה)

[a]

SVM-HARD-MARGIN מוצא לנו את המפריד עם ה"שוליים" (margin) הגדולים ביותר.

[a]

אלגוריתם DBSCAN

עבור פרמטר של $MinPts = 1$ (כאשר ב- $MinPts$ נספר גם הווקטור עצמו)

[q12]

בסוף תהליך ההרצה, מס' האשכולות תלוי ב- R שבחרנו

[a]

בסוף תהליך ההרצה, כל ווקטור יהיה אשכול. סה"כ בסוף התהליך – מס' האשכולות שווה למס' הווקטורים

[a]

בסוף תהליך ההרצה, כל הווקטורים יהיו אשכול אחד


[a]

בסוף תהליך ההרצה, מס' האשכולות יהיה שווה ללוג של מס' הווקטורים

[a]

בסוף תהליך ההרצה, מס' האשכולות יהיה שווה לחצי מס' הווקטורים

[a]



קוד נושא: 600089

שנה"ל: תשע"ט סמסטר: ב' מועד: א'

משך הבחינה: 2.5 שעות

מספר חלקים בבחינה: 2

חלק א' – שאלות פתוחות (40 נקודות)

נתונה טבלת האימון הבאה לבעיית סיווג:

f1	f2	Class
-2	-4	P
-2	0	P
0	2	P
2	2	N
2	-2	N
0	-4	N

הדוגמאות. יש להוסיף נזירון "דמיי" (f_0) שערכו 1. יש להתחיל מסט משקולות שכולו 1.

(w0=1, w1=1, w2 = 1)

פתרון :

[illegible]


1	-2	-4	P	2	-3	1	4	P	N
1	-2	0	P	2	-3	1	8	P	N
1	0	2	P	2	-3	1	4	P	N
1	2	2	N	2	-3	1	-2	N	N
1	2	-2	N	2	-3	1	-6	N	N
1	0	-4	N	2	-3	1	-2	N	N

סט המשקולות לאחר שתי איטרציות :

($w_0 = 2$, $w_1 = -3$, $w_2 = 1$)

ב. (5 נק') צייר בצורה סכמטית את הווקטורים על גבי מערכת צירים וסמן מיהם ה-Support Vectors. נמק תשובתך.

פתרון :



ה-sv support vectors מוקפים בעיגול והם:

ה-SV השליליים - $(-2, -4)$, $(0, 2)$

ה-SV החיוביים - $(2, 2)$, $(0, -4)$

ג. (8 נק') בהתבסס על סעיף ב' מצא את משוואת הסיווג של SVM-HARD-MARGIN.

רמז: זכור/זכרי מה אמור להיות ערך המשוואה על ה-SV

פתרון:

בהתאם ל- support vectors נקבל את מערכת המשוואות הבאה:

נזכור שעבור ווקטורים שהינם Support Vectors כאשר נציב אותם במשוואת הסיווג, נקבל עבור SV חיובי את הערך 1 ועבור SV שלילי את הערך -1

$$-2 \cdot w_1 - 4 \cdot w_2 + b = 1$$

$$0 \cdot w_1 + 2 \cdot w_2 + b = 1$$

$$2 \cdot w_1 + 2 \cdot w_2 + b = -1$$

$$0 \cdot w_1 - 4 \cdot w_2 + b = -1$$

נפתור את מערכת המשוואות ונקבל:

$$w_1 = -1, w_2 = 1/3, b = 1/3$$

שאלה פתוחה 2 (20 נקודות)

נתונים הווקטורים הבאים :

$$V_1 = (2,10), V_2 = (2,5), V_3 = (8,4), V_4 = (5,8), V_5 = (7,5), V_6 = (6,4), V_7 = (1,2), V_8 = (4,9)$$

מטריצה המפרטת את המרחק בריבוע (האוקלידי) בין כל שני ווקטורים נתונה להלן :

	V1	V2	V3	V4	V5	V6	V7	V8
V1	0	25	36	13	50	52	65	5
V2		0	37	18	25	17	10	20
V3			0	25	2	2	53	41
V4				0	13	17	52	2
V5					0	2	45	25
V6						0	29	29
V7							0	58
V8								0

מריצים את אלגוריתם KMEANS עבור $K=3$

המרכזים הראשונים שנבחרו הינם V_1, V_4, V_7

א. (10 נקודות) הריצו איטרציית KMEANS אחת מלאה. יש להראות את כל החישובים ובסופה יש

להציג :

מי האשכולות המתקבלים בתום איטרציה זו, מיהם המרכזים, ציירו דיאגרמה של 10×10 ובצורה

סכמטית ציירו את הווקטורים, האשכולות המתקבלים והמרכזים.

פתרון :

נשייך כל ווקטור למרכז הקרוב אליו ביותר. נשתמש בטבלת המרחקים בריבוע. (נכנה לצורך העניין

את המרחק בריבוע כ-D). ברור שאם המרחק בריבוע יותר גדול אז גם המרחק עצמו יותר גדול.


הווקטור	V1	V2	V3	V4	V5	V6	V7	V8
נימוק	נקודת השיוך, המרחק המינימלי, 0	D(V2,V1)=25 D(V2,V4)=18 D(V2,V7)=10 נבחר את המרחק הקצר ביותר	D(V3,V1)=36 D(V3,V4)=25 D(V3,V7)=53 נבחר את המרחק הקצר ביותר	נקודת השיוך, המרחק המינימלי, 0	D(V5,V1)=50 D(V5,V4)=13 D(V5,V7)=45 נבחר את המרחק הקצר ביותר	D(V6,V1)=52 D(V6,V4)=17 D(V6,V7)=29 נבחר את המרחק הקצר ביותר	נקודת השיוך, המרחק המינימלי, 0	D(V8,V1)=5 D(V8,V4)=2 D(V8,V7)=58 נבחר את המרחק הקצר ביותר
השיוך	V1	V7	V4	V4	V4	V4	V7	V4

האשכולות והמרכזים המתקבלים :

Cluster 1: {V1}. Center = (2,10)

Cluster 2: {V2, V7} Center = $(\frac{2+1}{2}, \frac{5+2}{2}) = (1.5, 3.5)$

Cluster 3: {V3,V4,V5,V6,V8} = $(\frac{8+5+7+6+4}{5}, \frac{4+8+5+4+9}{5}) = (6, 6)$



ב. (10 נקודות) הריצו איטרציות נוספות עד לעצירת האלגוריתם. יש לשרטט כל איטרציה בצורה סכמטית.

סיבוב ב :


ניתן לראות בבירור מהשרטוט כי הווקטור היחיד שישוייך למרכז שונה הוא V8

לכן האשכולות והמרכזים החדשים הינם :

$$\text{Cluster 1: } \{V1, V8\}. \text{ Center} = \left(\frac{2+4}{2}, \frac{9+10}{2}\right) = (3, 9.5)$$

$$\text{Cluster 2: } \{V2, V7\} \text{ Center} = \left(\frac{2+1}{2}, \frac{5+2}{2}\right) = (1.5, 3.5)$$

$$\text{Cluster 3: } \{V3, V4, V5, V6\} = \left(\frac{8+5+7+6}{4}, \frac{4+8+5+4}{4}\right) = (6.5, 5.25)$$




סיבוב ג :

ניתן לראות בבירור מהשרטוט כי הווקטור היחיד שישוייך למרכז שונה הוא V4
לכן האשכולות והמרכזים החדשים הינם :

$$\text{Cluster 1: } \{V1, V8, V4\}. \text{ Center} = \left(\frac{2+4+5}{3}, \frac{9+10+8}{3}\right) = (3.66, 9)$$

$$\text{Cluster 2: } \{V2, V7\} \text{ Center} = \left(\frac{2+1}{2}, \frac{5+2}{2}\right) = (1.5, 3.5)$$

$$\text{Cluster 3: } \{V3, V5, V6\} = \left(\frac{8+7+6}{3}, \frac{4+5+4}{3}\right) = (7, 4.33)$$



בשאלון שלהלן התשובות הנכונות הינן התשובה הראשונה בכל שאלה

חלק ב' – שאלות ברירה (60 נקודות)

לפניך 12 שאלות ברירה. בכל שאלה עליך לסמן את התשובה הנכונה מבין 5 האפשרויות הרשומות.

[Info]

נתון ה-confusion matrix הבא :

		Predicted		
		Class A	Class B	Class C
Actual	Class A	20	2	8
	Class B	10	20	10
	Class C	5	5	20

מהו ה-ACCURACY?

$$(20+20+20)/100 = 60/100 = 0.6$$

[q1]

0.6

[a]

0.4

[a]

0.2

[a]

1

[a]

0.75

[a]

נתונה טבלת האימון הבאה :

מס' דוגמא	x1	x2	x3	class
1	2	1	4	P
2	2	1	2	P
3	2	1	4	P
4	2	1	2	N
5	0	2	4	N
6	4	4	3	N

מס' דוגמא	x1	x2	x3	class	Dist from (4,4,4)	
1	2	1	4	P	$5 = 2 + 3 + 0$	
2	2	1	2	P	$7 = 2 + 3 + 2$	
3	2	1	4	P	$5 = 2 + 3 + 0$	
4	2	1	2	N	$7 = 2 + 3 + 2$	
5	0	2	4	N	$6 = 4 + 2 + 0$	
6	4	4	3	N	$1 = 0 + 0 + 1$	

אלו מהבאים יסווג **בוודאות** כ-N עפ"י אלגוריתם KNN

[q2]

עם שקלול מרחקים של $1/d$, $K=3$, $L1$, $(f1=4, f2=4, f3=4)$
(שלושת השכנים הקרובים ביותר הם #6, #1, #3.
משקלי ה"חיוביים" הינם

$$1/5 + 1/5 = 2/5$$

משקלי ה"שליליים" הינם

$$1/1 = 1$$

לכן יסווג כשלילי.

[a]

$K=6$, $L1$, $(f1=3, f2=3, f3=3)$, ללא שקלול מרחקים

[a]

אין מספיק נתונים בשאלה

[a]

$K=6$, $L1$, $(f1=2, f2=2, f3=2)$, ללא שקלול מרחקים

[a]

$K=1$, $L1$, $(f1=2, f2=1, f3=4)$, שקלול מרחקים של $1/d$

[a]

באלו מהאלגוריתמים הבאים שינוי סדר הזנת הדוגמאות בקבוצת האימון עשוי להשפיע על תוצאת האלגוריתם?

[q3]

NEURAL NETWORKS, PERCEPTRON

[a]

SVM-SOFT-MARGIN, DECISION TREE

[a]

NEURAL NETWORKS, MARGIN-SOFT-SVM

[a]

NAÏVE BAYES

[a]

DBSCAN

[a]

נתונה טבלת האימון הבאה :

class	x3	x2	x1	מס' דוגמא
P	4	1	2	1
P	2	2	2	2
P	4	1	2	3
P	2	1	2	4
N	4	2	2	5
N	2	2	1	6
N	4	2	2	7
N	1	1	1	8

מהו המאפיין עם ה-IG הנמוך ביותר $IG(class|x_i)$. אין צורך במחשבון אלא רק בהבנה של IG

[q4]

x_3

ניתן לראות בבירור מהטבלה שחוסר הוודאות הגדול ביותר הינו עבור x_3 . לעומת המאפיינים האחרים.

[a]

x_1

[a]

x_2

[a]

ל- x_1 ו- x_3 אות $INFOGAIN$ והוא הנמוך

[a]

ל- x_2 ו- x_3 אות $INFOGAIN$ והוא הנמוך

[a]

לפתרון בעיית ה-underflow באלגוריתם NAÏVE BAYES

[q5]

נשתמש בסכום לוגים של ההסתברויות השונות במקום בהכפלת ההסתברויות

[a]

נבצע "החלקה"

[a]

נשתמש גם במכנה $P(X)$ בנוסחת בייס

[a]

נבחר את המאפיין X_i עם ה- $IG(Y|X_i)$ הגבוה ביותר

[a]

נשתמש בפונקציות אקטיבציה לא לינאריות

[a]

אלגוריתם ADABOOST

[q6]

רגיש לווקטורי *outliers* כי מעלה את משקלם של ווקטורי ה- *outliers* עוד ועוד [a]


רגיש לווקטורי *outliers* כי מוריד את משקלם של ווקטורי ה- *outliers* עוד ועוד [a]

אינו רגיש לווקטורי *outliers* [a]

ככל שה- *weak hypothesis* שנבחר יהיה מדויק יותר, משקלו במסווג הסופי יהיה קטן יותר [a]

בכל איטרציה מובטח לנו שנמצא היפוטזה טובה מרנדומלית [a]

רשת נוירונים לסיווג – נתונה הרשת הבאה :



שימו לב – שכבת אקטיבציה sigmoid בשכבה האמצעית

$$\text{Sigmoid}(x) = \frac{1}{1+e^{-x}}$$

כיצד יסווג הווקטור שבכניסה (1,1,1,1,1)

$$\text{In}(1) = 1 \cdot -1 + 1 \cdot 0 + 1 \cdot 1 = 0$$

$$\text{In}(2) = 1 \cdot -1 + 1 \cdot 0 + 1 \cdot 1 = 0$$

$$\text{In}(3) = 1 \cdot -1 + 1 \cdot 0 + 1 \cdot 1 = 0$$

$$\text{Out}(1) = \text{sigmoid}(0) = \frac{1}{2}$$

$$\text{Out}(1) = \text{sigmoid}(0) = \frac{1}{2}$$

$$\text{Out}(1) = \text{sigmoid}(0) = \frac{1}{2}$$

$$Y(1) = (-1 \cdot \frac{1}{2} + 0 \cdot \frac{1}{2} + 1 \cdot \frac{1}{2}) = 0$$

$$Y(2) = (1 \cdot \frac{1}{2} + 0 \cdot \frac{1}{2}) = \frac{1}{2}$$

$$Y(3) = (1 \cdot \frac{1}{2} + 1 \cdot \frac{1}{2}) = 1$$

Y3 gets the highest value

[a]

y2

[a]

y1

[a]

y1 ו-y3 בהסתברות שווה

[a]

y2 ו-y3 בהסתברות שווה

[a]

מריצים svm-soft-margin על קבוצת ווקטורים שאינם ניתנים להפרדה לינארית

[q8]

אם "מקדם הענישה" C שואף לאין-סוף הרי אנו כמו ב- $SVM\ HARD\ MARGIN$

[a]

אם "מקדם הענישה" C שואף ל-0 הרי אנו כמו ב- $SVM\ HARD\ MARGIN$

[a]

נקבל משוואה לא לינארית המפרידה בין הקבוצות

[a]

יש להשתמש בפונקציות אקטיבציה לא לינאריות

[a]

תלוי בקבוצת הווקטורים

[a]

אלגוריתם SVM-HARD-MARGIN

מס' דוגמא	α	x1	x2	x3	class
1	0	2	1	4	P
2	0	2	2	2	P
3	1	2	1	4	P
4	0	2	1	2	P
5	0.5	2	2	4	N
6	1	1	2	2	N
7	0	2	2	4	N
8	0	1	1	1	N

חשב את W

$$W = \sum \alpha_i y_i x_i = (1 \times 1 \times (2,1,4)) + \left(\frac{1}{2} \times -1 \times (2,2,4)\right) + (1 \times -1 \times (1,2,2))$$
$$= (2,1,4) + (-1,-1,-2) + (-1,-2,-2) = (0,-2,0)$$

[q9]

$W = (0,-2,0)$

[a]

$$W = (0,0,0)$$

[a]

$$W = (1,-2,0)$$

[a]

$$W = (1, 2,1)$$

[a]

$$W = (2, 2,-1)$$

[a]

אלגוריתם *NAÏVE BAYES* –
נתונים הווקטורים הבאים :

# ווקטור	$f1$	$f2$	$f3$	class
1	1	1	0	P
2	1	0	0	P
3	0	0	0	N
4	1	0	0	N
5	1	1	0	N
6	0	1	0	P
7	0	0	0	P
8	0	1	0	N

כיצד יסווג הווקטור ($f1 = 1, f2 = 1, f3 = 0$) לפי אלגוריתם Naïve Bayes?
אותו מספר דוגמאות "חיוביות" ואותו מספר "שליליות" לכן ההסתברות של "מחלקה" לא משפיעה.

$$P(f1=1 | P) * P(f2=1 | P) * P(f1=0 | P) = \frac{1}{2} \times \frac{1}{2} \times 1 = \frac{1}{4}$$

$$P(f1=1 | N) * P(f2=1 | N) * P(f1=0 | N) = \frac{1}{2} \times \frac{1}{2} \times 1 = \frac{1}{4}$$

[q10]

אותה הסתברות ל-P ול-N

[a]

P

[a]

N

[a]

יש לבצע "החלקה" (smoothing). תלי בפרמטרי ההחלקה.

[a]

אין מספיק נתונים בשאלה

[a]

מה מבין הבאים **אינו נכון** עבור אלגוריתם SVM?

[q11]

SVM-HARD-MARGIN עשוי להביא למס' היפוטזות שונות, תלוי בבחירת פרמטרים ראשונית

[a]

SVM-SOFT-MARGIN עשוי להביא למס' היפוטזות שונות, תלוי בבחירת פרמטרים ראשונית

[a]

אם יש הפרדה לינארית, אזי מובטח לנו ש-SVM-HARD-MARGIN ימצא היפוטזה

[a]

מיפוי למימד גבוה יותר מאפשר לנו למצוא פתרון גם לבעיה לא לינארית (במימד המקורי של הבעיה)

[a]

SVM-HARD-MARGIN מוצא לנו את המפריד עם ה"שוליים" (margin) הגדולים ביותר.

[a]

אלגוריתם DBSCAN

עבור פרמטר של $\text{MinPts} = 1$ (כאשר ב-MinPts נספר גם הווקטור עצמו)

[q12]

בסוף תהליך ההרצה, מס' האשכולות תלוי ב- R שבחרנו

כי בסופו של דבר אנו מאחדים את כל הווקטורים ברדיוס R

[a]

בסוף תהליך ההרצה, כל ווקטור יהיה אשכול. סה"כ בסוף התהליך – מס' האשכולות שווה למס' הווקטורים

[a]

בסוף תהליך ההרצה, כל הווקטורים יהיו אשכול אחד

[a]

בסוף תהליך ההרצה, מס' האשכולות יהיה שווה ללוג של מס' הווקטורים

[a]

בסוף תהליך ההרצה, מס' האשכולות יהיה שווה לחצי מס' הווקטורים

[a]