



המסלול האקדמי המכללה למינהל
בית הספר למדעי המחשב

ת.ז. הסטודנט: _____
מס' חדר: _____ מס' נבחן: _____

מבחן בקורס: למידה חישובית וכריית נתונים

קוד קורס: 600089

תאריך הבחינה: 26/09/2019 שעת הבחינה: 16:00

שנה"ל: תשע"ט סמסטר: קיץ מועד: א'

שם המרצה: ד"ר משה בוטמן, ד"ר כפיר בר

משך הבחינה: 2.5 שעות

פתרון

הוראות לנבחנים:

- במבחן 2 חלקים:

חלק א' – 2 שאלות פתוחות (בסה"כ בחלק זה 40 נקודות)

א. משקל כל שאלה 20 נקודות.

ב. יש לנמק בפירוט את תשובותיך.

ג. יש לענות על כל שאלה במחברת נפרדת.

חלק ב' – 12 שאלות רב-ברירה (בסה"כ בחלק זה 60 נקודות)

א. משקל כל שאלה 5 נקודות.

ב. בכל שאלה יש לבחור את התשובה הנכונה ביותר ולסמנה במקום המיועד בצידו

השמאלי של דף הקידוד, **בעט שחור או כחול בלבד ובאופן ברור ומודגש.**

ג. **רק דף הקידוד ייבדק!**

ד. אין לסמן תשובות על דף הקידוד במדגש (מקור) זוהר!

ה. יש למלא בכתב יד ברור במקומות המיועדים בחציו הימני של דף הקידוד את שם

ביה"ס, חדר המבחן, מספר הנבחן, שם הקורס, תאריך הבחינה, שם המרצה, מספר תעודת הזהות (מספר בן תשע ספרות, כולל ספרת ביקורת) ואת מספר השאלון (המופיע בצידו הימני העליון של השאלון).

***** חשוב מאוד:**

בדף הקידוד יש לרשום ולקדד את מספר השאלון מימין לשמאל (להוסיף אפסים

משמאל במידת הצורך).

- הבחינה: ללא חומר עזר!

- שימוש במחשבון כיס: לא

- מחברת טיוטה: לא


- יש להחזיר את שאלון

בהצלחה !!!

חלק א' – שאלות פתוחות (40 נקודות)

שאלה פתוחה 1 (20 נקודות)


נתונה קבוצת האימון הבאה (P = עיגול, N = ריבוע):



א. (5 נקודות) העתק למחברתך את האיור ושרטט את מישור ההפרדה הנוצר ע"י אלגוריתם KNN עבור $K=1$. ללא משקול מרחקים, ללא משקול מאפיינים, מטריקת מרחק $L1$.

פתרון:

לכל נקודה במרחב, נחשב (ניתן לראות בקלות במקרה זה) מי הוא הווקטור הקרוב יותר.




ב. (5 נקודות) העתק למחברתך את האיור ושרטט את מישור ההפרדה הנוצר ע"י אלגוריתם KNN עבור $K=3$. ללא משקול מרחקים, ללא משקול מאפיינים, מטריקת מרחק $L1$.

פתרון:

לכל נקודה במרחב, נחשב (ניתן לראות בקלות במקרה זה) מי הוא שלושת הווקטורים הקרוב יותר ונסווג לפי הרוב.

בשאלה זו, מי שצבע את כל החלק הימני בירוק ואת השמאלי בכחול – יקבל 3 מ-5 נקודות. מי ששם לב ל"איים" הירוקים והכחולים - גם אם לא שרטט אותם במדויק, יקבל את מלוא הנקודות.



ג. (5 נקודות) חשב את $IG(Y|x_1)$. הנח שערכי המאפיינים בדידים ולא רציפים (כלומר x_1 יכול לקבל את הערכים -2 או 2). ניתן להשאיר בפתרון נוסחה עם לוגים.

$$\begin{aligned}
 IG(Y|x_1) &= H(Y) - H(Y|x_1) \\
 H(Y) &= -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{2} = 1 \\
 H(Y|x_1) &= p(x_1 = 2) \times H(Y|x_1 = 2) + p(x_1 = -2) \times H(Y|x_1 = -2) \\
 H(Y|x_1) &= \frac{1}{2} \times H\left(\frac{1}{5}, \frac{4}{5}\right) + \frac{1}{2} \times H\left(\frac{1}{5}, \frac{4}{5}\right) = -\frac{1}{5} \times \log_2 \frac{1}{5} - \frac{4}{5} \times \log_2 \frac{4}{5} \\
 IG(Y|x_1) &= 1 + \frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5}
 \end{aligned}$$

ד. (5 נקודות) הרץ את אלגוריתם הפרספטרון איטרציה אחת (כלומר מעבר אחד על כל הדוגמאות), מוד אינקרמנטלי, מוד סיווג. התחל/י מסט משקולות שכולו 1 (גם נורון הדמי). הרץ את הדוגמאות על פי הסדר מהשורה העליונה לתחתונה כאשר בכל שורה בחר/י את הדוגמא השמאלית ראשונה.


f0	f1	f2	class	w0	w1	w2	pred	Update?	
1	-2	4	P	1	1	1	$1*1+2*1+4*1>0$, P	N	
1	2	4	N	1	1	1	$1*1+2*1+4*1>0$, P	Y	
1	-2	2	P	0	-1	-3	$1*0+2*-1+2*-3<0$, N	Y	
1	2	2	N	1	-3	-1	$1*1+2*-3+2*-1<0$, N	N	
1	-2	0	N	1	-3	-1	$1*1+2*-3+0*-1>0$, P	Y	
1	2	0	P	0	-1	-1	$1*0+2*-1+0*-1<0$, N	Y	
1	-2	-2	P	1	1	-1	$1*1+2*1+2*-1>0$, P	N	
1	2	-2	N	1	1	-1	$1*1+2*1+2*-1>0$, P	Y	

1	-2	-4	P	0	-1	1	$1*0+-2*-1+-4*1<0, N$	Y	
1	2	-4	N	1	-3	-3			

מי שלא עדכן שורה אחרונה זה בסדר וגם מי שעידכן שורה אחרונה זה בסדר

שאלה פתוחה 2 (20 נקודות)

נתונים הווקטורים הבאים:




א. (10 נקודות) מריצים את אלגוריתם KMEANS עבור $K=2$, הצג את האפשרויות השונות בהן יסתיים אלגוריתם KMEANS. עבור כל תוצאה אפשרית, יש להציג את כל השלבים החל מבחירת המרכזים הראשונית ולפרט ולהציג את האיטרציות השונות (עדכון מרכזים, עדכון אשכולות). יש להתחיל מווקטורים קיימים כתנאי התחלה. מרכזי אשכול תוך כדי התהליך אינם חייבים להיות ווקטורים מהקבוצה.

פתרון: בשאלה זו שתי אופציות לסיום האלגוריתם. מי שנתן פתרון אחד מתוך השניים יקבל את מלוא הנקודות.


יחד עם זאת, פתרון המסתיים בצורה שאינה תקפה לסיום KMEANS יוריד נקודות.

אפשרות א

כל איור מציג איטרציה בריצת האלגוריתם החל מבחירת מרכזים (איור שמאלי עליון), כאשר האיור האחרון מציג את התוצאה הסופית של הריצה.



אפשרות ב




כמובן שכל "סיבוב" של הפתרון הינו "חוקי"

ב. **(10 נקודות)** מריצים את אלגוריתם KMEANS עבור $K=3$, הצג את האפשרויות השונות בהן יסתיים אלגוריתם KMEANS. עבור כל תוצאה אפשרית, יש להציג את כל השלבים החל מבחירת המרכזים הראשונית ולפרט ולהציג את האיטרציות השונות (עדכון מרכזים, עדכון אשכולות). יש להתחיל מווקטורים קיימים כתנאי התחלה. מרכזי אשכול תוך כדי התהליך אינם חייבים להיות ווקטורים מהקבוצה.


פתרון: בשאלה זו שתי אופציות לסיום האלגוריתם. מי שנתן פתרון אחד מתוך השניים יקבל את מלוא הנקודות.


יחד עם זאת, פתרון המסתיים בצורה שאינה תקפה לסיום KMEANS יוריד נקודות.

פתרון: אפשרות א'



אפשרות ב'





כמוכן שכל "סיבוב" של הפתרון הינו "חוקי"

חלק ב' – שאלות ברירה (60 נקודות)

לפניך 12 שאלות ברירה. בכל שאלה עליך לסמן את התשובה הנכונה מבין 5 האפשרויות הרשומות.


פתרון:

תמיד התשובה הראשונה הינה הנכונה.

בשאלה 3 – אלגוריתם ש"אינו יציב" נקבל ("מחמת הספק") גם את פתרון DBSCAN

[Info]

האיור הבא מתאר 3 עקומות רגרסיה המותאמות לאותה קבוצת אימון. התייחסו לעקומות האלה, וסמנו את התשובה הנכונה ביותר.



[q1]

הסבר: התשובה נובעת מהגדרת המונחים underfitting ו- overfitting.

איור a מתאר מצב של underfitting, איור c מתאר מצב של overfitting

[a]

מודל c יתן לנו הכללה טובה יותר מאשר מודל b

[a]

איור b מתאר variance גבוה מאחר וזה פולינום

[a]

איור a מתאר מצב של underfitting, איור b מתאר מצב של overfitting

[a]

איור c מתאר רגרסיה ליניארית טיפוסית, ולכן הוא מתאר מצב של underfitting

[a]

נתונה טבלת האימון הבאה:

class	x3	x2	x1	מס' דוגמא
P	1	1	2	1
P	1	1	2	2
P	1	1	2	3
N	2	1	3	4

5	0	1	4	N
6	4	4	3	N

מה מהבאים נכון?

הסבר: ניתן לראות שעבור x_3 יש לנו וודאות מוחלטת עבור כל ערך אפשרי שיכול לקבל

[q2]

$$H(\text{class} | x_3) = 0$$

[a]

האנטרופיה של class היא 0.3

[a]

הפריור (Prior) של קבוצת האימון הנ"ל הינו 0.45

[a]

$$H(\text{class} | x_1) = H(\text{class} | x_2)$$

[a]

$$H(\text{class} | x_3) = H(\text{class})$$

[a]

איזה מהאלגוריתמים הבאים "אינו יציב"?

הסבר: הגדרת היציבות – הסדר בה ניתנים הוקטורים לאימון משפיע על תוצאת האימון.

[q3]

פרספטרון, עם פונקציית Sigmoid במקום פונקציית ה – sign.

[a]

אלגוריתם Soft Margin ,SVM

[a]

אלגוריתם KNN עם $K=2$

[a]

NAÏVE BAYES

[a]

DBSCAN

[a]

נתונה טבלת האימון הבאה:

class	x3	x2	x1	מס' דוגמא
P	4	1	2	1
P	2	2	2	2
P	4	1	2	3
P	2	1	2	4
N	4	2	2	5
N	2	2	1	6
N	4	2	2	7

	8	1	1	N

$$P(x_1=2|P)*P(x_2=1|P)*P(x_3=4|P)*P(P)=1 \times \frac{3}{4} \times \frac{1}{2} \times \frac{1}{2} = \frac{3}{16}$$

$$P(x_1=2|N)*P(x_2=1|N)*P(x_3=4|N)*P(N)=\frac{1}{2} \times \frac{3}{4} \times \frac{1}{2} \times \frac{1}{2} = \frac{3}{32}$$

כיצד יסווג הוקטור (2,1,4) בעזרת Naïve Bayes?

[q4]

P

[a]

N

[a]

ללא החלקה P, אבל עם החלקה N

[a]

ללא החלקה N, אבל עם החלקה P

[a]

לא ניתן לקבוע

[a]

בחרו את הסעיף המציין את שמו של אלגוריתם למידה, וחסרונו כלשהו המזוהה איתו

הסבר: נובע מהגדרת האלגוריתם KNN

[q5]

KNN – זמן ריצה ארוך בשלב החיזוי

[a]

פרספטרון – זמן ריצה ארוך בשלב האימון

[a]

SVM – בדרך כלל נוטה ל - Overfitting

[a]

עץ החלטה – לא עובד על מאפיינים המכילים ערכים קטגוריים

[a]

Kmeans – לא יציב

[a]

מה הבאים נכון ב - Ensemble Learning?

הסבר: אחרת יתכן מצב בו כל המסווגים הם אותו דבקר ולמעשה לא עשינו הרבה.

[q6]

המודלים המשתתפים צריכים להיות שונים אחד מהשני

[a]

קבוצת האימון תסודר מחדש (shuffled) לפי כל איטרציה

[a]

תמיד נעדיף מניפולציה על המאפיינים מאשר מניפולציה על הדוגמאות

[a]

אי אפשר להשתמש במסווגים הסתברותיים

[a]

ניתן להפעיל Ensemble Learning רק על בעיות בינאריות (בעלות שתי מחלקות)

[a]

נתונה קבוצת אימון עם שתי מחלקות. אימנו מסווג SVM עם משוואת סיווג:

$$f(x) = \text{sign}(xw + b)$$

כעת משנים כל וקטור x בקבוצת האימון, ומוסיפים לו ערך קבוע c . כלומר: $x_i' = x_i + c$

ומאמנים מסווג SVM מחדש על קבוצת האימון המעודכנת. מה סביר שיקרה?

הסבר: תוספת קבוע לכל הוקטורים למעשה מזיזה את כל הדטה לאזור אחר של המרחב. לכן רק ערך ה- bias ישתנה.

[q7]

ערך ה- b ישתנה

[a]

ערכי ה- w יהיו שונים

[a]

לא יהיה שינוי מאחר והוספת קבוע לא משנה את המגמה של הנתונים

[a]

לא ניתן לדעת

[a]

ערכי w ו- b בהכרח יהיו שונים לחלוטין

[a]

נתונה קבוצת אימון שאינה ניתנת להפרדה ליניארית. מה מהאלגוריתמים הבאים לא בטוח יעצור בשלב האימון?

הסבר: לפי משפט הפרספטרון, רק אם הדטה ניתן להפרדה ליניארית מובטח שהוא יעצור.

[q8]

אלגוריתם פרספטרון

[a]

אלגוריתם SVM soft margin עם מקדם הענישה $C=10$

[a]

אלגוריתם Naïve Bayse

[a]

אלגוריתם KNN


[a]

אף תשובה אינה נכונה

[a]

נתונות קבוצות האימון הבאות, עם המסווגים שהותאמו להן:

א



ב



מה מהבאים יכול להיות?

הסבר: קרנל לא ליניארי מאפשר ליצור כל עקומה לא ליניארית

[q9]

שני האיורים מתאימים ל SVM עם קרנל לא ליניארי

[a]

איור ב מתאים ל SVM עם קרנל לא ליניארי, בעוד שאיור א מתאים לפרספטון

[a]

איור א מתאים ל KNN, בעוד שאיור ב מתאים ל SVM ללא קרנל

[a]

איור א מתאים ל SVM ללא קרנל, בעוד שאיור ב מתאים ל KNN

[a]

איור א מתאים לרשת נוירונים עם שכבה אחת, בעוד שאיור ב מתאים לפרספטון

[a]

מה מהבאים נכון עבור אלגוריתם Adaboost?

הסבר: נובע מהגדרת האלגוריתם.

[q10]

ככל שערך α גדול יותר, כך h_i מדויק יותר. כמו כן, α לעולם אינו שלילי

[a]

ככל שערך α גדול יותר, כך h_i פחות מדויק. כמו כן, α שלילי עבור מסווגים עם שגיאה של 0.5

[a]

ככל שערך α קטן יותר, כך h_{i+1} פחות מדויק. כמו כן, D_i יכול להכיל ערכים שליליים

[a]

ככל שערך α קטן יותר, כך h_i מדויק יותר. כמו כן, α לעולם אינו שלילי

[a]

אף תשובה אינה נכונה

[a]

התייחסו לקרנל ב – SVM וסמנו את התשובה הנכונה ביותר

הסבר: נובע מהגדרת הקרנל ב – SVM

[q11]

הקרנל מאפשר מיפוי של הוקטורים במימד גבוה, תוך ביצוע ההכפלה עצמה במימד נמוך

[a]

הקרנל מאפשר העלאת מימד רק לוקטורים מסוימים מתוך קבוצת האימון

[a]

רק אם משתמשים בקרנל לא ליניארי, SVM יכול להתכנס אם קבוצת האימון אינה ניתנת להפרדה ליניארית

[a]

הקרנל מאפשר סיווג בקבוצות אימון עם יותר משתי מחלקות

[a]

במידה וקבוצת האימון ניתנת להפרדה ליניארית, שימוש בקרנל לא ליניארי יגרום ל SVM לא להתכנס

[a]

נתונה קבוצת אימון עם שתי מחלקות. אנו מעוניינים לזהות חריגים (Outliers) עוד לפני אימון מסוג כלשהו. מה מהבאים הכי נכון לנסות?

הסבר: DBSCAN מאפשר זיהוי חריגים out of context בדטה (מסומנים כ – noise).

[q12]

נשתמש ב – DBSCAN ונסמן וקטורי רעש להיות החריגים

[a]

נריץ Kmeans עם $K=1$, ונסמן וקטורים שלא משתייכים לאשכול היחיד שנמצא, בתור חריגים

[a]

נריץ אשכול היררכי עד שנגיע לאשכול אחד. וקטורים שלא חוברו לאשכול, יסומנו כחריגים

[a]

נריץ DBSCAN ונסמן בתור חריגים את הוקטורים ששויכו לאשכול כלשהו

[a]

נריץ עץ החלטה של רמה אחת, ונסמן כחריגים את כל הוקטורים שהעץ מסווג כטעות

[a]