

אלגוריתם SVM:  
נתונה קבוצת האימון הבאה:

| f1 | f2 | Label |
|----|----|-------|
| 0  | 0  | P     |
| 1  | 2  | N     |
| 2  | 2  | N     |
| 3  | 2  | N     |
| 4  | 2  | N     |

הרצנו אלגוריתם SVM לינארי Hard Margin וקיבלנו:  
 $\alpha_1=0.4, \alpha_2=0.4, \alpha_3=0, \alpha_4=0, \alpha_5=0$

חשב את  $b$  במשוואת הסיווג  $SGN(WX - b)$

$$W = \sum \alpha_i y_i x_i =$$

$$\frac{4}{10} \times (+1) \times (0,0) + \frac{4}{10} \times (-1) \times (1,2) = (0,0) - \left(\frac{4}{10}, \frac{8}{10}\right) = \left(-\frac{4}{10}, -\frac{8}{10}\right)$$

ידוע שאם נציב SV חיובי נקבל 1

$$wx - b = \left(-\frac{4}{10}, -\frac{8}{10}\right) \begin{pmatrix} 0 \\ 0 \end{pmatrix} = 0 - b = 1 \rightarrow b = -1$$

מתקבל גם כשנציב SV שלילי (שם מקבלים -1)

אלגוריתם SVM:  
נתונה קבוצת האימון הבאה:

| f1 | f2 | Label |
|----|----|-------|
| 0  | 0  | P     |
| 3  | 1  | N     |
| 3  | 2  | N     |
| 3  | 3  | N     |

הרצנו אלגוריתם SVM לינארי Hard Margin וקיבלנו:  
 $\alpha_1 = 0.2, \alpha_2 = 0.2, \alpha_3 = 0, \alpha_4 = 0$

חשב את  $b$  במשוואת הסיווג  $SGN(WX - b)$

$$W = \sum \alpha_i y_i x_i =$$

$$\frac{2}{10} \times (+1) \times (0,0) + \frac{2}{10} \times (-1) \times (3,1) = (0,0) - \left(\frac{3}{10}, \frac{1}{10}\right) = \left(-\frac{3}{10}, -\frac{1}{10}\right)$$

ידוע שאם נציב SV חיובי נקבל 1

$$wx - b = \left(-\frac{3}{10}, -\frac{1}{10}\right) \begin{pmatrix} 0 \\ 0 \end{pmatrix} = 0 - b = 1 \rightarrow b = -1$$

מתקבל גם כשנציב SV שלילי (שם מקבלים -1)

אלגוריתם SVM:  
נתונה קבוצת האימון הבאה:

| f1 | f2 | Label |
|----|----|-------|
| 0  | 0  | P     |
| 0  | 2  | N     |
| 1  | 2  | N     |
| 2  | 2  | N     |
| 3  | 2  | N     |

הרצנו אלגוריתם SVM לינארי Hard Margin וקיבלנו:  
 $\alpha_1 = \frac{1}{2}, \alpha_2 = \frac{1}{2}, \alpha_3 = 0, \alpha_4 = 0, \alpha_5 = 0$

חשב את  $b$  במשוואת הסיווג  $SGN(WX - b)$

$$W = \sum \alpha_i y_i x_i =$$

$$\frac{1}{2} \times (+1) \times (0,0) + \frac{1}{2} \times (-1) \times (0,2) = (0,0) - (0,1) = (0,-1)$$

ידוע שאם נציב SV חיובי נקבל 1

$$wx - b = (0,-1) \begin{pmatrix} 0 \\ 0 \end{pmatrix} = 0 - b = 1 \rightarrow b = -1$$

מתקבל גם כשנציב SV שלילי (שם מקבלים -1)

נתונים הווקטורים הבאים:


$[-1, -1], [0, 0], [2, 2], [1, 1], [3, 3], [4, 4], [5, 5], [5, 3], [-1, 0], [5, 4], [-1, 1]$

נדרש לאשכל אותם עבור  $k=2$  עם אלגוריתם K-MEANS

נתונים המרכזים ההתחלתיים הבאים:


$(-1, 1), (5, 4)$

בסיום ריצת האלגוריתם, מה יהיו המרכזים שיתקבלו?



Cluster 1:  $(-1, 1), (-1, 0), (-1, -1), (0, 0), (1, 1), (2, 2)$

Cluster 2:  $(5, 3), (5, 4), (5, 5), (4, 4), (3, 3)$



$$\text{Center1-X} = (-1 + -1 + -1 + 0 + 1 + 2) / 6 = 0$$

$$\text{Center1-Y} = (1 + 0 + -1 + 0 + 1 + 2) / 6 = 0.5$$

$$\text{Center2-X} = (5 + 5 + 5 + 4 + 3) / 5 = 4.4$$

$$\text{Center2-Y} = (3 + 4 + 5 + 4 + 3) / 5 = 3.8$$

נתונים הווקטורים הבאים:


$[-1, -1], [0, 0], [2, 2], [1, 1], [3, 3], [4, 4], [5, 5], [5, 3], [-1, 0], [5, 4], [-1, 1]$

נדרש לאשכל אותם עבור  $k=2$  עם אלגוריתם K-MEANS

נתונים המרכזים ההתחלתיים הבאים:


$(-1, 1), (5, 5)$

בסיום ריצת האלגוריתם, מה יהיו המרכזים שיתקבלו?



Cluster 1:  $(-1, 1), (-1, 0), (-1, -1), (0, 0), (1, 1), (2, 2)$

Cluster 2:  $(5, 3), (5, 4), (5, 5), (4, 4), (3, 3)$



$$\text{Center1-X} = (-1 + -1 + -1 + 0 + 1 + 2) / 6 = 0$$

$$\text{Center1-Y} = (1 + 0 + -1 + 0 + 1 + 2) / 6 = 0.5$$

$$\text{Center2-X} = (5 + 5 + 5 + 4 + 3) / 5 = 4.4$$

$$\text{Center2-Y} = (3 + 4 + 5 + 4 + 3) / 5 = 3.8$$

נתונים הווקטורים הבאים:


$[-1, -1], [0, 0], [2, 2], [1, 1], [3, 3], [4, 4], [5, 5], [5, 3], [-1, 0], [5, 4], [-1, 1]$

נדרש לאשכל אותם עבור  $k=2$  עם אלגוריתם K-MEANS

נתונים המרכזים ההתחלתיים הבאים:


$(0,0), (3,3)$

בסיום ריצת האלגוריתם, מה יהיו המרכזים שיתקבלו?



Cluster 1:  $(-1,1), (-1,0), (-1,-1), (0,0), (1,1)$

Cluster 2:  $(5,3), (5,4), (5,5), (4,4), (3,3), (2,2)$



$$\text{Center1-X} = (-1 + -1 + -1 + 0 + 1) / 5 = -0.4$$

$$\text{Center1-Y} = (1 + 0 + -1 + 0 + 1) / 5 = 0.2$$

$$\text{Center2-X} = (5 + 5 + 5 + 4 + 3 + 2) / 6 = 4$$

$$\text{Center2-Y} = (3 + 4 + 5 + 4 + 3 + 2) / 6 = 3.5$$

(נתונים המאפיינים feature1, feature2, feature3 ויש צורך לחזות את class):

| Feature1 | Feature2 | Feature3 | Class |
|----------|----------|----------|-------|
| 0        | 1        | 1        | P     |
| 1        | 0        | 0        | P     |
| 0        | 0        | 1        | N     |
| 1        | 1        | 0        | N     |
| 0        | 1        | 2        | P     |
| 1        | 1        | 1        | P     |

בניח שאנו משנים את האלגוריתם העדכון של הפרספטרון ע"פ הנוסחה הבאה:

If current example  $(x_i, y_i)$  is correctly classified, don't change

If wrongly classified as 1,  $w \leftarrow w - 2x_i$

If wrongly classified as -1,  $w \leftarrow w + x_i$

פתור את הבעיה באמצעות אלגוריתם זה. עבוד במוד INCREMENTAL, כלומר, עדכון מבוצע לאחר כל דוגמא (אם יש צורך). התחילו עם קבוצת משקולות בה כל המשקולות שווים 0.5 והזן את הדוגמאות לאלגוריתם ע"פ סדר הופעתן בטבלה. מהן המשקולות שהתקבלו אחרי סיבוב עדכון אחד, כלומר, מעבר על כל הדוגמאות פעם אחת. יש להוסיף נירון דמי שערכו 1 עבור כל הווקטורים כפי שלמדנו

| f0 | f1 | f2 | f3 | w0   | w1  | w2  | w3   | class | Prediction |
|----|----|----|----|------|-----|-----|------|-------|------------|
| 1  | 0  | 1  | 1  | 0.5  | 0.5 | 0.5 | 0.5  | P     | P          |
| 1  | 1  | 0  | 0  | 0.5  | 0.5 | 0.5 | 0.5  | P     | P          |
| 1  | 0  | 0  | 1  | 0.5  | 0.5 | 0.5 | 0.5  | N     | P          |
| 1  | 1  | 1  | 0  | -1.5 | 0.5 | 0.5 | -1.5 | N     | N          |
| 1  | 0  | 1  | 2  | -1.5 | 0.5 | 0.5 | -1.5 | P     | N          |
| 1  | 1  | 1  | 1  | -0.5 | 0.5 | 1.5 | 0.5  | P     | P          |

(נתונים המאפיינים feature1, feature2, feature3 ויש צורך לחזות את class):

| Feature1 | Feature2 | Feature3 | Class |
|----------|----------|----------|-------|
| 0        | 1        | 1        | P     |
| 1        | 0        | 0        | P     |
| 0        | 0        | 1        | N     |
| 1        | 1        | 0        | N     |
| 0        | 1        | 2        | P     |
| 1        | 1        | 1        | P     |

נניח שאנו משנים את האלגוריתם העדכון של הפרספטרון ע"פ הנוסחה הבאה:

If current example  $(x_i, y_i)$  is correctly classified, don't change

If wrongly classified as 1,  $w \leftarrow w - 2x_i$

If wrongly classified as -1,  $w \leftarrow w + 2x_i$

פתור את הבעיה באמצעות אלגוריתם זה. עבוד במוד INCREMENTAL, כלומר, עדכון מבוצע לאחר כל דוגמא (אם יש צורך). התחילו עם קבוצת משקולות בה כל המשקולות שווים 0.5 והזן את הדוגמאות לאלגוריתם ע"פ סדר הופעתן בטבלה. מהן המשקולות שהתקבלו אחרי סיבוב עדכון אחד, כלומר, מעבר על כל הדוגמאות פעם אחת. יש להוסיף נירון דמי שערכו 1 עבור כל הווקטורים כפי שלמדנו

|  | f0 | f1 | f2 | f3 | w0   | w1  | w2  | w3   | class | Prediction |
|--|----|----|----|----|------|-----|-----|------|-------|------------|
|  | 1  | 0  | 1  | 1  | 0.5  | 0.5 | 0.5 | 0.5  | P     | P          |
|  | 1  | 1  | 0  | 0  | 0.5  | 0.5 | 0.5 | 0.5  | P     | P          |
|  | 1  | 0  | 0  | 1  | 0.5  | 0.5 | 0.5 | 0.5  | N     | P          |
|  | 1  | 1  | 1  | 0  | -1.5 | 0.5 | 0.5 | -1.5 | N     | N          |
|  | 1  | 0  | 1  | 2  | -1.5 | 0.5 | 0.5 | -1.5 | P     | N          |
|  | 1  | 1  | 1  | 1  | 0.5  | 0.5 | 2.5 | 2.5  | P     | P          |

(נתונים המאפיינים feature1, feature2, feature3 ויש צורך לחזות את class):

| Feature1 | Feature2 | Feature3 | Class |
|----------|----------|----------|-------|
| 0        | 1        | 1        | P     |
| 1        | 0        | 0        | P     |
| 0        | 0        | 1        | N     |
| 1        | 1        | 0        | N     |
| 0        | 1        | 2        | P     |
| 1        | 1        | 1        | P     |

נניח שאנו משנים את האלגוריתם העדכון של הפרספטרון ע"פ הנוסחה הבאה:

If current example  $(x_i, y_i)$  is correctly classified, don't change


If wrongly classified as 1,  $w \leftarrow w - x_i$

If wrongly classified as -1,  $w \leftarrow w + 2x_i$

פתור את הבעיה באמצעות אלגוריתם זה. עבוד במוד INCREMENTAL, כלומר, עדכון מבוצע לאחר כל דוגמא (אם יש צורך). התחילו עם קבוצת משקולות בה כל המשקולות שווים 0.5 והזן את הדוגמאות לאלגוריתם ע"פ סדר הופעתן בטבלה. מהן המשקולות שהתקבלו אחרי סיבוב עדכון אחד, כלומר, מעבר על כל הדוגמאות פעם אחת. יש להוסיף נירון דמי שערכו 1 עבור כל הווקטורים כפי שלמדנו

| f0 | f1 | f2 | f3 | w0   | w1   | w2   | w3   | class | Prediction |
|----|----|----|----|------|------|------|------|-------|------------|
| 1  | 0  | 1  | 1  | 0.5  | 0.5  | 0.5  | 0.5  | P     | P          |
| 1  | 1  | 0  | 0  | 0.5  | 0.5  | 0.5  | 0.5  | P     | P          |
| 1  | 0  | 0  | 1  | 0.5  | 0.5  | 0.5  | 0.5  | N     | P          |
| 1  | 1  | 1  | 0  | -0.5 | 0.5  | 0.5  | -0.5 | N     | P          |
| 1  | 0  | 1  | 2  | -1.5 | -0.5 | -0.5 | -0.5 | P     | N          |
| 1  | 1  | 1  | 1  | 0.5  | -0.5 | 1.5  | 3.5  | P     | P          |


נתון גרף ROC הבא:



חשב את ה-AUC ואת ה-EER

$$AUC = 0.3 \times 0.5 + 0.4 \times 0.6 + 0.2 \times 0.8 + 0.1 \times 1 = 0.65$$


$EER$  הינה הנקודה בה ה-FP שווה ל-(1-TP). במקרה שלפנינו 0.4



חשב את ה-AUC ואת ה-EER

$$AUC = 0.2 \times 0.4 + 0.4 \times 0.1 + 0.6 \times 0.3 + 0.1 \times 0.8 + 0.1 \times 1 = 0.48$$

$EER$  הינה הנקודה בה ה-FP שווה ל-(1-TP). במקרה שלפנינו 0.5



$$AUC = 0.3 \times 0.4 + 0.5 \times 0.4 + 0.8 \times 0.1 + 1 \times 0.1 = 0.5$$

$EER$  הינה הנקודה בה ה-FP שווה ל-(1-TP). במקרה שלפנינו 0.5

נתונה טבלת האימון הבאה:  
 כיצד יסווג הוקטור (2,3,3,2) עפ"י אלגוריתם נאיב בייס?  
 (גם עם הווקטור נמצא בקבוצת האימון עדיין יש לחשב עפ"י אלגוריתם נאיב בייס).

| f1 | f2 | f3 | f4 | Class |
|----|----|----|----|-------|
| 1  | 1  | 1  | 1  | A     |
| 1  | 2  | 3  | 2  | A     |
| 2  | 3  | 3  | 2  | A     |
| 2  | 4  | 4  | 3  | A     |
| 2  | 1  | 1  | 6  | B     |
| 1  | 3  | 3  | 2  | B     |
| 2  | 3  | 3  | 1  | B     |
| 3  | 2  | 3  | 2  | B     |
| 3  | 4  | 5  | 2  | C     |
| 2  | 3  | 2  | 2  | C     |
| 3  | 3  | 1  | 1  | C     |
| 2  | 2  | 1  | 1  | C     |
| 3  | 3  | 4  | 2  | D     |
| 1  | 2  | 3  | 3  | D     |
| 2  | 4  | 1  | 4  | D     |
| 4  | 3  | 1  | 2  | D     |

$$P(class|(x1 = 2, x2 = 3, x3 = 3, x4 = 2)) = \frac{P(x1 = 2, x2 = 3, x3 = 3, x4 = 2|class) \times P(class)}{P(x1 = 2, x2 = 3, x3 = 3, x4 = 2)}$$


P(class) זהה לכולם  
 מכנה זהה לכולם  
 נשתמש כעת בעיקרון אי התלות

$$P(A|(x1 = 2, x2 = 3, x3 = 3, x4 = 2)) = P(A|x1 = 2) \times P(A|x2 = 3) \times P(A|x3 = 3) \times P(A|x4 = 2) = \frac{1}{2} \times \frac{1}{4} \times \frac{1}{2} \times \frac{1}{2}$$

$$P(B|(x1 = 2, x2 = 3, x3 = 3, x4 = 2)) = P(B|x1 = 2) \times P(B|x2 = 3) \times P(B|x3 = 3) \times P(B|x4 = 2) = \frac{1}{2} \times \frac{1}{2} \times \frac{3}{4} \times \frac{1}{2}$$

$$P(C|(x1 = 2, x2 = 3, x3 = 3, x4 = 2)) = P(C|x1 = 2) \times P(C|x2 = 3) \times P(C|x3 = 3) \times P(C|x4 = 2) = \frac{1}{2} \times \frac{1}{2} \times 0$$

נדרשת החלקה



נתונה טבלת האימון הבאה:  
 כיצד יסווג הווקטור (2,2,1,2) עפ"י אלגוריתם נאיב בייס?  
 (גם עם הווקטור נמצא בקבוצת האימון עדיין יש לחשב עפ"י אלגוריתם נאיב בייס).

| f1 | f2 | f3 | f4 | Class |
|----|----|----|----|-------|
| 1  | 1  | 1  | 1  | A     |
| 1  | 2  | 3  | 2  | A     |
| 2  | 3  | 3  | 2  | A     |
| 2  | 4  | 4  | 3  | A     |
| 2  | 1  | 1  | 6  | B     |
| 1  | 3  | 3  | 2  | B     |
| 2  | 3  | 3  | 1  | B     |
| 3  | 2  | 3  | 2  | B     |
| 3  | 4  | 5  | 2  | C     |
| 2  | 3  | 2  | 2  | C     |
| 3  | 3  | 1  | 1  | C     |
| 2  | 2  | 1  | 1  | C     |
| 3  | 3  | 4  | 2  | D     |
| 1  | 2  | 3  | 3  | D     |
| 2  | 4  | 1  | 4  | D     |
| 4  | 3  | 1  | 2  | D     |

$$P(class|(x1 = 2, x2 = 2, x3 = 1, x4 = 2)) = \frac{P(x1 = 2, x2 = 2, x3 = 1, x4 = 2|class) \times P(class)}{P(x1 = 2, x2 = 2, x3 = 1, x4 = 2)}$$

P(class) זהה לכולם  
 מכנה זהה לכולם  
 נשתמש כעת בעיקרון אי התלות

$$P(A|(x1 = 2, x2 = 2, x3 = 1, x4 = 2)) = P(A|x1 = 2) \times P(A|x2 = 2) \times P(A|x3 = 1) \times P(A|x4 = 2) = \frac{1}{2} \times \frac{1}{4} \times \frac{1}{4} \times \frac{1}{2} = \frac{1}{64}$$

$$P(B|(x1 = 2, x2 = 2, x3 = 3, x4 = 2)) = P(B|x1 = 2) \times P(B|x2 = 2) \times P(B|x3 = 1) \times P(B|x4 = 2) = \frac{1}{2} \times \frac{1}{4} \times \frac{1}{4} \times \frac{1}{2} = \frac{1}{64}$$

$$P(C|(x1 = 2, x2 = 2, x3 = 1, x4 = 2)) = P(C|x1 = 2) \times P(C|x2 = 2) \times P(C|x3 = 1) \times P(C|x4 = 2) = \frac{1}{2} \times \frac{1}{4} \times \frac{1}{2} \times \frac{1}{2} = \frac{2}{64}$$

$$P(D|(x1 = 2, x2 = 2, x3 = 1, x4 = 2)) = P(D|x1 = 2) \times P(D|x2 = 2) \times P(D|x3 = 1) \times P(D|x4 = 2) = \frac{1}{4} \times \frac{1}{4} \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{64}$$

נתונה טבלת האימון הבאה:

כיצד יסווג הוקטור (2,3,1,2)

עפ"י אלגוריתם נאיב בייס?

(גם עם הווקטור נמצא בקבוצת האימון עדיין יש לחשב עפ"י אלגוריתם נאיב בייס).

| f1 | f2 | f3 | f4 | Class |
|----|----|----|----|-------|
| 1  | 1  | 1  | 1  | A     |
| 1  | 2  | 3  | 2  | A     |
| 2  | 3  | 3  | 2  | A     |
| 2  | 4  | 4  | 3  | A     |
| 2  | 1  | 1  | 6  | B     |
| 1  | 3  | 3  | 2  | B     |
| 2  | 3  | 3  | 1  | B     |
| 3  | 2  | 3  | 2  | B     |
| 3  | 4  | 5  | 2  | C     |
| 2  | 3  | 2  | 2  | C     |
| 3  | 3  | 1  | 1  | C     |
| 2  | 2  | 1  | 1  | C     |
| 3  | 3  | 4  | 2  | D     |
| 1  | 2  | 3  | 3  | D     |
| 2  | 4  | 1  | 4  | D     |
| 4  | 3  | 1  | 2  | D     |

$$P(class|(x1 = 2, x2 = 3, x3 = 1, x4 = 2)) = \frac{P(x1 = 2, x2 = 3, x3 = 1, x4 = 2|class) \times P(class)}{P(x1 = 2, x2 = 3, x3 = 1, x4 = 2)}$$

P(class) זהה לכולם  
מכנה זהה לכולם  
נשתמש כעת בעיקרון אי התלות

$$\begin{aligned} P(A|(x1 = 2, x2 = 3, x3 = 1, x4 = 2)) &= P(A|x1 = 2) \times P(A|x2 = 3) \times P(A|x3 = 1) \times P(A|x4 = 2) = \frac{1}{2} \times \frac{1}{4} \times \frac{1}{4} \times \frac{1}{2} = \frac{1}{64} \\ P(B|(x1 = 2, x2 = 3, x3 = 1, x4 = 2)) &= P(B|x1 = 2) \times P(B|x2 = 3) \times P(B|x3 = 1) \times P(B|x4 = 2) = \frac{1}{2} \times \frac{1}{2} \times \frac{1}{4} \times \frac{1}{4} = \frac{1}{64} \\ P(C|(x1 = 2, x2 = 3, x3 = 1, x4 = 2)) &= P(C|x1 = 2) \times P(C|x2 = 3) \times P(C|x3 = 1) \times P(C|x4 = 2) = \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} = \frac{4}{64} \\ P(D|(x1 = 2, x2 = 3, x3 = 1, x4 = 2)) &= P(D|x1 = 2) \times P(D|x2 = 3) \times P(D|x3 = 1) \times P(D|x4 = 2) = \frac{1}{4} \times \frac{1}{2} \times \frac{1}{2} \times \frac{1}{2} = \frac{1}{32} \end{aligned}$$

| x1 | x2 | x3 | CLASS |
|----|----|----|-------|
| 1  | 1  | 1  | A     |
| 0  | 2  | 2  | A     |
| 2  | 1  | 3  | A     |
| 2  | 2  | 4  | A     |
| 1  | 1  | 4  | B     |
| 1  | 2  | 3  | B     |
| 2  | 1  | 2  | C     |
| 1  | 2  | 1  | C     |

נתונה טבלת האימון הבאה:  
על פי אלגוריתם עץ החלטה ID3  
איזה מאפיין יבחר לראש העץ?

$$H(class) = -\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{4}\log_2\frac{1}{4} - \frac{1}{4}\log_2\frac{1}{4} = 1.5$$

$$\begin{aligned} H(class|x1) &= p(x1 = 0) \times H(class|x1 = 0) + p(x1 = 1) \times H(class|x1 = 1) + p(x1 = 2) \times H(class|x1 = 2) \\ &= \frac{1}{8} \times 0 + \frac{4}{8} (H(A, B, B, C) + \frac{3}{8} H(A, A, C)) = 0 + \frac{4}{8} \times \frac{3}{2} + \frac{3}{8} \times \sim 0.9 \sim 1.08 \end{aligned}$$

$$\begin{aligned} H(class|x2) &= p(x2 = 1) \times H(class|x2 = 1) + p(x2 = 2) \times H(class|x2 = 2) \\ &= \frac{1}{2} \times H(A, A, B, C) + \frac{1}{2} (H(A, B, B, C) + \frac{3}{8} H(A, A, B, C)) = \frac{1}{2} \times \frac{3}{2} + \frac{1}{2} \times \frac{3}{2} = \frac{3}{2} \end{aligned}$$

$$\begin{aligned} H(class|x3) &= p(x3 = 1) \times H(class|x3 = 1) + p(x3 = 2) \times H(class|x3 = 2) + p(x3 = 3) \times H(class|x3 = 3) + p(x3 = 4) \times H(class|x3 = 4) \\ &= \frac{2}{8} \times H(A, C) + \frac{2}{8} (H(A, C) + \frac{2}{8} H(A, B) + \frac{2}{8} H(A, B)) = \frac{2}{8} \times 1 + \frac{2}{8} \times 1 + \frac{2}{8} \times 1 + \frac{2}{8} \times 1 = 1 \end{aligned}$$

נתונה טבלת האימון הבאה:  
 על פי אלגוריתם עץ החלטה ID3  
 איזה מאפיין יבחר לראש העץ?

| x1 | x2 | x3 | CLASS |
|----|----|----|-------|
| 1  | 0  | 1  | A     |
| 1  | 2  | 4  | A     |
| 2  | 1  | 3  | A     |
| 2  | 2  | 2  | A     |
| 1  | 1  | 4  | B     |
| 2  | 1  | 3  | B     |
| 1  | 1  | 2  | C     |
| 2  | 2  | 1  | C     |

$$H(class) = -\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{4}\log_2\frac{1}{4} - \frac{1}{4}\log_2\frac{1}{4} = 1.5$$

$$\begin{aligned} H(class|x1) &= p(x1 = 1) \times H(class|x1 = 1) + p(x1 = 2) \times H(class|x1 = 2) \\ &= \frac{1}{2} \times H(A, A, B, C) + \frac{1}{2} (H(A, A, B, C) = \frac{1}{2} \times \frac{3}{2} + \frac{1}{2} \times \frac{3}{2} = \frac{3}{2} \end{aligned}$$

$$\begin{aligned} H(class|x2) &= p(x2 = 0) \times H(class|x2 = 0) + p(x2 = 1) \times H(class|x2 = 1) + p(x2 = 2) \times H(class|x2 = 2) \\ &= \frac{1}{8} \times 0 + \frac{1}{2} (H(A, B, B, C) + \frac{3}{8} H(A, A, C) = 0 + \frac{4}{8} \times \frac{3}{2} + \frac{3}{8} \times \sim 0.9 \sim = 1.08 \end{aligned}$$

$$\begin{aligned} H(class|x3) &= p(x3 = 1) \times H(class|x3 = 1) + p(x3 = 2) \times H(class|x3 = 2) + p(x3 = 3) \times H(class|x3 = 3) + p(x3 = 4) \times H(class|x3 = 4) \\ &= \frac{2}{8} \times H(A, C) + \frac{2}{8} (H(A, C) + \frac{2}{8} H(A, B) + \frac{2}{8} H(A, B) = \frac{2}{8} \times 1 + \frac{2}{8} \times 1 + \frac{2}{8} \times 1 + \frac{2}{8} \times 1 = 1 \end{aligned}$$

נתונה טבלת האימון הבאה:  
על פי אלגוריתם עץ החלטה ID3  
איזה מאפיין יבחר לראש העץ?

| x1 | x2 | x3 | CLASS |
|----|----|----|-------|
| 1  | 1  | 1  | A     |
| 0  | 2  | 2  | A     |
| 2  | 1  | 3  | A     |
| 2  | 2  | 4  | A     |
| 1  | 1  | 4  | B     |
| 1  | 2  | 3  | B     |
| 2  | 1  | 2  | C     |
| 1  | 2  | 1  | C     |

$$H(class) = -\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{4}\log_2\frac{1}{4} - \frac{1}{4}\log_2\frac{1}{4} = 1.5$$

$$\begin{aligned} H(class|x1) &= p(x1 = 0) \times H(class|x1 = 0) + p(x1 = 1) \times H(class|x1 = 1) + p(x1 = 2) \times H(class|x1 = 2) \\ &= \frac{1}{8} \times 0 + \frac{4}{8} (H(A, B, B, C) + \frac{3}{8} H(A, A, C)) = 0 + \frac{4}{8} \times \frac{3}{2} + \frac{3}{8} \times \sim 0.9 \sim 1.08 \end{aligned}$$

$$\begin{aligned} H(class|x2) &= p(x2 = 1) \times H(class|x2 = 1) + p(x2 = 2) \times H(class|x2 = 2) \\ &= \frac{1}{2} \times H(A, A, B, C) + \frac{1}{2} (H(A, B, B, C) + \frac{3}{8} H(A, A, B, C)) = \frac{1}{2} \times \frac{3}{2} + \frac{1}{2} \times \frac{3}{2} = \frac{3}{2} \end{aligned}$$

$$\begin{aligned} H(class|x3) &= p(x3 = 1) \times H(class|x3 = 1) + p(x3 = 2) \times H(class|x3 = 2) + p(x3 = 3) \times H(class|x3 = 3) + p(x3 = 4) \times H(class|x3 = 4) \\ &= \frac{2}{8} \times H(A, C) + \frac{2}{8} (H(A, C) + \frac{2}{8} H(A, B) + \frac{2}{8} H(A, B)) = \frac{2}{8} \times 1 + \frac{2}{8} \times 1 + \frac{2}{8} \times 1 + \frac{2}{8} \times 1 = 1 \end{aligned}$$


נתונה דגימה חדשה X המסומנת בכתום.

דגימה זו סווגה לקבוצה 1, עם K=5, תוך שימוש במטריקת מרחק L1,

ובשקלול מרחקים של  $\frac{1}{d^2}$ .

איזה מהשרטוטים הבאים נכון?

שימו לב שהדגימה סווגה בהכרח לקבוצה 1. כלומר ללא דילמות (דילמה יכולה להיות כאשר שתי קבוצות מקבלות ציון שווה או למשל כאשר מודדים מיהם שלוש הקרובים ומזהים שיש יותר משלוש אפשריים ואז ניתן לנקוט במספר אפשרויות)




מסומנים 5 הקרובים ביותר  
מרחקים 2,3,4 לפי L1  
יש דילמה


"1": 3,4

"2": 2,3

"3": 3,4,4



מסומנים 5 הקרובים ביותר  
מרחקים 4 לפי L1  
יש דילמה בין "2" ו"1"  
(מרחקים זהים)




**לא משנה איזה חמישה  
קרובים ניקח. גם אם  
ניקח שישה. עדיין "1"  
הוא המנצח**


"1": 4,4,5,5

"2": 4,5

$$\frac{1}{4^2} + \frac{1}{4^2} + \frac{1}{5^2} > \frac{1}{4^2} + \frac{1}{5^2}$$



מסומנים 6 הקרובים ביותר  
מרחקים 2,3 לפי L1  
יש דילמה אם נבחר 5 מתוך  
ה-6. וגם אם ניקח את כל  
השישה, "2" ינצח לאחר  
השקלול



מסומנים 7 הקרובים ביותר  
מרחקים 3,4 לפי L1  
לא משנה מה ה"חמישה"  
שנבחר או גם אם נבחר את  
כולם, לפחות יש "דילמה"


אלגוריתם KNN:

נתונה דגימה חדשה X המסומנת בכתום.



דגימה זו סווגה בהכרח (כלומר ללא שוויון בין קבוצות שונות) לקבוצה 1, עם  $K=3$ , תוך שימוש במטריקת מרחק אוקלידי, ובשקלול מרחקים של  $\frac{1}{d}$ .

איזה מהשרטוטים הבאים נכון?

שימו לב שהדגימה סווגה בהכרח לקבוצה 1. כלומר ללא דילמות (דילמה יכולה להיות כאשר שתי קבוצות מקבלות ציון שווה או למשל כאשר מודדים מיהם שלושת הקרובים ומזהים שיש יותר משלוש אפשרויות ואז ניתן לנקוט במספר אפשרויות)



מסומנים 4 הקרובים ביותר במרחקים שווים. ניתן לראות שבכל קונפיגורציה של בחירה יש "דילמה"




מסומנים 3 הקרובים ביותר מרחקים לפי L2.

"1":  $\sqrt{2}, \sqrt{2}$

"3": 1

$$\frac{1}{\sqrt{2}} + \frac{1}{\sqrt{2}} > \frac{1}{1}$$

"1" הוא המנצח




מסומנים 4 הקרובים ביותר מרחקים לפי L2.

אם נבחר בשלושה הקרובים ביותר את "1", "2", "הרי ש"1" לא ינצח.

"1":  $\sqrt{2}$

"2": 1,  $\sqrt{8}$

$$\frac{1}{1} + \frac{1}{\sqrt{8}} > \frac{1}{\sqrt{2}}$$



מסומנים 4 הקרובים ביותר מרחקים לפי L2.


אם נבחר בשלושה הקרובים ביותר את "1", "2", "הרי ש"1" לא ינצח.

"1":  $\sqrt{2}$

"2": 1

"3": 1

$$\frac{1}{\sqrt{2}} < 1$$



מסומנים 4 הקרובים ביותר מרחקים לפי L2.

אם נבחר בשלושה הקרובים ביותר את "1", "2", "הרי ש"1" לא ינצח.

"1":  $\sqrt{2}$

"2": 1

"3": 1


$$\frac{1}{\sqrt{2}} < 1$$

אלגוריתם KNN:


נתונה דגימה חדשה X המסומנת בכתום.

דגימה זו סווגה בהכרח (כלומר ללא שוויון בין קבוצות שונות) לקבוצה 1, עם  $K=3$ , תוך שימוש במטריקת מרחק אוקלידי, ובשקלול מרחקים של  $\frac{1}{d}$ .


איזה מהשרטוטים הבאים נכון?




מסומנים 4 הקרובים ביותר  
במרחקים שווים.  
ניתן לראות שבכל  
קונפיגורציה של בחירה יש  
"דילמה"




מסומנים 3 הקרובים ביותר  
מרחקים לפי L2.  
ברור שעם השקלול "2"  
ינצח  
"1": 2  
"2":  $2 + \frac{1}{\sqrt{2}}$   
 $2 + \frac{1}{\sqrt{2}} > 2$



מסומנים 4 הקרובים ביותר  
מרחקים לפי L2.  
אם נבחר בשלושה הקרובים  
ביותר למשל את "3",  
"2", "3" הרי ש"1" לא ינצח.



מסומנים 3 הקרובים ביותר  
מרחקים לפי L2.  
ברור שעם השקלול "2"  
ינצח  
"1": 2  
"2":  $2 + \frac{1}{\sqrt{2}}$



מסומנים 5 הקרובים ביותר  
מרחקים לפי L2.  
אם נבחר בשלושה הקרובים  
ביותר למשל את "3",  
"2", "3" הרי ש"1" לא ינצח.

בשאלה זו בהיבטים מסויימים אכן קיימת דילמה בכל אחת מהקונפיגורציות המקפות בירוק.  
בשתי הנוספות וודאי ש"1" לא "ינצח", לכן החלטתי לקבל כתשובה נכונה את כל אחת  
מהאופציות המסומנות בירוק.

$$2 + \frac{1}{\sqrt{2}} > 2$$

# אלו האימרות הלא נכונות

- ניתן להשתמש באותה היפוטזה באיטרציה  $i$  ובאיטרציה  $i+1$  באלגוריתם ADABOOST
- עקרון התער של אוקמה מציע לחפש את האלגוריתם המורכב ביותר הפותר את הבעיה.
- אם רוצים שרשת ניורונים תחשב פונקציה לא לינארית אז לא חייבים לשים פונקציות אקטיבציה לא לינאריות
- דוגמא לאלגוריתם סיווג הינו אלגוריתם K-MEANS
- בגישת ONE VS. ALL נצטרך לחשב יותר "היפוטזות" מאשר בגישת ONE VS. ONE
- באלגוריתם עץ החלטה ID3: התבססות על האינפוגיין (InfoGain) סותרת את עיקרון התער של אוקמה
- אלגוריתם הפרספטרון: בעיית סיווג - גם כאשר יש הפרדה לינארית, לא בטוח שנמצא אותה באמצעות אלגוריתם פרספטרון (מוד אינקרמנטלי) אפילו לאחר מס' אין-סופי של איטרציות
- באמצעות רשת ניורונים לא ניתן לפתור בעיית מרבית מחלקות
- באלגוריתם ADABOOST, כל דוגמא שסווגה נכון באיטרציה ה-  $t$  תקבל משקל גבוה יותר לאיטרציה ה-  $t+1$
- דוגמא לאלגוריתם EAGER הוא אלגוריתם KNN
- גם כאשר יש הפרדה לינארית בין קבוצות לא נעדיף להשתמש באלגוריתמים SVM-SOFT-MARGIN