


Roc-Curve

התבוננו בגרף ROC Curve הימני:



חשבו את ה- AUC ואת ה-EER.

[q1]

$AUC=0.68$ ו- $EER=0.4$, אם היינו משנים את הגרף (איור מוקטן להמחשה מצד שמאל) כך שהיה מגיע ל $TP = 1$ כבר בנקודה בה $FP = 0.7$, אזי ה- EER לא היה משתנה. ה- AUC לעומת זאת היה גדל.

$$AUC = 0.4 \times 0.4 + 0.1 \times 0.6 + 0.4 \times 0.9 + 0.1 \times 1 = 0.68$$

EER is the point where $\%FP = (1 - \%TP) \rightarrow (FP = 0.4, TP = 0.6) \rightarrow EER = 0.4$

Red graph has larger Area under curve (even no need to calculate) & does not change the EER point since the change is at $FP = 0.7$

בחר את הסעיף בו כל האמרות הן נכונות

[q2]

(1) באלגוריתמים ממשפחת אלגוריתמי boosting, ע"י שקלול מס' מסווגים לינאריים ניתן להגיע למסווג לא לינארי.

(2) באלגוריתם Naïve Bias הנחת האי התלות בין המאפיינים מאפשרת לנו לחשב את הסתברות המותנית הנדרשת בהינתן ווקטור רב ממדי כמכפלה של הסתברויות בהינתן כל מאפיין בנפרד.

(3) ברשתות נוירונים - הוספת שכבה חבויה ופונקציה אקטיבציה לא לינארית מאפשרים הפרדה גם לא לינארית

(4) טריק הקרנל באלגוריתם SVM נועד לחסוך בחישוביות שנובעת ממיפוי ווקטורים למימד הגבוה בו יש הפרדה לינארית

על מנת למצוא את המחלקה של קבוצת אימון נתונה (שלושה מאפיינים f_1, f_2, f_3), השתמשו באלגוריתם SVM ליניארי.

#	f_1	f_2	f_3	Class
1	1	1	1	1
2	2	2	2	1
3	3	3	3	-1
4	4	4	4	-1
5	5	5	5	-1

התקבלו הפרמטרים הבאים: (שימו לב – הנתונים אינם בהכרח פתרון נכון לקבוצת האימון אלא רק לצורך השאלה)

$$\alpha_1 = 0, \alpha_2 = 0.666, \alpha_3 = 0.666, \alpha_4 = 0, \alpha_5 = 0$$

$$b = -3$$

מי הם ה-Support vectors? מהו W , וסווג את הנק' $(2,2,6)$

משוואת הסיווג: $\text{SGN}(WX-b)$

[q3]

ווקטורים #3, #2 הם Support vectors, $W = (-0.666, -0.666, -0.666)$, וסיווג הנק' $(2,2,6)$ הוא שלילי.

$$W = \left(\sum \alpha_i y_i x_i \right) = 0.666 \times (+1) \times (2,2,2) + 0.666 \times (-1) \times (3,3,3) =$$

$$(-0.666, -0.666, -0.666)$$

$$\text{Classification}(2,2,6) = \text{SGN}(W^T X - b) = -0.666 \times 2 + -0.666 \times 2 + -0.666 \times 6 - (-3)$$

$$<0 \rightarrow \text{NEG}$$


רשתות עצביות (Neural Networks)

נתונה רשת נוירונים עם שכבת כניסה, שתי שכבות חביות, ושכבת יציאה בכל שכבה יש 4 נוירונים. מה מהבאים נכון?

[q4]

סה"כ ברשת יש 48 משקולות (ללא הביאס) על הקשתות המחברות בין הנוירונים השונים

[a]



$$4 \times 4 + 4 \times 4 + 4 \times 4 = 48$$

בכל סעיף נתונה טבלת אימון בה שתי מחלקות – מחלקת ה'משולשים' ומחלקת ה'עיגולים'.
בחר את הסעיף בו ה-? יסווג כ משולש- ▲

[q5]

K=3 מטריקת מרחק L1 שקלול מרחקים של $\frac{1}{d}$ פתרון: ● weights = $\frac{1}{5} = \frac{14}{70}$ ▲ weights = $\frac{1}{7} + \frac{1}{10} = \frac{10+7}{70} = \frac{17}{70}$ ▲ > ●	
---	--

נתונה טבלת האימון הבאה:

מס' דוגמא	x1	x2	x3	class
1	2	1	4	P
2	2	2	2	P
3	2	1	4	P
4	2	1	2	P
5	2	2	4	N
6	1	2	2	N
7	2	2	4	N
8	1	1	1	N

כיצד יסווג הוקטור (2,2,2) בעזרת Naïve Bayes?

[q6]
P

$$P(P|x1 = 2, x2 = 2, x3 = 2) = \frac{P(x1 = 2, x2 = 2, x3 = 2|P) \times P(P)}{P(x1 = 2, x2 = 2, x3 = 2)}$$

$$P(N|x1 = 2, x2 = 2, x3 = 2) = \frac{P(x1 = 2, x2 = 2, x3 = 2|N) \times P(N)}{P(x1 = 2, x2 = 2, x3 = 2)}$$

$$P(x1 = 2, x2 = 2, x3 = 2|P) \times P(P) >? P(x1 = 2, x2 = 2, x3 = 2|N) \times P(N)$$

$P(P) = 0.5, P(N) = 0.5$

$$P(x1 = 2, x2 = 2, x3 = 2|P) >? P(x1 = 2, x2 = 2, x3 = 2|N)$$

Naïve assumption (independence between features)

$$P(x1 = 2, x2 = 2, x3 = 2|P) >? P(x1 = 2, x2 = 2, x3 = 2|N)$$


$$P(x1 = 2|P) \times P(x2 = 2|P) \times P(x3 = 2|P) = 1 \times \frac{1}{4} \times \frac{1}{2}$$

$$P(x1 = 2|N) \times P(x2 = 2|N) \times P(x3 = 2|N) = \frac{1}{2} \times \frac{3}{4} \times \frac{1}{4}$$


$$P(P|x1 = 2, x2 = 2, x3 = 2) > P(N|x1 = 2, x2 = 2, x3 = 2)$$

אלגוריתם k-means

נתונים הווקטורים הבאים, עבור $k=3$, מסומנים ב-x הווקטורים בהם איתחלנו את אלגוריתם k-means



הרצנו צעד אחד באלגוריתם. איזה מהבאים מתאים לאחר צעד אחד באלגוריתם?
[q7]



בחר/י את האמרה הנכונה ביותר עבור אלגוריתם ADABOOST?

[q8]

הטעות המשוקללת של כל היפוטזה צריכה להיות קטנה מ-0.5

נתונה טבלת האימון הבאה:

class	x3	x2	x1	מס' דוגמא
P	1	1	2	1
P	1	1	2	2
P	1	1	2	3
N	2	1	3	4
N	4	1	0	5
N	3	4	4	6

מה מהבאים נכון?

[q9]

$H(\text{class} | x_3) = 0$

$$H(\text{class} | x_3) = P(x_3 = 1) \times H(\text{class} | x_3 = 1) + P(x_3 = 2) \times H(\text{class} | x_3 = 2) + P(x_3 = 3) \times H(\text{class} | x_3 = 3) + P(x_3 = 4) \times H(\text{class} | x_3 = 4)$$

$$H(\text{class} | x_3 = 1) = 0$$

$$H(\text{class} | x_3 = 2) = 0$$

$$H(\text{class} | x_3 = 3) = 0$$

$$H(\text{class} | x_3 = 4) = 0$$

$$H(\text{class} | x_3) = 0$$

נתונה בעיית סיווג בינארית (שתי מחלקות) בה שני מאפיינים:

$$(x_1, x_2)$$

פתרנו את בעיית הסיווג ומצאנו שהמשוואה (הלא לינארית) הבאה מייצרת הפרדה בין שתי המחלקות:

$$(x_1 - 1)^2 + (x_2 - 1)^3 = 0$$

אנו מחפשים מיפוי של המאפיינים x_1, x_2 למימד גבוה יותר בו יש הפרדה לינארית. איזה מהמיפויים הבאים ייצר הפרדה לינארית

[q10]

שתי תשובות נכונות

$$(x_1, x_2) \rightarrow (x_2^3 + x_1^2, x_2^2, x_2, x_1)$$

$$(x_1, x_2) \rightarrow (x_1^2, x_1 + x_2, x_2^3, x_2^2, x_2)$$

פתרון:

$$(x_1 - 1)^2 + (x_2 - 1)^3 = 0 =$$

$$(x_1^2 - 2x_1 + 1) + (x_2 - 1)(x_2 - 1)^2 =$$

$$(x_1^2 - 2x_1 + 1) + (x_2^2 - 2x_2 + 1)(x_2 - 1) =$$

$$(x_1^2 - 2x_1 + 1) + (x_2^3 - 2x_2^2 + x_2 - x_2^2 + 2x_2 - 1) =$$

$$(x_1^2 - 2x_1 + 1) + (x_2^3 - 2x_2^2 + x_2 - x_2^2 + 2x_2 - 1) =$$

$$(x_1^2 - 2x_1 + 1) + (x_2^3 - 3x_2^2 + 3x_2 - 1) =$$

$$1 \cdot (x_2^3 + x_1^2) - 3 \cdot (x_2^2) + 3 \cdot (x_2) - 2(x_1)$$

או

$$1 \cdot (x_1^2) - 2(x_1 + x_2) + 1 \cdot (x_2^3) - 3 \cdot (x_2^2) + 5 \cdot (x_2)$$