

שאלה 1:

נתונה טבלת האימון הבאה:

x1	x2	x3	y
9	1	2	0
8	1	4	0
1	2	3	1
3	2	4	1

סווגו את הוקטורים 2,2,2 ו- 9,9,9 בעזרת פרספטרון (הדרכה: תחילה חשבו את w. ניחוש ראשוני של כל משקל הוא 2, הריצו למשך 2 epochs). מה יהיו הסיווגים שלהם?

[q1]

2,2,2 יסווג כ- 1, ו- 9,9,9 יסווג כ- 1

[a1]

2,2,2 יסווג כ- 1, ו- 9,9,9 יסווג כ- 0

[a2]

2,2,2 יסווג כ- 0, ו- 9,9,9 יסווג כ- 1

[a3]

2,2,2 יסווג כ- 0, ו- 9,9,9 יסווג כ- 0

[a4]

w לא ניתן לחישוב

[a5]

פתרון:

x0	x1	x2	x3	y		w0	x1	x2	x3	Update?
1	9	1	2	0		2	2	2	2	Yes
1	8	1	4	0		1	7-	1	0	No
1	1	2	3	1		1	7-	1	0	Yes
1	3	2	4	1		2	6-	3	3	No
1	9	1	2	0		2	6-	3	3	No

1	8	1	4	0		2	6-	3	3	No
1	1	2	3	1		2	6-	3	3	No
1	3	2	4	1		2	6-	3	3	No

כעת נכפול את הוקטורים 2,2,2 ו- 9,9,9 ב- משקלים שקיבלנו:

$$(1,2,2,2) * (2, -6, 3, 3) > 0 \rightarrow \text{POS}$$

$$(1,9,9,9) * (2, -6, 3, 3) > 0 \rightarrow \text{POS}$$

שאלה 2:

נתונה קבוצת האימון הבאה (x_1, x_2) הינם המאפיינים, y מייצג את המחלקה לסיווג):

x_1	x_2	y
1	1	1
1	2	1
1	3	1
1	4	1
1	5	1
8	1	-1
8	2	-1
8	3	-1
8	4	-1
8	5	-1
2	3	-1

על מנת לענות על השאלה, מומלץ לצייר את הנקודות במרחב דו מימדי.
מה מהבאים נכון?

[q2]

בריצת SVM-hard-margin נקבל את הישר $x=1.5$ ואילו בריצת SVM-soft-margin ניתן לקבל את הישר $x=4.5$

[a1]

גם בריצת SVM-hard-margin וגם בריצת SVM-soft-margin נקבל את הישר $x=1.5$

[a2]

בריצת SVM-hard-margin נקבל את הישר $x=1.5$ ואילו בריצת SVM-soft-margin ניתן לקבל את הישר $x=4$

[a3]

בריצת SVM-hard-margin ניתן לקבל את הישר $x=4.5$ אם קובעים את $C=100$, ואילו בריצת SVM-soft-margin ניתן לקבל את הישר $x=1.5$ בעזרת ערך כלשהו של C (כלומר קיים ערך C כזה)

[a4]

ריצת SVM-hard-margin לא תתכנס ואילו ריצת SVM-soft-margin תתכנס לישר $x=1.5$

[a5]

פתרון:

אם מציירים את הנקודות במרחב, מבחינים שהקודה האחרונה היא למעשה חריגה (outlier), למרות שקבוצת האימון הנ"ל ניתנת להפרדה ליניארית. לכן, כאשר מריצים hard margin אז חייבים להתייחס לנקודה החריגה, ולמעשה מקבלים ישר שעובר בדיוק באמצע, כלומר כאשר $x=1.5$. אבל כאשר מריצים soft margin, עם ערך רלוונטי של C ניתן לקבל את הישר $x=4.5$ שלמעשה מתעלם מהנקודה החריגה. שימו לב, התשובות שבהן מתואר ישר עם מרווח לא סימטרי בשני הכיוונים כמובן לא יכולות להיות נכונות. תשובה 2 טוענת שבטוח נקבל את הישר $x=1.5$ ב-soft, וזה לא נכון.

שאלה 3:

נתוני חיסון כלשהו התקבלו במעבדת המחקר שלכם כך:

רמת נוגדנים	מחלות רקע	קבוצת גיל	מין
OK	Yes	Young	Female
Not OK	Yes	Young	Female
OK	No	Old	Female
OK	No	Very old	Female
OK	No	Very old	Male
Not OK	Yes	Old	Male
OK	Yes	Old	Male
Not OK	Yes	Young	Male

מבקשים ממכם לבנות מודל חיזוי לרמת נוגדנים תקינה (OK) והחלטתם להשתמש ב-Naive Bayes. מה יחזה המודל שלכם עבור האדם הבא (סמנו את התשובה המתאימה ביותר):

Female, Old, Yes

[q3]

רמת הנוגדים תקינה

[a1]

רמת הנוגדים אינה תקינה

[a2]

המודל יחזה שרמת הנוגדנים תקינה ואינה תקינה באותה הסתברות

[a3]

אין מספיק נתונים כדי שהמודל יקבל החלטה

[a4]

האלגוריתם Naive Bayes לא מיועד לבעיות מהסוג הזה ועל כן לא ניתן להשתמש בו לפתרון הבעיה

[a5]

פתרון:


מחשבים לפי נייב בייס:

$$p(\text{OK}|\text{Female, Old, Yes}) = P(\text{OK}) * P(\text{Female}|\text{OK}) * P(\text{Old}|\text{OK}) * P(\text{yes}|\text{OK}) \\ = \frac{5}{8} * \frac{3}{8} * \frac{2}{8} * \frac{2}{8} = \underline{\underline{0.3}}$$

$$p(\text{Not OK}|\text{Female, Old, Yes}) = P(\text{Not OK}) * P(\text{Female}|\text{N.OK}) * P(\text{Old}|\text{N.OK}) * P(\text{yes}|\text{N.OK}) \\ = \frac{3}{8} * \frac{1}{3} * \frac{1}{3} * 1 = 0.25$$

שאלה 4:

נתונים הוקטורים הדו-מימדיים הבאים כקבוצת אימון:



מהי התשובה הנכונה ביותר מבין האפשרויות הבאות, המתארות אלגוריתמים שיצליחו לייצר מפריד מושלם (עם אפס שגיאות על קבוצת האימון)?

[q4]

האלגוריתמים: עץ החלטה, רשת נוירונים (עם מספר שכבות ונוירונים ככל שידרש), KNN עם $K=2$

[a1]

האלגוריתמים: עץ החלטה, רשת נוירונים (עם מספר שכבות ונוירונים ככל שידרש), KNN לא משנה באיזה ערך של K משתמשים

[a2]

האלגוריתמים: SVM-Soft, AdaBoost עם קרנל ליניארי

[a3]

האלגוריתמים: עץ החלטה, SVM-Soft עם קרנל ליניארי

[a4]

האלגוריתמים: SVM-Hard

[a5]

פתרון:

בשאלה זאת היתה כוונה ל-KNN בתשובה הראשונה להיות עם משקול מרחקים. מאחר וזה לא היה נתון, החלטנו לקבל את כל התשובות בשאלה זו.

שאלה 5:

ב - Naive Bayes, מדוע צריך להניח שהמאפיינים מתפלגים בצורה בלתי תלויה אחד בשני?

[q5]

אחרת, מספר פוקנציות ההסתברות שנצטרך לחשב הוא עצום וידרוש קבוצת אימון גדולה באופן בלתי סביר

[a1]

הנחת האי תלות היא תכונה מובנית של נוסחת Bayes ולכן חייבים להשתמש בה

[a2]

הנחת האי תלות מאפשרת לנו לבנות מודל ליותר משתי מחלקות

[a3]

הנחת האי תלות מאפשרת לנו לעבוד על משתנים קטגוריים

[a4]

אחרת, מספר המאפיינים שניתן להשתמש במודל הוא לכל היותר 3

[a5]

פתרון:

ללא הנחה זו, נצטרך לחשב את ההסתברות לכל קומבינציית תלויות בין המאפיינים, ומדובר בכמות גדולה מדי.

שאלה 6:

התייחסו לאלגוריתם KNN וסמנו את התשובה הנכונה ביותר.

[q6]

ככל שמגדילים את K מסתכנים בלמידת חסר (underfitting)

[a1]

ככל שמגדילים את K מסתכנים בלמידת יתר (overfitting)

[a2]

ככל שמגדילים את K מתקבלים יותר חריגים (outliers)

[a3]

ערך קטן של K מאפשר לנו למצוא יותר אשכולות (clusters)

[a4]

כאשר קבוצת המבחן ניתנת להפרדה ליניארית, הערך של K לא משנה את יכולת ההכללה של המודל


[a5]

פתרון:

ככל שנגדיל את K, כך המשמעות של המצאות וקטורים חריגים קטנה. הרי ככל ש-K גדול, מתייחסים ליותר וקטורים בסביבה הקרובה כאשר מקבלים החלטה, ולכן המשקל של וקטור בודד קטן. מצד שני, ככל ש-K גדול, יכולים להגיע למצב שבו מחליטים לפי וקטורים שנמצאים רחוק מדי מהוקטור אותו מנסים לסווג, וזה גורם ללמידת חסר.

שאלה 7:

נתון גרף ה ROC הבא:



בחר אפשרות אחת נכונה:

[q7]

ה AUC וה EER שווים

[a1]

ה AUC גדול מה EER

[a2]

ה EER גדול מה AUC

[a3]

ה AUC חיובי וה EER שלילי

[a4]

ה AUC שלילי וה EER חיובי

[a5]

פתרון

$$AUC=0.3\times0.4+0.5\times0.4+0.8\times0.1+1\times0.1 = 0.5$$

EER הינה הנקודה בה ה-FP שווה ל(1-TP). במקרה שלפנינו 0.5 שניהם יצאו 0.5 ולכן תשובה ראשונה נכונה

שאלה 8:

מריצים את אלגוריתם SVM על קבוצת האימון הבאה:

f1	f2	Label
0	0	P
1	2	N
2	2	N
3	2	N
4	2	N

שימו לב שהאלגוריתם רק בתצורה של Hard Margin, והתקבלו כופלי לגרנז' הבאים:

α_1	α_2	α_3	α_4	α_5
0.4	0.4	0	0	0

חשבו את b במשוואת הסיווג

$$SGN(WX-b)$$

[q8]

-1

[a1]

0

[a2]

1

[a3]

0.4

[a4]

0.8

[a5]

פתרון

$$W = \sum_i \alpha_i y_i x_i =$$

$$\frac{4}{10} \times (+1) \times (0,0) + \frac{4}{10} \times (-1) \times (1,2) =$$

$$(0,0) - \left(\frac{4}{10}, \frac{8}{10}\right) = \left(-\frac{4}{10}, -\frac{8}{10}\right)$$


ידוע שאם נציב SV חיובי נקבל 1

$$wx - b = \left(-\frac{4}{10}, -\frac{8}{10}\right) \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$= 0 - b = 1 \rightarrow b = -1$$

שאלה 9:

נתונים הוקטורים הדו-מימדיים הבאים (המרחק בין כל וקטור לוקטור הוא 2):



איזו מההרצות הבאות תסתיים עם מספר האשכולות (clusters) הגדול ביותר?
הערות:

- ב. DBSCAN הוקטור עצמו לא נחשב לערך המספר המינימלי המוגדר ב - MinPts
- ב. DBSCAN וקטור רעש לא נחשב אשכול

[q9]

אלגוריתם KMEANS עם $K=2$, מרחק L_2 , ומרכזים התחלתיים הם שני הוקטורים הראשונים משמאל

[a1]

אלגוריתם DBSCAN עם $\epsilon=2$, $\text{MinPts}=4$ כאשר מתחילים מהוקטור השמאלי ביותר

[a2]

אלגוריתם DBSCAN עם $\epsilon=2$, $\text{MinPts}=2$ כאשר מתחילים מהוקטור השמאלי ביותר

[a3]

אלגוריתם היררכי Bottom Up, שמריצים עד שהמרחק של שני האשכולות הקרובים ביותר הוא לפחות 3

[a4]

אלגוריתם KNN עם $K=3$

[a5]

פתרון:

בתשובה הראשונה מתקבלים 2 אשכולות, ע"פ הגדרת האלגוריתם KMEANS. בתשובה השניה מגדירים מצב בו אף וקטור לא Core ולכן כל הוקטורים מוגדרים כרעש. במצב כזה יש 0 אשכולות. בתשובה השלישית, כל הוקטורים למעט השניים הקיצוניים יוגדרו כ - Core ולכן נסיים עם אשכול אחד. בתשובה רביעית, בהעדר הגדרת מרחק, יש לשער שמדובר בפונקציית מרחק של מינימום שנמדדת בין כל הוקטורים של שני אשכולות נתונים. על כן מחברים את כולם ומגיעים למצב של אשכול אחד. תשובה חמישית לא עוסקת באשכול.

שאלה 10:

נתונה קבוצת אימון של וקטורים מחולקים לשתי מחלקות. הקבוצה ניתנת להפרדה ליניארית למעט מספר קטן של וקטורים חריגים (outliers). מה מהבאות, השיטה שיש לה סיכוי הכי טוב להביא לדיוק (accuracy) הגבוה ביותר על קבוצת מבחן רלוונטית כלשהי?

[q10]

הרצת DBSCAN, כך שהחריגים יזוהו כרעש, מחיקת וקטורי הרעש, ואז למידה עם Perceptron

[a1]

הרצת SVM Hard

[a2]

הרצת KNN עם $K=1$ ופונקציית מרחק אוקלידית

[a3]

הרצת עץ החלטה עם רמה אחת

[a4]

הרצת KMEANS עם $K=2$ ואז שימוש בחלוקה לאשכולות בתור הסיווג למחלקה

[a5]

פתרון:

בתשובה 1 מזהים את וקטורי הרעש ומסירים אותם. במצב כזה perceptron יבצע למידה מושלמת. כל שאר התשובות לא מגיעות לתוצאה מושלמת.

שאלה 11:

התייחסו לאלגוריתם SVM וסמנו את התשובה הנכונה ביותר.

[q11]

בשימוש ב SVM עם kernel ניתן לפתור בעיות שלא ניתנות להפרדה על ידי מפריד לינארי

[a1]

בשימוש ב SVM עם kernel ה margin כבר לא רלוונטי

[a2]

ה support vectors מחושבים על ידי דגימה אקראית מתוך סך הוקטורים

[a3]

בשימוש ב SVM עם kernel אין יותר צורך ב support vectors

[a4]

ב SVM עם soft margin ככל שנגדיל את פרמטר C האלגוריתם פחות יתייחס לשגיאות

[a5]

פתרון

התשובה הראשונה נכונה כי עם קרנל למדנו שניתן לעלות את הבעיה למימד גבוה יותר בו כן תהיה הפרדה לינארית עדיין.

שאלה 12:

התייחסו לאלגוריתם id3 (עץ החלטה עם Info Gain) וסמנו את התשובה הנכונה ביותר.

[q12]

עץ החלטה עשוי למצוא מודל ללא שגיאות במקרה שבו SVM לינארי עם hard margin נכשל בלמצוא מודל ללא שגיאות

[a1]

ככל שנאפשר עץ עמוק יותר, נקטין את הסיכוי ללמידת יתר (overfitting)

[a2]

עץ החלטה הוא אלגוריתם ממשפחת ה unsupervised

[a3]

בבעיה שבה יש 2 מחלקות (classes), אם משתמשים בעץ החלטה עדיף שתהיה הטיה בין המחלקות - כלומר שמחלקה אחת תכיל לפחות 80 אחוז מהנתונים והשניה את היתר

[a4]

אלגוריתם עץ החלטה עשוי לא להסתיים (להיכנס ללולאה אינסופית) בבעיות מסוימות

[a5]

פתרון

תשובה 2 לא מתקבלת כי זה הפוך - ככל שנעמיק בעץ נסתכן ביותר ב overfitting והעץ הופך לסוג של "זיכרון".
תשובה 3 לא מתקבלת כי עצי החלטה שלמדנו הם ממשפחת ה classification שהם supervised learning.
תשובה 4 גם לא טובה כי class imbalance יכול להרוס לנו את ההחלטות של העץ כי הוא עובד סטטיסטית (באנטרופיה יש רכיב הסתברותי).

תשובה 5 - לפי מה שלמדנו האלגוריתם מסתיים ואף ניתחנו בשיעור מה עושים בכל מצב.

תשובה 1 נכונה ומתייחסת לכך אם SVM לינארי לא מוצא מודל בלי שגיאות (ב HARD) עדיין עץ ההחלטה שהוא מודל שאינו לינארי עשוי למצוא מודל למקרה הזה.

חלק ב - שאלות פתוחות

שאלה 1:

נתונים הוקטורים החד ממדיים הבאים:

i	x	label
1	-2	1
2	-1	0
3	0	1
4	1	0
5	2	0
6	3	1
7	4	1

כמו כן נתונה משוואת/אלגוריתם הסיווג הבא:

If $(x > 1)$ then classify as 0

else classify as 1

מריצים את אלגוריתם AdaBoost עם אלגוריתם הסיווג הנ"ל. מתחילים עם משקולות שוות לכל הדוגמאות כפי שלמדנו. מה יהיו ערכי המשקולות של 5 הדוגמאות (הוקטורים) הראשונות לאחר האיטרציה הראשונה (ולאחר נרמול)?

תשובה:

ערכי המשקולות: (יש לכתוב את התשובה הסופית בטבלה הבאה וחובה להסביר את הדרך מתחת לטבלה)

w1	w2	w3	w4	w5

הסבר:

פתרון:

בשאלון היתה טעות שתוקנה במהלך הבחינה, 2 השורות האחרונות בטבלה הוסרו.

i	x	label
1	-2	1
2	-1	0
3	0	1
4	1	0
5	2	0
6	3	1
7	4	1

2 שורות אחרונות בטבלה הוסרו במהלך הבחינה

w1	w2	w3	w4	w5
0.166	0.25	0.166	0.25	0.166

ראשית יש לחשב את מספר השגיאות שהמודל יוצא באיטרציה הראשונה (2 במקרה שלנו) כך שיחסית ל 5 שורות קיבלנו epsilon של 0.4=2%
הרי הפרדיקציות של המודל שלנו בעמודה הימנית :

i	x	label	classified
1	-2	1	1
2	-1	0	1
3	0	1	1
4	1	0	1
5	2	0	0

נחשב את alpha על ידי

$$\alpha = 0.5 \ln((1-0.4)/0.4) = 0.202$$

ואז נחשב את D עבור המקרים הצדקנו בהם:

$$D_{2corr} = (1/5) * \exp(-1 * 0.202) = 0.163$$

ועבור המקרים שטעינו בהם:

$$D_{2incorr} = (1/5) * \exp(0.202) = 0.244$$

הנירמול יתקבל על ידי

$$\text{Norm factor} = (2 * 0.244) + ((5-2) * 0.163) = 0.979$$

ומכאן נחשב את W1 (שבו אין טעות) כ:

$$W1 = 0.204 / 1.224 = 0.166$$

ואת W2 למשל שבו יש טעות כ:

$$W2 = 0.306 / 1.224 = 0.25$$

כך הלאה לגבי יתר המשקלים

שאלה 2:

נתונה הטבלה הבאה:

Outlook	Temperature	Humidity	Windy	Play
Sunny	Hot	High	FALSE	Yes
Sunny	Hot	High	TRUE	No
Overcast	Hot	High	FALSE	Yes
Rainy	Mild	High	FALSE	Yes
Rainy	Cool	Normal	FALSE	No
Rainy	Cool	Normal	TRUE	Yes
Overcast	Cool	Normal	TRUE	Yes
Sunny	Mild	High	FALSE	No
Sunny	Cool	Normal	FALSE	Yes
Rainy	Mild	Normal	FALSE	No
Sunny	Mild	Normal	TRUE	Yes
Overcast	Mild	High	TRUE	No
Overcast	Hot	Normal	FALSE	Yes
Rainy	Mild	High	TRUE	No

בהינתן התכונות Outlook, Temperature, Humidity, Windy רוצים לחזות את העמודה Play באמצעות עץ החלטה עם האלגוריתם שלמדנו בכיתה (על בסיס Entropy).
כפי שקורה בשלב הראשון של האלגוריתם, עליכם לחשב את ה Information Gain של כל אחת מ 4 התכונות ולכתוב מי מהן תופיע בראש עץ ההחלטה.

תשובה:

ערכי ה Information Gain לשלב הראשון של האלגוריתם (יש לכתוב את התשובה הסופית בטבלה הבאה וחוברת לפרט את החישוב מתחת לטבלה):

Outlook	Temperature	Humidity	Windy

התכונה שתופיע בראש העץ היא:

פירוט החישוב:

פתרון:

Outlook	Temperature	Humidity	Windy
0.06	0.128	0.061	0.011

התכונה שתופיע בראש העץ היא:

Temperature

נחשב ראשית את האנטרופיה הכללית של הבעיה

$$\text{Entropy(Play)} = \text{Entropy}(8,6) = -p \log p - q \log q = -(8/14) \log_2(8/14) - (6/14) \log_2(6/14) = 0.985$$

Entropy(Play|Outlook) =

$P(\text{Sunny}) * \text{Entropy}(3,2) + P(\text{Overcast}) * \text{Entropy}(3,1) + P(\text{Rainy}) * \text{Entropy}(2,3) = (5/14) * 0.971 + (4/14) * 0.811 + (5/14) * 0.971 = 0.925$

$\text{Gain}(\text{Play}|\text{Outlook}) = \text{Entropy}(\text{Play}) - \text{Entropy}(\text{Play}|\text{Outlook}) = 0.985 - 0.925 = 0.06$

באופן דומה יש לבצע ליתר התכונות, במקרה של השאלה הזאת ל Temperature יצא ה Gain הגבוה ביותר
(0.128)