

שאלה 1:

נתונה טבלת האימון הבאה:

x1	x2	x3	y
0	1	2	1
8	1	4	0
7	1	1	1
3	2	4	0

סווגו את הוקטורים 3,3,3 ו- 2,3,4 בעזרת פרספטרון (הדרכה: תחילה חשבו את w . ניחוש ראשוני של כל משקל הוא 1, הריצו למשך 2 epochs). מה יהיו הסיווגים שלהם?

[q1]

3,3,3 יסווג כ- 0, ו- 2,3,4 יסווג כ- 0

[a1]

3,3,3 יסווג כ- 1, ו- 2,3,4 יסווג כ- 0

[a2]

3,3,3 יסווג כ- 0, ו- 2,3,4 יסווג כ- 1

[a3]

3,3,3 יסווג כ- 1, ו- 2,3,4 יסווג כ- 1

[a4]

w לא ניתן לחישוב

[a5]

פתרון:

x0	x1	x2	x3	y		w0	w1	w2	w3	Update?
1	0	1	2	1		1	1	1	1	No
1	8	1	4	0		1	1	1	1	Yes
1	7	1	1	1		0	7-	0	3-	Yes
1	3	2	4	0		1	0	1	2-	No
1	0	1	2	1		1	0	1	2-	No

1	8	1	4	0		1	0	1	2-	No
1	7	1	1	1		1	0	1	2-	No
1	3	2	4	0		1	0	1	2-	No

כעת נכפול את הוקטורים 3,3,3 ו- 2,3,4 ב- משקלים שקיבלנו:

$$(1,3,3,3) * (1, 0, 1, -2) < 0 \rightarrow \text{NEG}$$

$$(1,2,3,4) * (1, 0, 1, -2) < 0 \rightarrow \text{NEG}$$

שאלה 2:

נתונה קבוצת האימון הבאה (x_1, x_2) הינם המאפיינים, y מייצג את המחלקה לסיווג):

x_1	x_2	y
2	1	1
2	2	1
2	3	1
2	4	1
2	5	1
7	1	-1
7	2	-1
7	3	-1
7	4	-1
7	5	-1
8	3	1

על מנת לענות על השאלה, מומלץ לצייר את הנקודות במרחב דו מימדי.
מה מהבאים נכון?

[q2]

ריצת SVM-hard-margin לא תתכנס לתוצאה סופית, לעומת זאת בריצת SVM-soft-margin ניתן לקבל את הישר $x=4.5$

[a1]

גם בריצת SVM-hard-margin וגם בריצת SVM-soft-margin נקבל את הישר $x=4.5$

[a2]

גם ריצת SVM-hard-margin וגם ריצת SVM-soft-margin לא תתכנס לתוצאה סופית

[a3]

בריצת SVM-hard-margin ניתן לקבל את הישר $x=7.5$, ואילו בריצת SVM-soft-margin ניתן לקבל את הישר $x=4.5$

[a4]

ריצת SVM-hard-margin לא תתכנס ואילו ריצת SVM-soft-margin תתכנס לישר $x=7.5$


[a5]

פתרון:

כאשר מציירים את הנקודות, מקבלים שתי עמודות, אחת כאשר $x=7$ ואחת כאשר $x=2$. נקודה אחת בעמודה 8 המשמשת כחריגה להתפלגות. הדטה לא ניתן להפרדה ליניארית, ולכן SVM-hard-margin לא יתכנס לתוצאה, ואילו כאשר מריצים את SVM-soft-margin אז בקונפיגורציה מתאימה אפשר לקבל את המפריד $x=4.5$ שעובר בדיוק באמצע.

שאלה 3:

נתון גרף ה ROC הבא:



בחר אפשרות אחת נכונה:

[q3]

ה AUC גדול מה EER

[a1]

ה EER גדול מה AUC

[a2]

ה AUC וה EER שווים

[a3]

ה AUC חיובי וה EER שלילי

[a4]

ה EER חיובי וה AUC שלילי

[a5]


פתרון:

$$AUC = 0.3 \times 0.5 + 0.4 \times 0.6 + 0.2 \times 0.8 + 0.1 \times 1 = 0.65$$

EER הינה הנקודה בה ה-FP שווה ל-(1-TP). במקרה שלפנינו 0.4

שאלה 4:

נתונים הוקטורים הדו-מימדיים הבאים כקבוצת אימון, המחולקים לשתי מחלקות: עיגולים וריבועים.



מהי התשובה הנכונה ביותר מבין האפשרויות הבאות, המתארות אלגוריתמים שייטת ויצליחו לייצר מפריד מושלם (עם אפס שגיאות על קבוצת האימון)?

[q4]

האלגוריתמים: רשת נוירונים (עם מספר שכבות ונוירונים ככל שידרש), SVM עם קרנל כלשהו לא ליניארי

[a1]

האלגוריתמים: רשת נוירונים (עם מספר שכבות ונוירונים ככל שידרש), KNN עם $K=3$ ומשקול מרחקים

[a2]

האלגוריתמים: רשת נוירונים (עם מספר שכבות ונוירונים ככל שידרש), SVM עם קרנל ליניארי

[a3]

האלגוריתמים: עץ החלטה, SVM-Soft עם קרנל ליניארי

[a4]

SVM-Hard האלגוריתמים:

[a5]

פתרון:

כאן קיבלנו את שתי התשובות הראשונות. בתשובה הראשונה יש רשת נוירונים שיכולה למצוא מפריד לא ליניארי שמסוגל להפריד את הקבוצות, וכמו כן SVM עם קרנל לא ליניארי מסוגל לעשות זאת, פוטנציאלית. בתשובה השניה נוסף KNN עם $K=3$ ומשקול מרחקים שמאפשר מצב של סיווג כל נקודה למחלקה הנכונה לפי הגדרת פונקציית משקול מתאימה. כל שאר התשובות מכילות מסווג שבדאות אינו מסוגל להגיע לחלוקה מושלמת.

שאלה 5:

נתונה קבוצת אימון של וקטורים דו מימדיים (x_1, x_2) בינאריים (עם ערכים של 1 או 0 בלבד) המחולקים לשתי מחלקות (p, n) . התייחסו ל Naive Bayes, ובחרו מבין התשובות הבאות את זאת שמכילה אך ורק הסתברויות שיש לחשב (שימו לב: התשובה הנכונה לא בהכרח תכיל את כל ההסתברויות שיש לחשב).

[q5]

$P(x_1|p)$, $P(x_2|p)$, $P(p)$

[a1]

$P(p x_2), P(p x_1), P(p)$	[a2]
$P(p x_2), P(p x_1), P(p, x_1, x_2)$	[a3]
$P(x_2, n), P(x_1, p), P(p), P(n)$	[a4]
$P(x_1 x_2)$	[a5]

פתרון:

מאחר וכל המשתנים הם בינאריים, אז ניתן לכתוב בקיצור את המשתנה או השלילה שלו. בתשובה 1 נמצאות הסתברויות שיש לחשב לנאיב בייס. בכל שאר התשובות אין.

שאלה 6:

התייחסו לאלגוריתם KMEANS וסמנו את התשובה הנכונה ביותר.
[q6]


- הגדלת K עשויה להקטין את ההשפעה השלילית של חריגים (outliers) על תוצאות האישכול [a1]
- ככל שמגדילים את K כך גם גדל ערך ה- distortion [a2]
- האלגוריתם KMEANS אינו מושפע מהמצאות חריגים בקבוצת הוקטורים [a3]
- ערך קטן של K מאפשר לנו למצוא יותר אשכולות (clusters) [a4]
- אין חשיבות למיקום המרכזים בתחילת הריצה, על תוצאות הסיום [a5]

פתרון:

הגדלת K ב- KMEANS עשויה לאפשר לחריגים אלה לנחות באשכולות נפרדים ולכן פחות להפריע לאשכולות המרכזיים שאינם חריגים.

שאלה 7:

הגרף הבא מראה עקומות של train ו validation עבור מודל למידה עם סיבוכיות הולכת ועולה.



בחר באחת מהאפשרויות הבאות עבור המקרה הסביר:

[q7]

עקומה A מבטאת את שגיאת ה train ועקומה B מבטאת את שגיאת ה validation. בצד שמאל של הגרף ה variance נמוך ובצד ימין גבוה. בצד שמאל של הגרף ה bias גבוה ובצד ימין נמוך.

[a1]

עקומה A מבטאת את שגיאת ה train ועקומה B מבטאת את שגיאת ה validation. בצד שמאל של הגרף ה variance גבוה ובצד ימין נמוך. בצד שמאל של הגרף ה bias נמוך ובצד ימין גבוה.

[a2]

עקומה A מבטאת את שגיאת ה validation ועקומה B מבטאת את שגיאת ה train. בצד שמאל של הגרף ה variance נמוך ובצד ימין גבוה. בצד שמאל של הגרף ה bias גבוה ובצד ימין נמוך.

[a3]


עקומה A מבטאת את שגיאת ה validation ועקומה B מבטאת את שגיאת ה train. בצד שמאל של הגרף ה variance גבוה ובצד ימין נמוך. בצד שמאל של הגרף ה bias נמוך ובצד ימין גבוה.

[a4]

עקומה A מבטאת את שגיאת ה validation ועקומה B מבטאת את שגיאת ה train. בצד שמאל של הגרף ה variance נמוך ובצד ימין גבוה. בצד שמאל של הגרף ה bias גבוה ובצד ימין נמוך.

[a5]


פתרון:



הוחלט לקבל את כל התשובות מכיוון שלא היתה אחידות במעבר על הנושא בין הכיתות, על אף שהחומר נמצא במצגות הקורס.

שאלה 8:

נתונה רשת נוירונים הבאה:



כמו כן נתונים המשקלים הבאים:

$$W_{AD}=W_{BE}=W_{CF}=1$$

$$W_{AE}=W_{BF}=W_{CD}=W_{BD}=-1$$

$$W_{DG}=W_{EG}=W_{FG}=2$$

פונקציית האקטיבציה לשכבת הפלט היא פונקציית sgn. ערך הסף ב G הוא 0.5 (כפי שמופיע בתרשים) פונקציית האקטיבציה לשכבות החביוות היא פונקציית סיגמואיד.

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

לנוחיותכם, נוסחת הסיגמואיד:

מה יהיה הפלט של הרשת עבור הקלט:

$$X_1=3, X_2=2, X_3=1$$

[q8]

הפלט של הרשת יהיה 1, ואם נשנה את ערך הסף של G ל 3.5 הפלט של הרשת ישתנה.

[a1]

הפלט של הרשת יהיה 1, ואם נשנה את ערך הסף של G ל 1.5 הפלט של הרשת ישתנה.

[a2]

הפלט של הרשת יהיה 0, ואם נשנה את ערך הסף של G ל 1.5 הפלט של הרשת ישתנה.

[a3]

הפלט של הרשת יהיה 0, ואם נשנה את ערך הסף של G ל 1.5 הפלט של הרשת לא ישתנה.

[a4]

הפלט של הרשת יהיה 0, ואם נשנה את ערך הסף של G ל 1 הפלט של הרשת לא ישתנה.

[a5]


פתרון:

$$\begin{aligned} D &: \text{sigmoid}(x_1 w_{AD} + x_2 w_{BD} + x_3 w_{CD}) = \text{sigmoid}(3 \times 1 + 2 \times -1 + 1 \times -1) = \text{sigmoid}(0) = 0.5 \\ E &: \text{sigmoid}(x_1 w_{AE} + x_2 w_{BE}) = \text{sigmoid}(3 \times -1 + 2 \times 1) = \text{sigmoid}(-1) = 0.27 \\ F &: \text{sigmoid}(x_2 w_{BF} + x_3 w_{CF}) = \text{sigmoid}(2 \times -1 + 1 \times 1) = \text{sigmoid}(-1) = 0.27 \\ G &: \text{SGN}((D \times w_{DG} + E \times w_{EG} + F \times w_{FG}) - 0.5) = \\ &\text{SGN}((0.5 \times 2 + 0.27 \times 2 + 0.27 \times 2) - 0.5) = \text{SGN}(1.5) > 0 \rightarrow 1 \end{aligned}$$

במקרה של ערך סף של 3.5 ה SGN יופעל על ערך שלילי ומכאן שהפלט ישתנה בהתאם

שאלה 9:

נתונים הוקטורים הדו-מימדיים הבאים (המרחק בין כל וקטור לוקטור הוא 2, בשני הצירים):



איזו מההרצות הבאות תסתיים עם מספר אשכולות (clusters) הגדול ביותר?
הערות:

א. ב - DBSCAN הוקטור עצמו לא נחשב לערך המספר המינימלי המוגדר ב - MinPnts
ב. ב - DBSCAN וקטור רעש לא נחשב אשכול

[q9]

אלגוריתם KMEANS עם $K=3$, מרחק L_2 , ומרכזים התחלתיים הם שני הוקטורים הראשונים משמאל

[a1]

אלגוריתם DBSCAN עם $\text{MinPnts}=3$, $r=2$, כאשר מתחילים מהוקטור השמאלי ביותר

[a2]

אלגוריתם DBSCAN עם $\text{MinPnts}=4$, $r=2$, כאשר מתחילים מהוקטור השמאלי ביותר

[a3]

אלגוריתם KMEANS עם $K=2$, מרחק L_2 , ומרכזים התחלתיים הם שני הוקטורים הראשונים מימין

[a4]

אלגוריתם KNN עם $K=8$

[a5]

פתרון:

תשובה א- נוצרים 3 אשכולות לפי הגדרה.

תשובה ב- כל הוקטורים הם Core objects חוץ מאלה שבקצוות, שמשווגים כ - border. בכל אופן זה מביא את כולם להיות יחד באותו האשכול.

תשובה ג- במקרה זה כל הוקטורים משווגים כרעש, ולכן מספר האשכולות הוא 0.

תשובה ד- מספר האשכולות הוא 2.

תשובה ה- זהו אינו אלגוריתם לאשכול.

שאלה 10:

סמנו את ההצהרה הנכונה מבין ההצהרות הבאות.

[q10]

בתום אימון SVM, כל מה שצריך לשמור על מנת לסווג דוגמא חדשה, זה את ה - support vectors ואת הגדרת הקרנל בו השתמשו

[a1]

משתמשים ב Info gain על מנת למקסם את המרווח של SVM

[a2]

אם ישנה תלות בין שני מאפיינים בקבוצת אימון כלשהי, לא ניתן להשתמש ב Naive Bayes

[a3]

למידת יתר (overfitting) מתרחשת רק כאשר יש מעט מאפיינים בקבוצת האימון

[a4]

אלגוריתם ID3 עובד רק במקרה של סיווג לשתי מחלקות בלבד (סיווג בינארי)

[a5]

פתרון:

תשובה א - זה כל מה שצריך על מנת לסווג דוגמא חדשה. כשאנחנו אומרים שהם support vectors, זה למעשה אומר שיהיו לנו את האלפות שלהם, כי אחרת לא היינו יכולים לדעת. בכל אופן כל שאר התשובות אינן נכונות. עם זאת החלטנו לקבל את כל התשובות רק כי הניסוח בתשובה ג' עשוי להתפרש לא נכון.

שאלה 11:

התייחסו לאלגוריתם adaboost וסמנו את התשובה הנכונה ביותר.
[q11]

לאורך כל הריצה לא ייתכן שייבחר מסווג חלש זהה בשתי איטרציות עוקבות

[a1]

לאורך כל הריצה לא ייתכן שייבחר מסווג חלש שיצליח לסווג את קבוצת האימון בצורה מושלמת

[a2]

אין אפשרות להשתמש ב Naive Bayes כמסווג חלש

[a3]

הפונקציה D מעניקה משקלים למסווגים שיבחרו במהלך הריצה

[a4]

ניתן לפתור בעיה מרובת מחלקות, בריצה אחת של האלגוריתם

[a5]

פתרון:

זה מה שהוכחנו בתרגול האחרון, ולמעשה תמצית הרציונאל מאחורי AdaBoost.

שאלה 12:

נתונה קבוצת האימון הבאה:

X1	X2	Y
0	0	0
0	1	1
1	0	0
1	1	1
2	0	1
2	1	1

סמנו את התשובה הנכונה ביותר.

[q12]

$$H(Y) \approx 0.92, H(Y|X1) \approx 0.66, H(Y|X2) \approx 0.46$$

[a1]

$$H(Y) \approx 0.92, H(Y|X1) \approx 0.46, H(Y|X2) \approx 0.66$$

[a2]

$$H(Y) = 1, H(Y|X1) \approx 0.66, H(Y|X2) \approx 0.46$$

[a3]

הנתונים שניתנו אינם מספיקים לחישוב אנטרופיה

[a4]

$$H(Y) = 2/6, H(Y|X1) = 1/3, H(Y|X2) = 1/2$$

[a5]

פתרון:

מדובר חישוב פשוט של ערכי אנטרופיה.

$$H(Y) = -2/6 \log(2/6) - 4/6 \log(4/6) \approx 0.92$$

$$H(Y|X1) = 2/6 * 1 + 2/6 * 1 + 2/6 * 0 = 4/6 \approx 0.66$$

$$H(Y|X2) = 3/6 * H(2,1) + 3/6 * 0 \approx 0.46$$

חלק ב - שאלות פתוחות

שאלה 1:

נתונים הוקטורים החד ממדיים הבאים:

i	x	label
1	-2	1
2	-1	0
3	0	0
4	1	1
5	2	0
6	3	0
7	4	0

כמו כן נתונה משוואת/אלגוריתם הסיווג הבא:

If ($x > 2$) then classify as 0

else classify as 1

מריצים את אלגוריתם AdaBoost עם אלגוריתם הסיווג הנ"ל. מתחילים עם משקולות שוות לכל הדוגמאות כפי שלמדנו. מה יהיו ערכי המשקולות של 5 הדוגמאות (הוקטורים) הראשונות לאחר האיטרציה הראשונה (ולאחר נרמול)?

תשובה:

ערכי המשקולות: (יש לכתוב את התשובה הסופית בטבלה הבאה וחובה להסביר את הדרך מתחת לטבלה)

w1	w2	w3	w4	w5
----	----	----	----	----

--	--	--	--	--

הסבר:

פתרון:

	A	B	C	D	E	F
1	Lines	7				
2	i	x	label	classified		
3	1	-2	1	1		
4	2	-1	0	1		
5	3	0	0	1		
6	4	1	1	1		
7	5	2	0	1		
8	6	3	0	0		
9	7	4	0	0		
10						
11	concat	1				
12	X> THRESHOLD		Threshold	2		
13	errors	3				
14						
15			פתרון			
16	epsilon	0.428571				
17	alpha	0.143841				
18	D_2corr	0.123718				
19	D_2 incorr	0.164957				
20	Norm Factor =		0.989743			
21	w1	0.125				
22	w2	0.166667				
23	w3	0.166667				
24	w4	0.125				
25	w5	0.166667				
26	w6	0.125				
27	w7	0.125				
28						
29						

שאלה 2:

נתונה הטבלה הבאה:

Outlook	Temperature	Humidity	Windy	Play
Overcast	Mild	High	TRUE	No
Sunny	Hot	High	TRUE	No
Overcast	Mild	High	FALSE	Yes
Rainy	Mild	Normal	FALSE	Yes
Overcast	Hot	Normal	FALSE	No
Sunny	Hot	Normal	TRUE	Yes
Overcast	Mild	Normal	TRUE	Yes
Sunny	Mild	High	FALSE	No
Sunny	Hot	Normal	FALSE	Yes
Rainy	Cool	Normal	FALSE	No
Sunny	Hot	Normal	TRUE	No
Rainy	Cool	High	TRUE	No
Overcast	Cool	Normal	FALSE	Yes
Rainy	Cool	High	TRUE	Yes

בהינתן התכונות Outlook, Temperature, Humidity, Windy רוצים לחזות את העמודה Play באמצעות עץ החלטה עם האלגוריתם שלמדנו בכיתה (על בסיס Entropy).
כפי שקורה בשלב הראשון של האלגוריתם, עליכם לחשב את ה Information Gain של כל אחת מ 4 התכונות ולכתוב מי מהן תופיע בראש עץ ההחלטה.

תשובה:

ערכי ה Information Gain לשלב הראשון של האלגוריתם (יש לכתוב את התשובה הסופית בטבלה הבאה
והובה לפרט את החישוב מתחת לטבלה):

Outlook	Temperature	Humidity	Windy

התכונה שתופיע בראש העץ היא:

פירוט החישוב:

פתרון:

בדומה לצורת החישוב של מועד א' (ערכי הטבלה רק שונים) -

Feature	Information Gain
Outlook	0.021
Temperature	0.021
Humidity	0.061
Windy	0.015

נבחר את התכונה עם הIG הגבוה ביותר - Humidity