

חלק פתוח (שאלה פתוחה פתרון בשאלון ולא במחברת)

שימו לב - יש לרשום את התשובה לשאלה של החלק הפתוח בגוף השאלון בלבד -
לא תיבדק מחברת טיוטא.

נתונים הוקטורים החד ממדיים הבאים:

#	f1	class
1	1	0
2	2	0
3	1	0
4	2	1
5	1	1

כמו כן נתונה משוואת/אלגוריתם הסיווג הבא:

1If (x>=2) then classify as
else classify as 0

מריצים את אלגוריתם AdaBoost עם אלגוריתם הסיווג הנ"ל. מתחילים עם משקולות שוות לכל הדוגמאות כפי שלמדנו.

מה יהיו ערכי המשקולות של 2 הדוגמאות (הוקטורים) הראשונות לאחר האיטרציה הראשונה (וללא נרמול)? השאירו תשובתכם בדיוק של ספרה אחת לאחר הנקודה תזכורת לנוסחאות ADABOOST

$$\alpha_m = \frac{1}{2} \ln \left(\frac{1 - \epsilon_m}{\epsilon_m} \right)$$

$$D_{t+1}(i) = \frac{D_t(i) \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$$

לנוחותכם טבלאות חישובים שחלקם עשויים לסייע לכם בתשובתכם:

x	e^x	e^{-x}
0.35	1.4	0.7
0.2	1.2	0.8
0.45	1.6	0.6

x	$\ln(x)$
0.5	-0.7
1	0.0
1.5	0.4
2	0.7
2.5	0.9

תשובה:

ערכי המשקולות: (יש לכתוב את התשובה הסופית בטבלה הבאה וחובה להסביר את הדרך מתחת לטבלה)

w1	w2

הסבר (חובה להראות כיצד הגעתם למשקולות):

פתרון שאלה פתוחה:

IF (f1>=2) then POS					
#	f1	class	prediction	ERROR	WEIGHT OF EXAMPLE
1	1	0	0	0	0.2
2	2	0	1	1	0.2
3	1	0	0	0	0.2
4	2	1	1	0	0.2
5	1	1	0	1	0.2

$$\text{weighted error } (\varepsilon) = 0.2 + 0.2 = 0.4$$

$$\alpha = \frac{1}{2} \ln \left(\frac{1 - \varepsilon}{\varepsilon} \right) = \frac{1}{2} \ln \left(\frac{1 - 0.4}{0.4} \right) = \frac{1}{2} \ln \left(\frac{0.6}{0.4} \right) = \frac{1}{2} \ln(1.5) = \frac{1}{2} \times 0.4 = 0.2$$

משקל דוגמא ראשונה:


$$w_1 = 0.2 \times e^{-0.2 \times (-1) \times (-1)} = 0.2 \times e^{-0.2 \times (-1) \times (-1)} = 0.2 \times 0.8 = 0.16$$

משקל דוגמא שניה:

$$w_2 = 0.2 \times e^{-0.2 \times (-1) \times (+1)} = 0.2 \times 1.2 = 0.24$$

חלק סגור (שאלות רב ברירה)

1. בעיית אישכול:
נתונים הווקטורים הבאים:



הרצנו שני אלגוריתמי אישכול

אלגוריתם KMEANS עבור $K=2$. התחלנו עם המרכזים ההתחלתיים הבאים: $(5,0)$, $(-1,0)$


אלגוריתם DBSCAN עם הפרמטרים הבאים: $\text{MINPTS} = 5$ (כולל הווקטור עצמו), $r=1.5$, כאשר סדר

בחירת הווקטורים הוא: $(-1,0)$ אח"כ $(0,5)$ אח"כ $(2,0)$ אח"כ $(4,5)$ אח"כ $(5,0)$ ואח"כ בחירת ווקטורים

(ככל שיש צורך) בסדר אקראי

אילו מהבאים הינו סיום אפשרי לאלגוריתם ?

א.



פתרון:

KMEANS – ניתן לראות בבירור חלוקה מיידית של כל הווקטורים הקרובים לכל אחד משני המרכזים
ההתחלתיים. לגבי הווקטור (2,0) ניתן לשייך אותו לכל אחד מהמרכזים (מרחק שווה)



חישוב מרכזים:

$$center_1(x) = \frac{3 \times 6 + 5 \times 6 + 4}{13} = 4, center_1(y) = \frac{2 \times (0 + 1 + 2 + 3 + 4 + 5) + 5}{13} = \frac{35}{13} = 2.6$$

$$center_2(x) = \frac{-1 \times 6 + 1 \times 6 + 0 + 2}{14} = 0.1, center_2(y) = \frac{2 \times (0 + 1 + 2 + 3 + 4 + 5) + 5 + 0}{14} = 2.5$$

אין צורך לבצע חישוב - גם ללא חישוב מדויק ניתן להסיק שה-y של המרכז השמאלי נמוך מה-y של המרכז הימני

DBSCAN

ניתן לראות כי הווקטורים היחידים שיש ברדיוס 1.5 שלהם 5 אובייקטים (כולל הם עצמם) הם:

(0,5), (2,0), (4,5)

הם "יאספו" אליהם לאשכול את הווקטורים הסמוכים להם שיהפכו לווקטורי "גבול" (border)

למשל הווקטור (2,0) יחובר לאשכול עם:

(1,0)(1,1)(3,0)(3,1)

שאר הווקטורים יהפכו לווקטורי "רעש"

2. החלטנו לבנות מע' בקרת כניסה למשרד. יש לנו 8 עובדים במשרד ואנו רוצים לבנות מע' זיהוי פנים

כך שבהינתן תמונת פנים המערכת תסווגה לאחד מ-8 "מחלקות" (מחלקה - Y)

בשלב אימון מערכת הלמידה הזנו מס' זהה של דוגמאות (תמונות) זהה עבור כל עובד.

$H(Y)$ - אנתרופיה של "מחלקה"

$MAX_IG(Y|f1)$ - האינפורמישן גיין המקסימאלי של מחלקה בהינתן תכונה כלשהי $f1$

בחר תשובה אחת נכונה:

א.

$$H(Y) = 3, MAX_IG(Class|f1) = 3$$

אם היינו מזינים מס' שונה של דוגמאות עבור כל עובד אז האנתרופיה של מחלקה הייתה שונה

פתרון:


$$H(Y) = 8 \times \left[-\frac{1}{8} \times \log_2 \left(\frac{1}{8} \right) \right] = 8 \times \left[-\frac{1}{8} \times (-3) \right] = 3$$

האינפורמישן גיין המקסימאלי יכול להיות 3 (כגובה האנתרופיה) - אם נמצא תכונה שמפרידה באופן מלא בין

המחלקות

האנתרופיה חושבה עם הנתון שהסתברות לכל מחלקה היא $\frac{1}{8}$

3. נתון גרף הROC הבא לבעיית סיווג שנבחנה על 100 דוגמאות חיוביות ו200 שליליות.
(שימו לב – TPR = True Positive Rate, FPR = False Positive Rate)



נתון ה- Confusion Matrix הבא (שימו לב, נתון לא באחוזים אלא במספרים אבסולוטיים). מה מהבאים מייצג Confusion Matrix אפשרי לבעיה זו


א.

Confusion Matrix:

		Predicted	
		Pos	Neg
Actual	Pos	100	0
	Neg	100	100

פתרון:

בנקודה זו בגרף יש 100% גילוי (כלומר 100 גילויי אמת) ו-50% התראות שווא (כלומר 100 התראות שווא)



4. נתונה טבלת האימון הבאה:

	f1	f2	f3	Class
1	1	4	1	P
2	1	2	3	P
3				P
4	-1	4	0	P
5	1	0	-2	N
6	-1	-1	1	N
7				N
8	1	0	-3	N

נדרש לסווג את הווקטור $(1,2,2)$ עפ"י אלגוריתם נאיב ביס. אפשר להניח שהמאפיינים בלתי תלויים זה בזה. חסרים לנו בטבלה ערכי הווקטורים #7, #3 אלו מהאפשרויות הבאות לערכי הווקטור לא יחייבו פעולת החלקה:

פתרון: ווקטור 3 : $(0,0,2)$ ווקטור 7 : $(0,2,2)$

פתרון:

החלקה צריך לבצע כאשר אין מופע של ערך מאפיין נדרש בשתי המחלקות


$(f1=1, f2=2, f3=2)$

$f1=1$ מופיע גם עבור P וגם עבור N – לכן אין משמעות לערך שמופיע בתשובה

$f2=2$ מופיע עבור P אך לא עבור N – לכן אנו חייבים שיופיע כך עבור ווקטור מס' 7

$f3=2$ לא מופיע עבור P ולא עבור N – לכן אנו חייבים שיופיע כך עבור ווקטורים מס' 7, 3

5. לבעיית סיווג בת 2 מחלקות נתונים הווקטורים הבאים בקבוצת האימון ריבוע – "חיובי", עיגול – "שלילי":




הריצו אלגוריתם SVM-HARD-MARGIN עם קרנל לינארי:
משוואת הסיווג:

$$Y = \text{SGN}(w_1 \times f_1 + w_2 \times f_2 - b)$$

מהי משוואת הסיווג שהתקבלה?
פתרון:

$$w_1 = 3, w_2 = 0, b = -6$$

לפי הגדרת MARGIN-HARD-SVM צריך לייצר את המפריד עם ה-margin הגדול ביותר, לכן ברור שהמפריד הוא כדלקמן:



ברור שווקטורים על הקו ערכם צריך להיות שווה ל-0 כשמציבים אותם במשוואת הקו.
נבחר למשל שתי נקודות:

$$(f_1 = -2, f_2 = 0)$$

$$(f_1 = -2, f_2 = 1)$$

$$w_1 \times f_1 + w_2 \times f_2 - b$$

$$w_1 \times (-2) + w_2 \times (0) - b = 0$$

$$w_1 \times (-2) + w_2 \times (1) - b = 0$$

$$w_2 \rightarrow 0$$

$$-2w_1 = b$$

לכן התשובה

$$w_1 = 3, w_2 = 0, b = -6$$

נכונה

6. בעיית מולטי-קלאס - בהינתן שאנו יודעים לפתור בעיה בינארית, למדנו שתי גישות:

One vs. One

One vs. All

קיבלנו בעיה בה 7 מחלקות.

- א. בגישת one vs. all נייצר 7 אלגוריתמי למידה ובגישת one vs. one נייצר 21 אלגוריתמי למידה
- ב. בגישת one vs. all נייצר 7 אלגוריתמי למידה ובגישת one vs. one נייצר 28 אלגוריתמי למידה
- ג. בגישת one vs. all נייצר 6 אלגוריתמי למידה ובגישת one vs. one נייצר 21 אלגוריתמי למידה
- ד. בגישת one vs. all נייצר 8 אלגוריתמי למידה ובגישת one vs. one נייצר 42 אלגוריתמי למידה
- ה. בגישת one vs. all נייצר 1 אלגוריתמי למידה ובגישת one vs. one נייצר 21 אלגוריתמי למידה

פתרון:

בגישת One vs. all אנו מייצרים אלגוריתם סיווג בינארי המפריד בין כל מחלקה לכל שאר המחלקות יחד. עבור 7 מחלקות ייווצרו 7 מכונות למידה
בגישת one vs. one אנו מייצרים מפרידים לכל הזוגות האפשריים: המחלקה הראשונה נגד שש האחרות, לבאה בתור צריך מפרידים נגד 5 האחרות וכו'

$$6+5+4+3+2+1 = 21$$

7. KNN ("השכנים הקרובים"). שקלול מרחקים (הנותן לוקטור קרוב משקל גדול יותר) לא ישפיע לעולם

עבור

א. $k=2$

ב. $k=3$ ויש לנו 3 ווקטורים בלבד בקבוצת האימון

ג. $k=3$ ויש לנו 30 ווקטורים בלבד בקבוצת האימון

ד. שקלול מרחקים לעולם עשוי להשפיע

ה. שקלול מרחקים ישפיע רק כאשר k זוגי

בשאלה זו החלטנו לקבל את כל התשובות (מאחר שאף אחת מהן לא עונה

בצורה נכונה)


8. התייחסו לאלגוריתם KMEANS וסמנו את התשובה הנכונה ביותר.

- א. הגדלת K עשויה להקטין את ההשפעה השלילית של חריגים (outliers) על תוצאות האישכול וה-distortion
- ב. ככל שמגדילים את K כך גם גדל ערך ה-distortion – לא נכון. ראינו בהרצאה שהגדלת k דווקא מפחית את ה-distortion
- ג. ה-distortion באלגוריתם KMEANS אינו מושפע מהמצאות חריגים בקבוצת הוקטורים – לא נכון. כפי שראינו החריגים יסיטו את מרכז האשכול
- ד. ערך קטן של K מאפשר לנו למצוא יותר אשכולות (clusters) - לא נכון. K מגדיר את מס' האשכולות
- ה. אין חשיבות למיקום המרכזים בתחילת הריצה, על תוצאות הסיום - לא נכון. הראינו בהרצאה שלא נכון

פתרון:

הגדלת K ב KMEANS - עשויה לאפשר לחריגים אלה לנחות באשכולות נפרדים ולכן פחות להפריע לאשכולות המרכזים שאינם חריגים

9. נתונה רשת נוירונים הבאה:



כמו כן נתונים המשקלים הבאים:

$$W_{AD}=W_{BE}=W_{CF}=1$$

$$W_{AE}=W_{BF}=W_{CD}=W_{BD}=-1$$

$$W_{DG}=W_{EG}=W_{FG}=2$$

פונקציית האקטיבציה לשכבת הפלט היא פונקציית sgn. ערך הסף ב G הוא 0.5 (כפי שמופיע בתרשים)
פונקציית האקטיבציה לשכבות החביוות היא פונקציית סיגמואיד.
לנוחיותכם, נוסחת הסיגמואיד:

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

מה יהיה הפלט של הרשת עבור הקלט:

$$X_1=3, X_2=2, X_3=1$$

לנוחותכם מצורפים ערכי הסיגמאוויד הבאים:

$$\text{Sigmoid}(-2) = 0.11$$

$$\text{Sigmoid}(-1) = 0.26$$

$$\text{Sigmoid}(0) = 0.5$$

$$\text{Sigmoid}(1) = 0.73$$

$$\text{Sigmoid}(2) = 0.88$$

א. הפלט של הרשת יהיה 1, ואם נשנה את ערך הסף של G ל 3.5 הפלט של הרשת ישתנה.

פתרון:

$$D : \text{sigmoid}(x_1 w_{AD} + x_2 w_{BD} + x_3 w_{CD}) = \text{sigmoid}(3 \times 1 + 2 \times -1 + 1 \times -1) = \text{sigmoid}(0) = 0.5$$

$$E : \text{sigmoid}(x_1 w_{AE} + x_2 w_{BE}) = \text{sigmoid}(3 \times -1 + 2 \times 1) = \text{sigmoid}(-1)$$

$$F : \text{sigmoid}(x_2 w_{BF} + x_3 w_{CF}) = \text{sigmoid}(2 \times -1 + 1 \times 1) = \text{sigmoid}(-1)$$

$$\text{Input to G: } 0.5 \times 2 + 0.26 \times 2 + 0.26 \times 2 = 3.08$$

חוצה את ערך הסף חצי אך לא את ערך הסף 3.5